



Probabilidade e Amostras

POL 177
Robert Vidigal




Lembretes

- Lista #2 para entregar terça-feira, 15 de setembro.
- Prova #2 quinta-feira, 17 de setembro

Probabilidade

- Transformando intuições sobre como “provável” algo é em números




Probabilidade

$$\text{Probabilidade} = \frac{\text{\# de vezes evento/resultado de interesse pode ocorrer}}{\text{Total \# de vezes qualquer resultado/evento pode ocorrer}}$$

Probabilidade

Probabilidade = # de vezes evento/resultado de interesse pode ocorrer

Total # de vezes qualquer resultado/evento pode ocorrer



4 naipes

13 cartas em cada naipe

52 cartas num baralho

Probabilidade

Probabilidade = $\frac{\text{\# de vezes evento/resultado de interesse pode ocorrer}}{\text{Total \# de vezes qualquer resultado/evento pode ocorrer}}$

Total # de vezes qualquer resultado/evento pode ocorrer



4 naipes 13 cartas em cada naipe 52 cartas num baralho

Probabilidade

Probabilidade = $\frac{\text{\# de vezes evento/resultado de interesse pode ocorrer}}{\text{Total \# de vezes qualquer resultado/evento pode ocorrer}}$

Total # de vezes qualquer resultado/evento pode ocorrer



4 naipes 13 cartas em cada naipe 52 cartas num baralho

Selecionar aleatoriamente: Simpsons

Simpson	Sexo	Cabelo
Homer	Masculino	Careca
Marge	Mulheres	Azul
Bart	Masculino	Amarelo
Lisa	Mulheres	Amarelo
Maggie	Mulheres	Amarelo

Probabilidade de escolher um homem?

Probabilidade de apanhar um homem careca?

Probabilidade de apanhar uma mulher de cabelo amarelo?

Probabilidade de escolher uma mulher de cabelos azuis
ou um rapaz de cabelos amarelos?

Se restringimos a mulheres, a probabilidade
de selecionar uma de cabelos azuis?

Seleccionar aleatoriamente: Simpsons

Simpson	Sexo	Cabelo
Homer	Masculino	Careca
Marge	Mulheres	Azul
Bart	Masculino	Amarelo
Lisa	Mulheres	Amarelo
Maggie	Mulheres	Amarelo

Probabilidade de escolher um homem? $= 2 / 5$

Probabilidade de apanhar um homem careca? $= 1 / 5$


Probabilidade de apanhar uma mulher de cabelo amarelo? $= 2 / 5$

Probabilidade de escolher uma mulher de cabelos azuis $= 2 / 5$
ou um rapaz de cabelos amarelos?

Se restringimos a mulheres, a probabilidade
de selecionar uma de cabelos azuis? $= 1 / 3$

Erro de amostragem

- Digamos que estamos interessados na idade dos presidentes dos EUA quando eleitos...



Erro de amostragem

- Dado o erro amostral, como podemos fazer uma inferência sobre uma população baseada em uma única amostra?


Distribuição amostral

Distribuição amostral

- Pense em coletar várias amostras da mesma população e nos resultados de cada amostra
 - Isso cria uma distribuição amostral
 - Cada amostra produz uma «pontuação» adicionada à distribuição amostral
- Diferentes distribuições de amostragem produzem estatísticas diferentes
 - Vamos nos concentrar no MEIO


Distribuição amostral

- Digamos que estamos interessados na idade dos presidentes dos EUA quando eleitos...
 - **Amostras repetidas de 5 presidentes e idade média recorde**




Distribuição amostral

- Digamos que estamos interessados na idade dos presidentes dos EUA quando eleitos...
 - **Amostras repetidas de 5 presidentes e idade média**
 - Depois de 20 amostras...




Distribuição amostral

- Digamos que estamos interessados na idade dos presidentes dos EUA quando eleitos...
 - **Amostras repetidas de 5 presidentes e idade média**
 - Depois de 60 amostras...



Distribuição amostral

- Digamos que estamos interessados na idade dos presidentes dos EUA quando eleitos...
 - **Amostras repetidas de 5 presidentes e idade média**
 - Após 200 amostras



Distribuição amostral


- O que é familiar sobre esta distribuição?



Distribuição amostral da média

- Digamos que estamos interessados na idade dos presidentes dos EUA quando eleitos...
 - **Amostras repetidas de 5 presidentes e idade média recorde**
 - Após TODAS as amostras possíveis!

Note que a média
dessa distribuição
amostral = a média
populacional



Teorema do limite central (TLC)

- **Distribuição das médias por amostragem torna-se mais normal à medida que as amostras aumentam de tamanho**
 - Mesmo quando a população original não é normalmente distribuída!
 - A distribuição das médias é menos variável do que a distribuição dos escores individuais

Teorema do limite central (TLC)

- Relativamente poucas médias amostrais devem estar longe da média populacional...
- Isto é, a maioria das médias da amostra deve estar próxima da população media!




Pouco frequentes



Frequentes



Pouco frequentes



Distribuição amostral

- A forma exata da distribuição da amostra depende do tamanho da amostra!
- Para uma dada população, existe uma distribuição amostral da média para cada tamanho da amostra possível
 - O tamanho da amostra e o erro de amostragem estão relacionados
 - **Maior** o tamanho da amostra, **menor** o de erro de amostragem

O escore z mede uma distância

Quantos desvios-padrão separam um valor da média?

$$z = (x - \mu) / \sigma$$

Escore z	Posição do valor
Negativo	Abaixo da média
Zero	Igual à média
Positivo	Acima da média

Um exemplo com uma observação

Média da população: $\mu = 20$ Desvio-padrão: $\sigma = 4$

Uma observação tem valor $x = 28$.

$$z = (28 - 20) / 4 = 2$$



28 está dois desvios-padrão acima de 20.

Indivíduos e médias variam de formas diferentes


Mesma população: $\mu = 20$ e $\sigma = 4$. Amostras com $n = 16$.

Valores individuais

Cada ponto representaria uma observação.

Médias amostrais

Cada ponto representaria a média de 16 observações.



Exemplo hipotético: população normal e observações independentes.

O erro-padrão mede a variação das médias

$$EP = \sigma / \sqrt{n}$$


Símbolo	Significado
σ	Desvio-padrão das observações na população
n	Número de amostras
EP	Desvio-padrão das médias amostrais

Com $\sigma = 4$ e $n = 16$: $EP = 4 / \sqrt{16} = 1$

Amostras maiores produzem médias menos variáveis

A população permanece a mesma: $\mu = 20$ e $\sigma = 4$.

Tamanho n	Erro-padrão
4	$4 / \sqrt{4} = 2$
16	$4 / \sqrt{16} = 1$
64	$4 / \sqrt{64} = 0,5$



Quadruplicar n reduz o erro-padrão à metade.

O escore z de uma média amostral

Quantos erros-padrão separam a média da amostra da média da população?

$$z = (\bar{x} - \mu) / EP$$

$\bar{x}$ = média da amostra μ = média da população

$$EP = \sigma / \sqrt{n}$$

Um z de 2 indica uma média 2 erros-padrão acima de μ .

O mesmo valor, duas comparações

População: $\mu = 20$ e $\sigma = 4$. Score: 22.

	Uma amostra	Média de 16 amostras
Score	$x = 22$	$\bar{x} = 22$
Escala de comparação	$\sigma = 4$	$EP = 4 / \sqrt{16} = 1$
Cálculo do escore z	$(22 - 20) / 4$	$(22 - 20) / 1$
Resultado	$z = 0,5$	$z = 2$

A mesma distância de 2 unidades da média equivale a 2 erros-padrão quando avaliamos a média de 16 observações.

A probabilidade corresponde a uma área


$$\mu = 20 \quad \sigma = 4 \quad n = 16 \quad EP = 1$$

Média: 22

$$z = (22 - 20) / 1 = 2$$

2,28%

das amostras teriam
média igual ou superior a 22.



Região verde: média ≥ 22


Suposições: população normal e observações independentes.

Uma média de 23 é surpreendente?

Uma população tem média 20.

Sorteamos 16 observações e calculamos sua média.

A média amostral encontrada é 23.




Essa diferença é grande em relação a quê?

Exemplo hipotético: população normal e observações independentes.

A variação entre médias amostrais

Imagine repetir o sorteio muitas vezes.

Amostra	Observações	Média
1	16	8
2	16	20
3	16	23
4	16	32



Cada ponto representa uma média

O erro-padrão mede quanto essas médias variam.

O erro-padrão dá a escala

Primeiro cenário

Média populacional: $\mu = 20$

Desvio-padrão populacional: $\sigma = 48$

Observações em cada amostra: $n = 16$

$$EP = \sigma / \sqrt{n} = 48 / \sqrt{16} = 12$$

O desvio-padrão das médias amostrais é 12 unidades.

A média 23 está perto do centro


$$\mu = 20 \quad \sigma = 48 \quad n = 16$$

$$z = (23 - 20) / 12$$

$$z = 0,25$$

23 está apenas 0,25
erro-padrão acima de 20.

Distribuição das médias: EP = 12



Média amostral

Centro = 20


Médias de 23 ou mais são frequentes

$$\mu = 20 \quad \sigma = 48 \quad n = 16 \quad EP = 12$$

40,13%

das amostras teriam
média igual ou superior a 23.

Cerca de 401 em 1.000 repetições.



Média amostral

Centro = 20 Região verde: média ≥ 23

Uma população com menor dispersão


A média continua 20. Cada amostra continua com 16 observações.

Cinza: EP = 12 Verde: EP = 1

Agora, $\sigma = 4$

$$EP = 4 / \sqrt{16} = 1$$

As médias ficam mais concentradas em torno de 20.



Média = 20

A mesma média 23 agora é rara


$$\mu = 20 \quad \sigma = 4 \quad n = 16 \quad EP = 1$$

$$z = (23 - 20) / 1 = 3$$

0,13%

das amostras teriam
média igual ou superior a 23.

EP = 1 (escala ampliada: 16 a 24)



Média amostral

Centro = 20 Região verde: média ≥ 23

Aproximadamente 1 em 1.000 repetições.

A distância depende do erro-padrão

	Mais dispersa	Menos dispersa
Média populacional	20	20
Desvio-padrão populacional	48	4
Observações por amostra	16	16
Erro-padrão	12	1
Média amostral avaliada	23	23
Escore z	0,25	3
Probabilidade de média ≥ 23	40,13%	0,13%

Medimos a distância à média populacional em erros-padrão.

Se aumentarmos n , o que acontece com essa distância?

Olhando para a frente

- A estatística inferencial envolve a avaliação dessas probabilidades
 - Decidir quando uma amostra é “surpreendente” e quando não é
- Quando uma amostra é realmente “surpreendente” nós mudamos nossas crenças
- Exemplo:
 - Se nós though os pontos de vista americanos sobre a imigração tinham permanecido inalterados....
 - ...Mas a média da ANES 2016 foi muito “surpreendente” dada nas últimas décadas de pesquisa...
 - ...Concluimos que as opiniões dos americanos tinham mudado