Correlação

r de Pearson, inferência e correlação parcial

Robert Vidigal

MQAPP / UnB • 2026.2

Comparação de médias

Até esse ponto da disciplina, as perguntas eram deste tipo:

- **Teste t ou Z de uma amostra:** a média de uma população difere de um valor de referência? Por exemplo: a média de uma turma difere de 7?

Comparação de médias

Até esse ponto da disciplina, as perguntas eram deste tipo:

- **Teste t ou Z de uma amostra:** a média de uma população difere de um valor de referência? Por exemplo: a média de uma turma difere de 7?

- **Teste t de amostras independentes:** as médias de dois grupos diferem? Por exemplo: estudantes do turno diurno e do noturno têm médias diferentes?

Da comparação de médias à associação entre variáveis

Na correlação, a pergunta muda. Em uma amostra de estudantes, podemos registrar **duas medidas para cada pessoa.**

Da comparação de médias à associação entre variáveis

Na correlação, a pergunta muda. Em uma amostra de estudantes, podemos registrar **duas medidas para cada pessoa.**

Agora, vamos investigar outra pergunta:

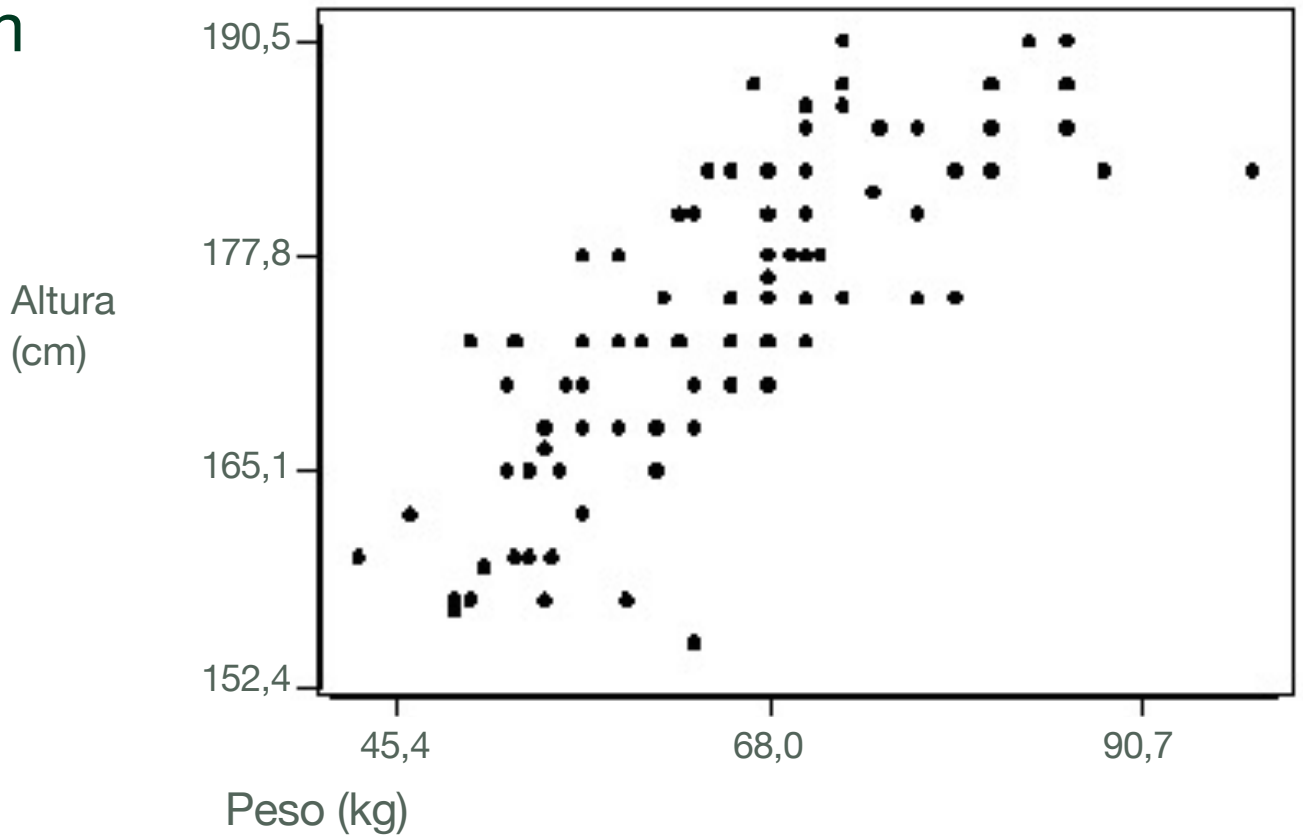
quando uma variável aumenta, a outra tende a aumentar, diminuir ou não apresentar um padrão linear?

Exemplo: qual é a relação entre horas de estudo e nota?

Correlação

As correlações representam a relação sistemática entre duas variáveis.

Altura e peso de adultos



Correlação

- Duas propriedades principais de uma correlação:
  - Direção
    - A natureza da relação entre as variáveis

Positivo

as variáveis vão na mesma direção



Negativo

as variáveis vão direções opostas

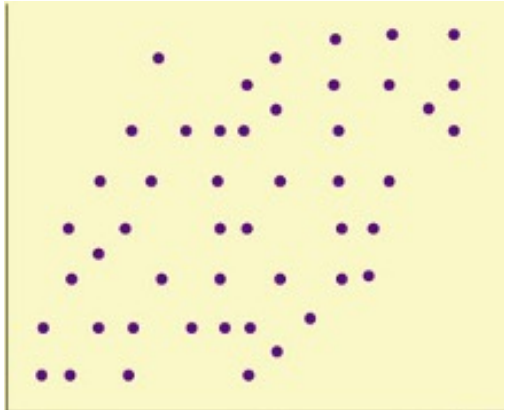


Força da correlação

A força indica a consistência da relação entre as variáveis.

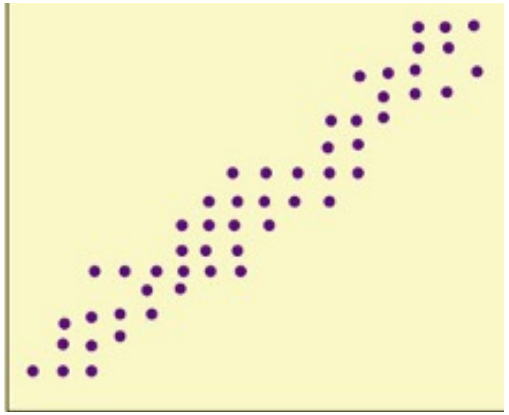
Associação fraca

As observações ficam mais dispersas.
A relação é menos consistente.



Associação forte

Valores extremos de X tendem a acompanhar valores extremos de Y.



Correlação

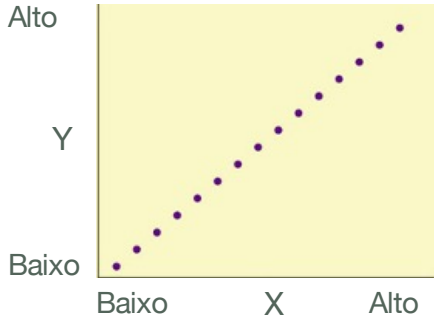
- Essas relações são quantificadas por um coeficiente de correlação
  - Vamos usar o coeficiente de correlação de Pearson: r
    - *r pode ter qualquer valor de -1,00 a +1,00*
    - O sinal de r (- / +) indica a direção da relação
    - O valor absoluto (magnitude) de r indica a força da relação

Pequeno	.10
Médio	.30
Grande	.50

Diagramas de dispersão

As correlações podem ser visualizadas usando um gráfico de dispersão.

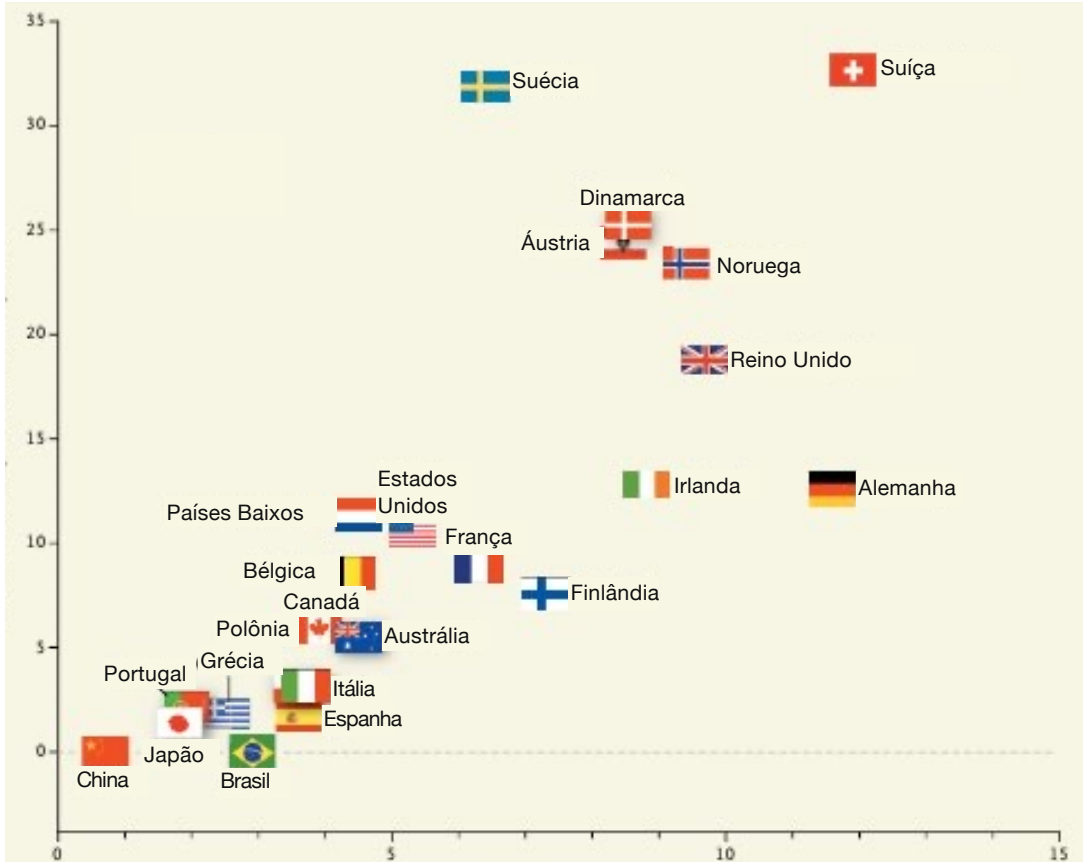
Positiva perfeita



Correlação não implica causalidade

Consumo de chocolate e prêmios Nobel

Relação entre o consumo anual por habitante e o número de laureados com o Nobel por país.

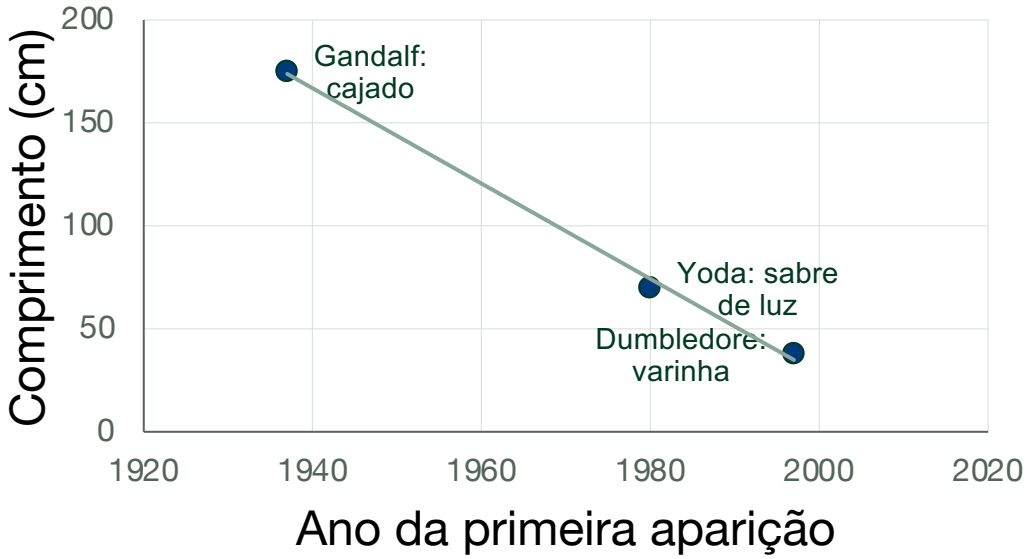


Consumo de chocolate (kg por habitante/ano)

Correlações na literatura e no cinema

Cada ponto é um personagem. O ano é da obra; a idade pertence à história.

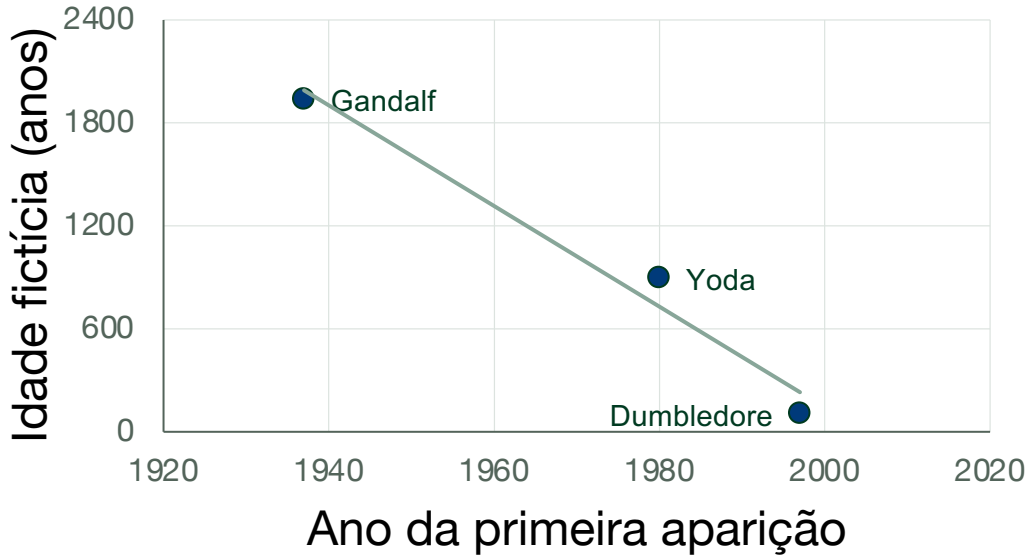
Comprimento do objeto



r = –0,9985

y = 4656,434 – 2,314x

Idade fictícia do personagem



r = –0,9863

y = 58789,986 – 29,324x

À direita, os personagens de aparição mais recente têm idades fictícias menores.

Correlação

- Limitações
  - Direção causal
    - Ambos os sentidos de causalidade são possíveis



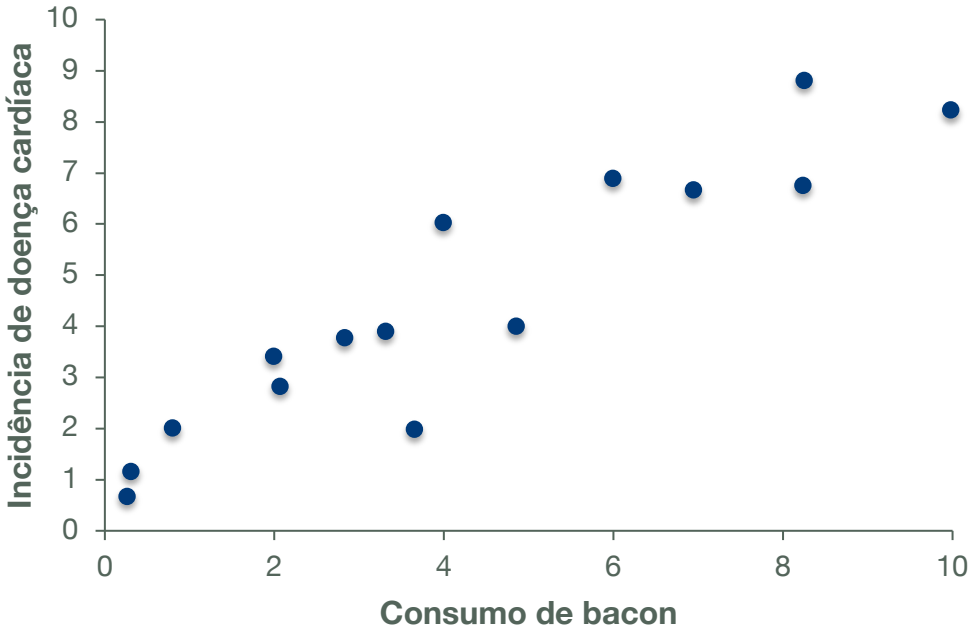
Correlação

- Limitações
  - Terceira variável
    - Algumas outras variáveis estão relacionadas tanto com nossas variáveis quanto com sua relação (ilusória)



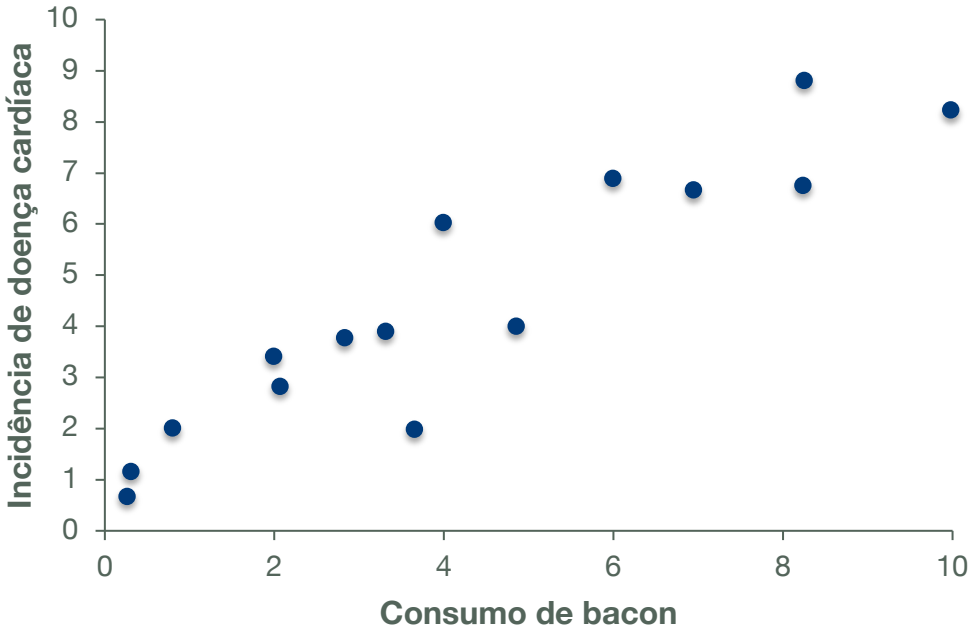
Correlação

- Que tipo de correlação seria esperada entre o consumo de bacon e a incidência de doenças cardíacas?



Correlação

- Que tipo de correlação seria esperada entre o consumo de bacon e a incidência de doenças cardíacas?

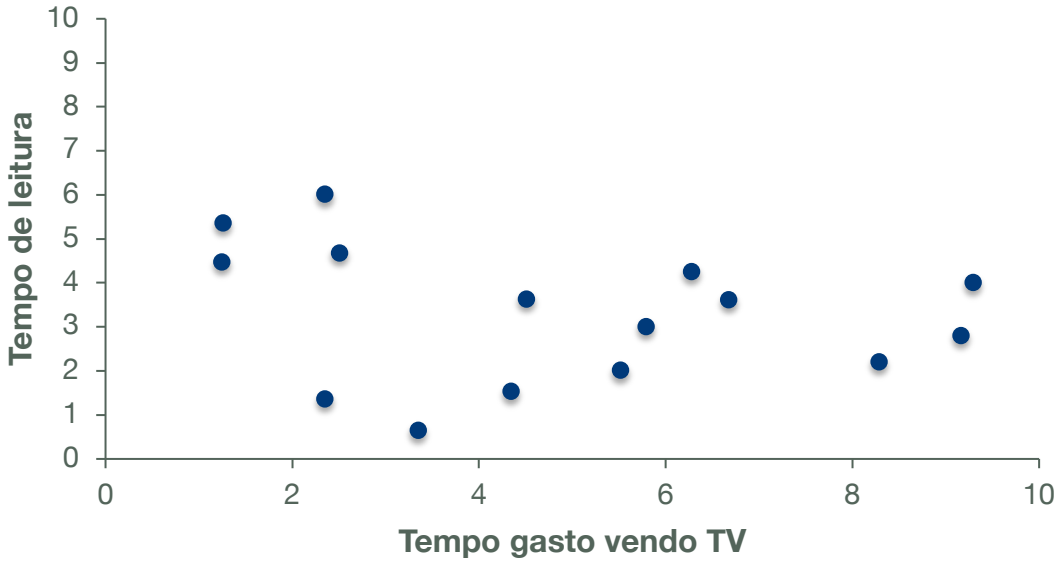


Grande positivo

***r* = .93**

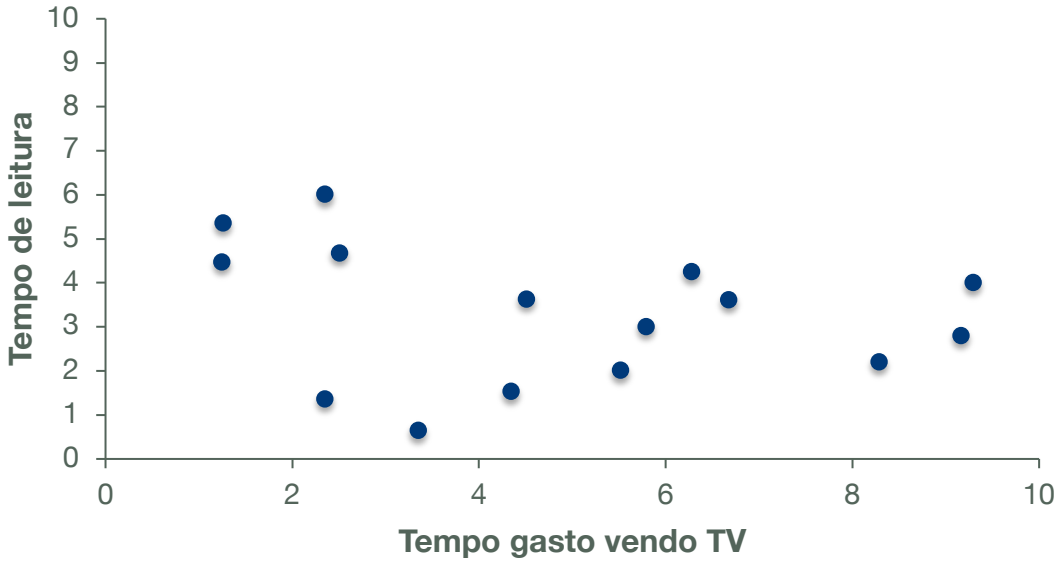
Correlação

- Que tipo de correlação seria esperada entre a quantidade de tempo de lazer gasto lendo e a quantidade de tempo assistindo TV?



Correlação

- Que tipo de correlação seria esperada entre a quantidade de tempo de lazer gasto lendo e a quantidade de tempo assistindo TV?

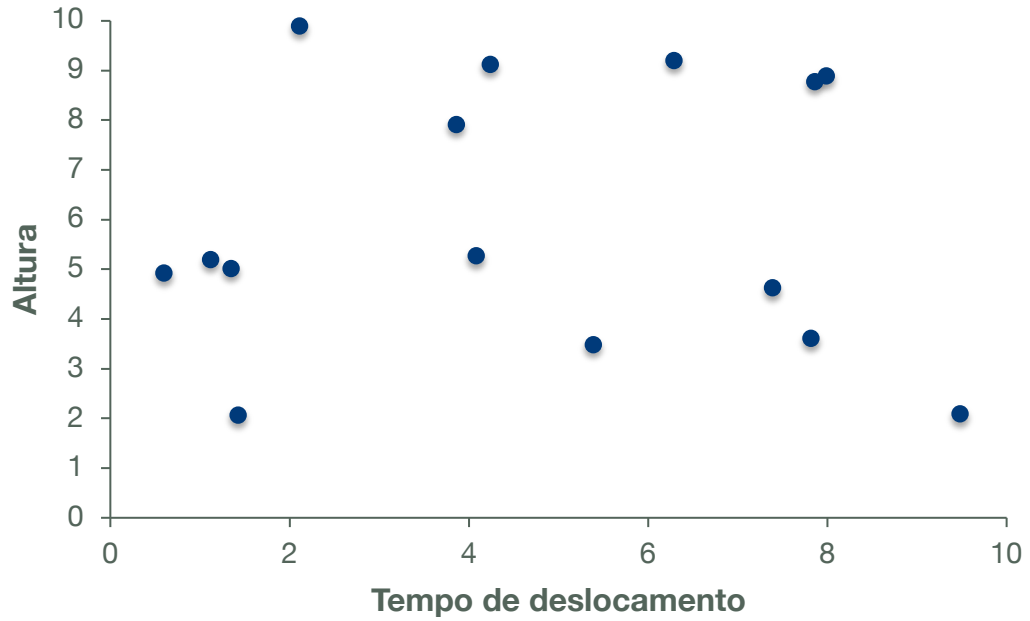


Pequeno negativo

***r* = -.24**

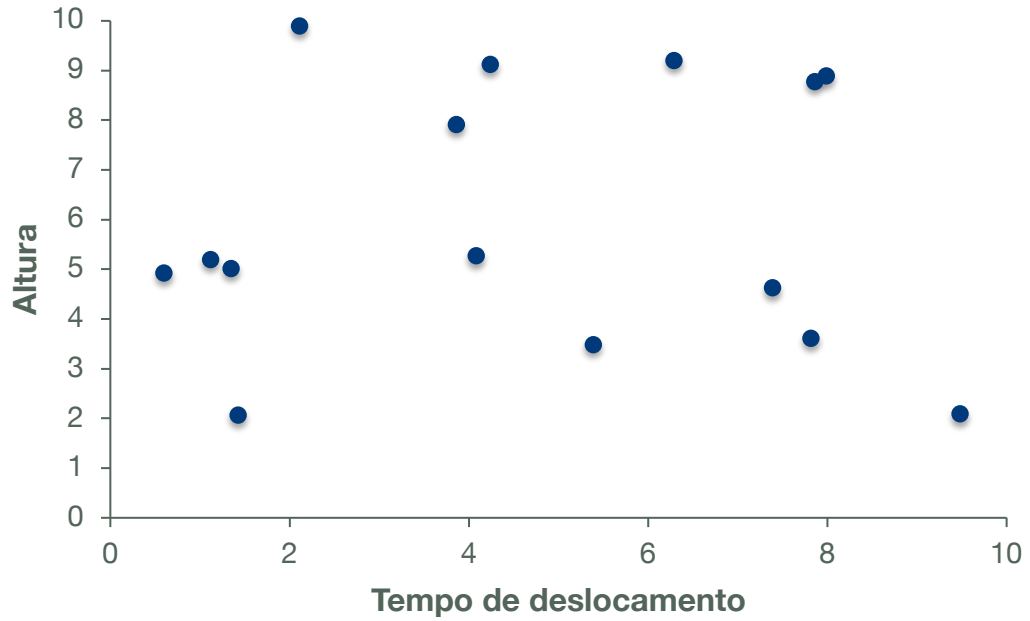
Correlação

- Que tipo de correlação seria esperada entre a altura de uma pessoa e a duração de seu trajeto diário?



Correlação

- Que tipo de correlação seria esperada entre a altura de uma pessoa e a duração de seu trajeto diário?



Nenhuma correlação

***r* = .02**

Antes do teste de Pearson

Começamos pelo desenho da pesquisa e pelo diagrama de dispersão.

Cada pessoa fornece um par (X, Y). As observações de pessoas diferentes devem ser independentes.

No gráfico, procuramos um padrão aproximadamente linear e verificamos dispersão e pontos extremos.

Espera e satisfação no serviço público

Um serviço público quer investigar se o tempo de espera está associado à satisfação com o atendimento.

Cada pessoa fornece duas medidas:
X: espera em minutos.
Y: satisfação de 0 a 10.

10 pessoas, duas medidas por pessoa

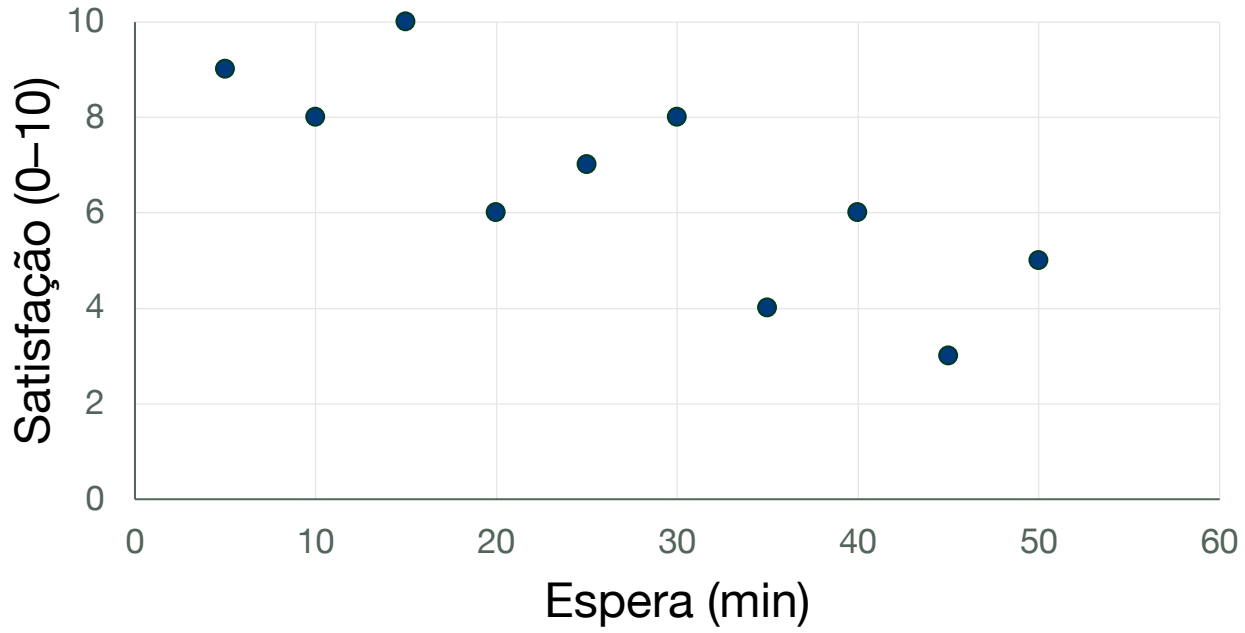
Pessoa	Espera X (min)	Satisfação Y (0–10)
1	5	9
2	10	8
3	15	10
4	20	6
5	25	7
6	30	8
7	35	4
8	40	6
9	45	3
10	50	5

Satisfação: 0 = pior avaliação; 10 = melhor avaliação.

Dados simulados para fins didáticos

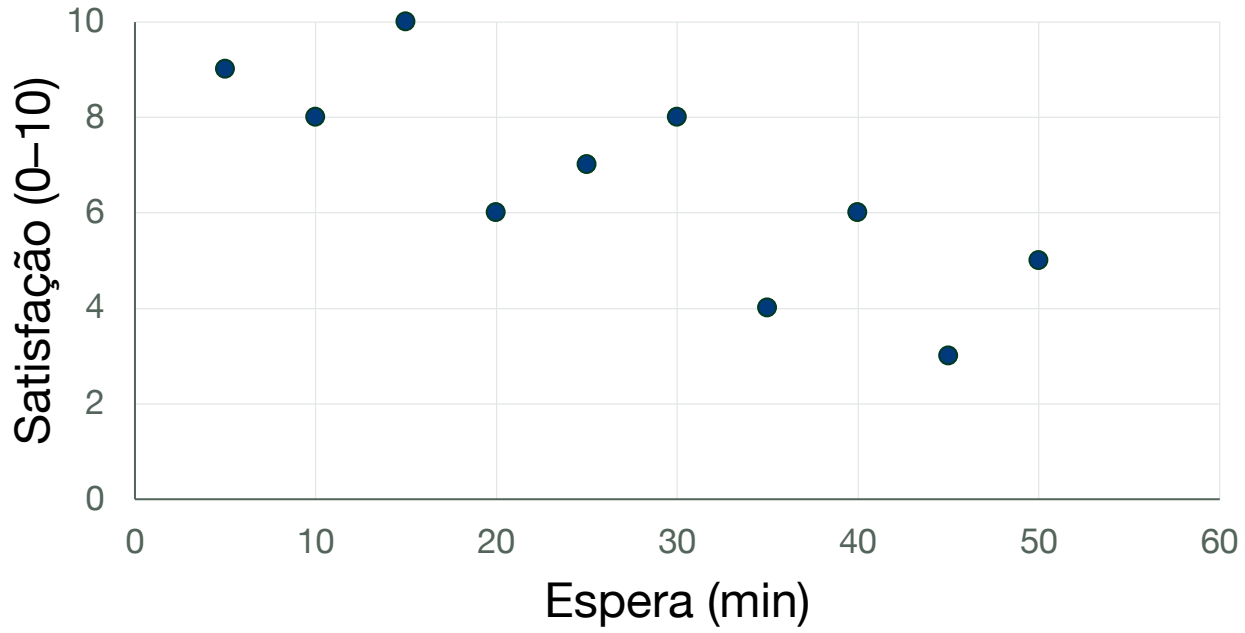
Tempo de espera e satisfação

Cada ponto representa uma pessoa, com duas medidas: espera e satisfação.



Tempo de espera e satisfação

Cada ponto representa uma pessoa, com duas medidas: espera e satisfação.



O gráfico sugere uma associação negativa.

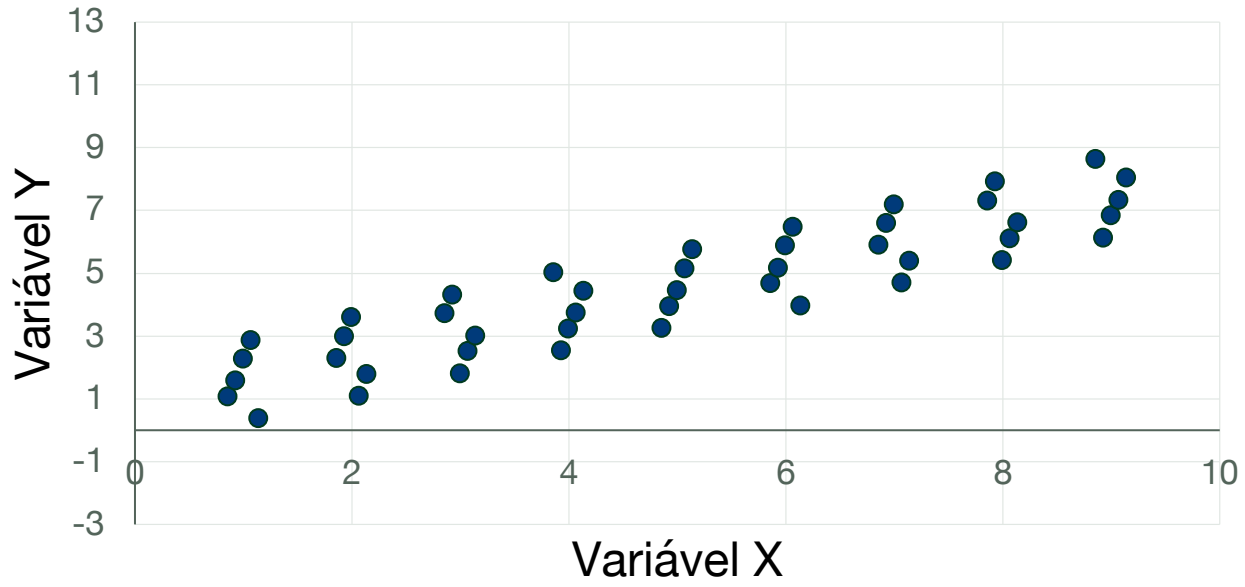
Essa tendência na amostra é evidência de associação na população?

Agora vamos verificar os dados e aprender a testar essa hipótese.

Dados simulados para fins didáticos

Dispersão semelhante ao longo de X

A faixa vertical dos pontos mantém uma espessura parecida ao longo do eixo X.



X e Y podem ter unidades e variâncias diferentes.

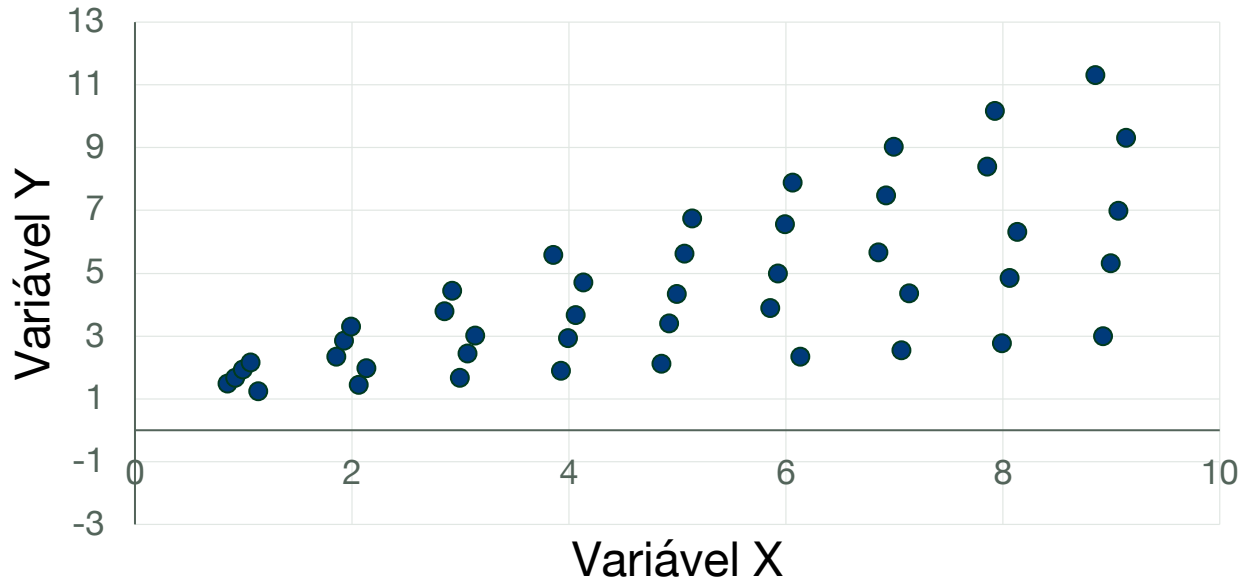
O que observar

Compare a distância dos pontos em relação à tendência, ao longo do eixo X.

Esse padrão é chamado homoscedasticidade.

Dispersão que muda ao longo de X

Neste exemplo, a faixa de pontos se alarga à medida que X aumenta.



O que observar

Para X baixo, os pontos ficam próximos da tendência. Para X alto, ficam mais espalhados.

Esse formato de funil indica heteroscedasticidade.

Podemos calcular r, mas esse padrão exige cautela com a inferência usual.

Na próxima aula

Hoje foi: direção, força e limites da correlação

Como ler diagramas de dispersão e interpretar o sinal e a magnitude de r.

Para revisar para próxima aula

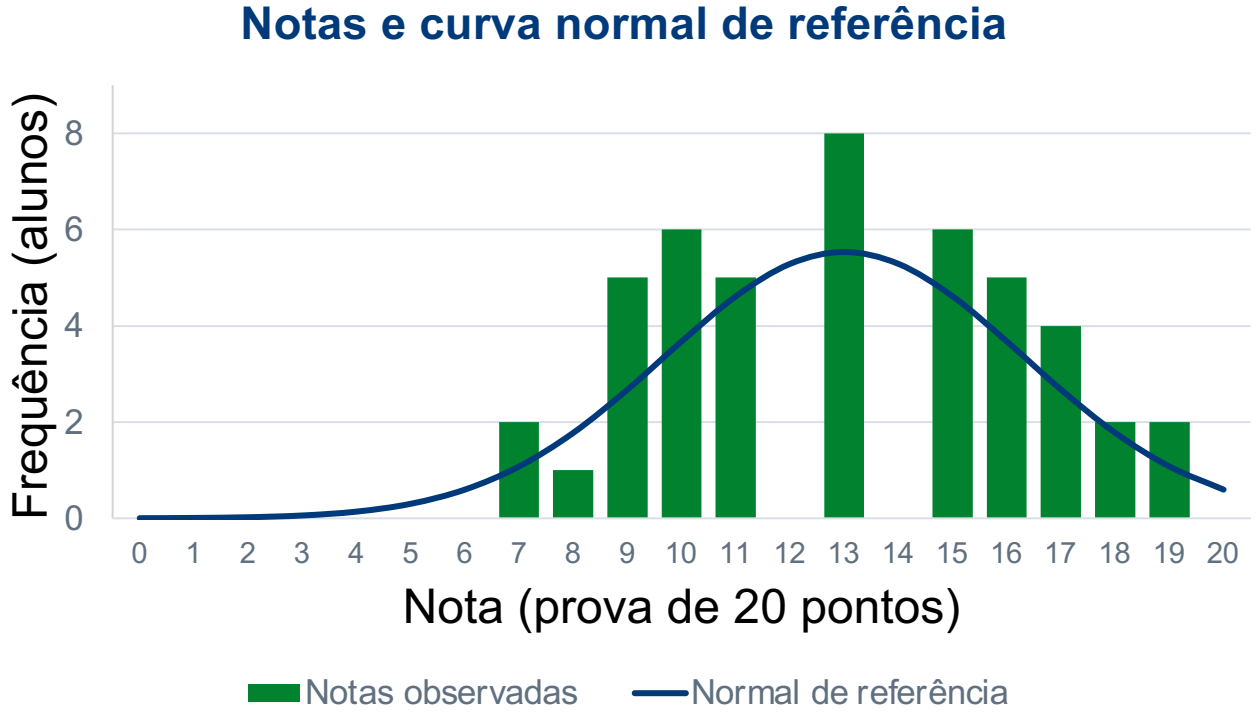
Uma correlação negativa significa uma associação fraca? Por que uma correlação forte não demonstra causalidade?

Na próxima aula: cuidados com os dados e teste da correlação de Pearson

Prova 3: estatísticas descritivas

46 notas acima de zero. Prova de 20 pontos. Sete zeros excluídos.

Estatística	Resultado
Média	**13,00 (65,0%)**
Mediana	**13,00**
Moda	**13,00**
Desvio-padrão	**3,32**
Variância	**11,00**
Mínimo / Máximo	**7 / 19**
Notas ≥ 10	**38 (82,6%)**

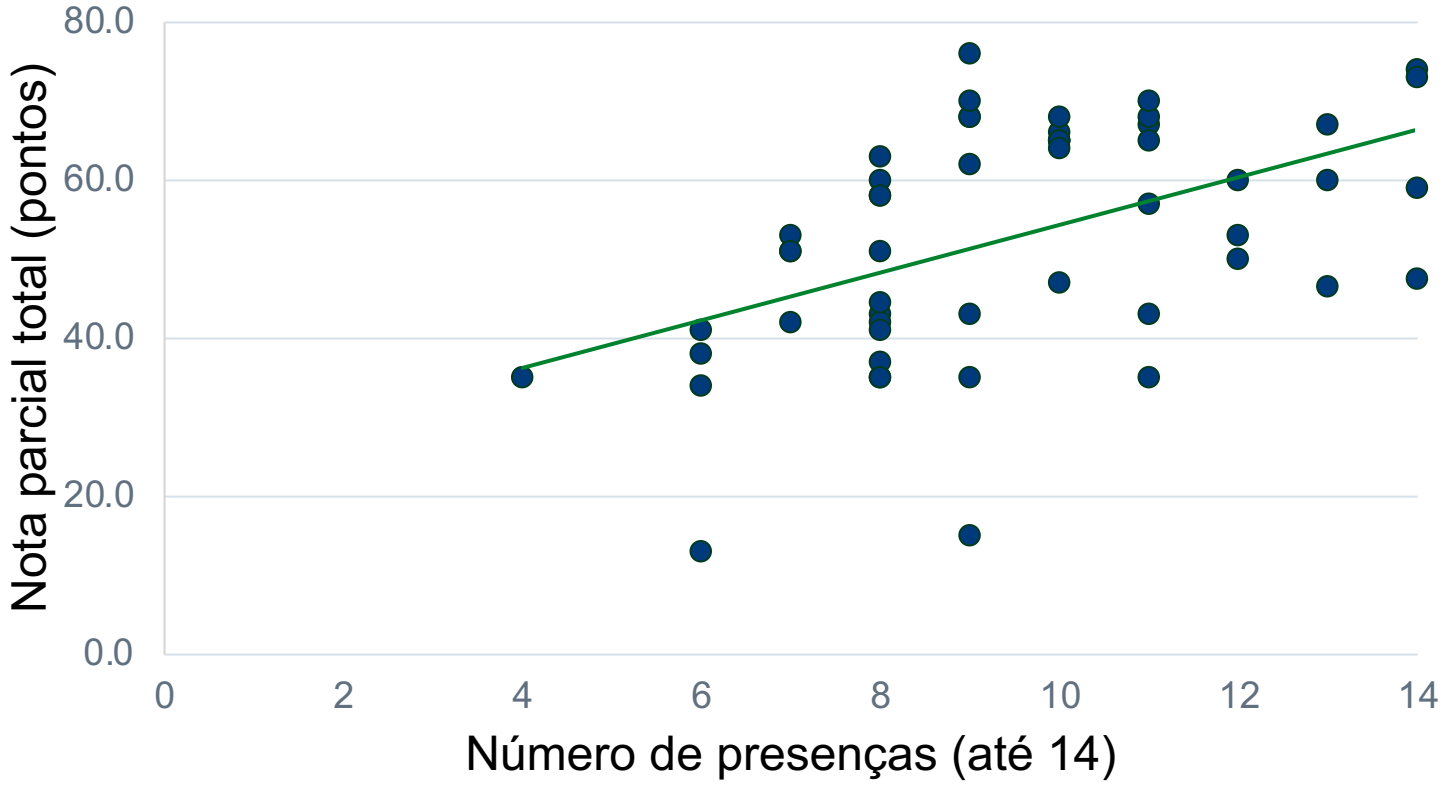


A curva normal permite comparar o formato esperado com as notas.

A semelhança visual com a curva não confirma normalidade.

Presenças e nota parcial total

53 alunos com notas e presenças correspondentes por matrícula. Chamada parcial de 14 aulas.



Correlação de Pearson

r = 0,486

Associação positiva moderada

Alunos com mais presenças tendem a ter notas parciais mais altas.

Spearman: ρ = 0,515

A correlação descreve uma associação e não estabelece causalidade.

Total conforme registrado, com um valor de 76 acima do máximo indicado de 75.

Correlação e causalidade



Retomada: como interpretar r de Pearson

O sinal indica a direção

$r > 0$: valores maiores de X tendem a acompanhar valores maiores de Y.

$r < 0$: valores maiores de X tendem a acompanhar valores menores de Y.

A magnitude indica a força

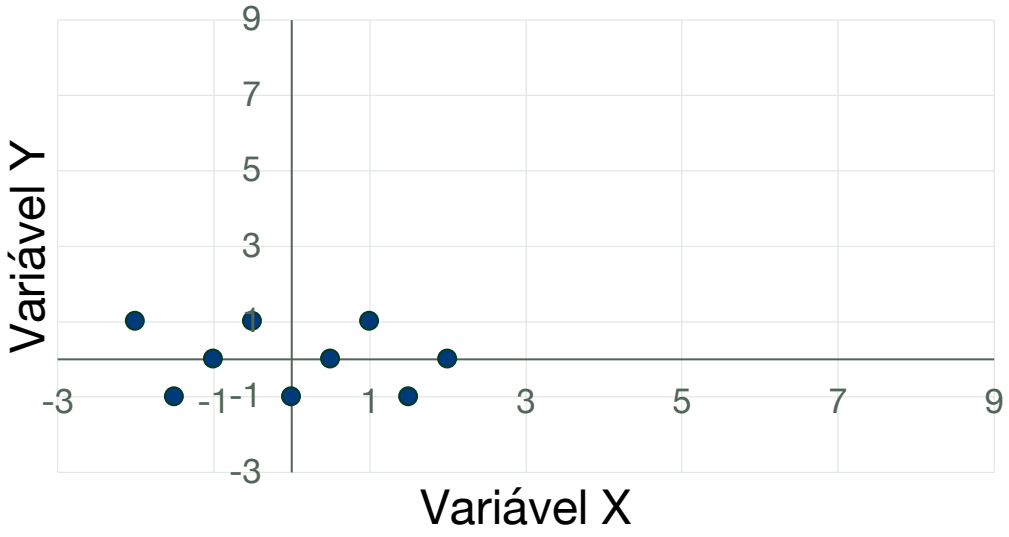
r = –0,80 é uma associação linear mais forte que r = +0,30.

r próximo de zero indica pouca associação linear. Ainda pode haver um padrão curvo.

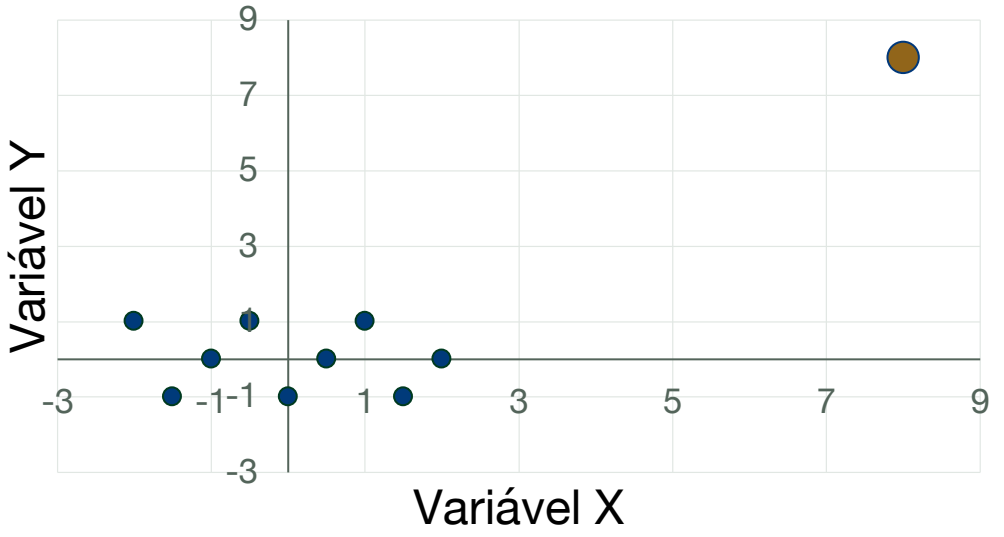
Correlação, por si só, não demonstra causa e efeito.

Um único ponto pode mudar r

Sem o ponto extremo: r = –0,16



Com o ponto extremo: r = 0,83

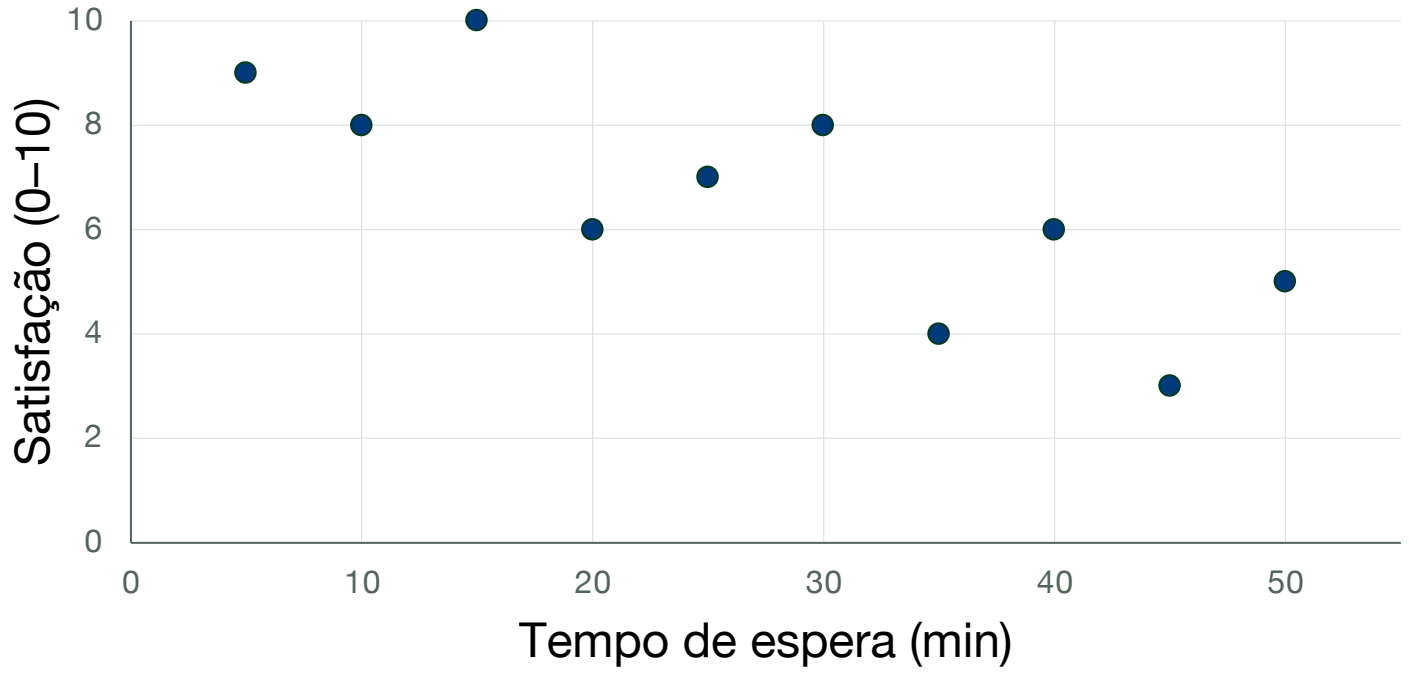


Os nove pontos originais são os mesmos nos dois gráficos.

Investigue o ponto extremo. Compare os resultados antes de decidir como tratá-lo.

Espera e satisfação: gráfico de dispersão

Como a satisfação varia entre pessoas que esperaram tempos diferentes?



Cada ponto representa uma pessoa.

O gráfico sugere uma associação negativa: esperas maiores tendem a acompanhar notas menores.

Dados simulados para fins didáticos

Passos do teste de hipóteses

1. Selecione o teste apropriado para seus dados
2. Declarar as hipóteses nulas e de pesquisa
3. Descreva a distribuição da hipótese nula.
4. Determinar os valores críticos.
5. Calcular a estatística do teste.
6. Tome uma decisão.

Passos do teste de hipóteses

2. Declarar as hipóteses nulas e de pesquisa

- Descreva as duas possibilidades mutuamente exclusivas em palavras e simbolicamente
  - Hipóteses sobre a relação entre duas variáveis em toda a população
    - Coeficientes de correlação = quantidade de variância em uma variável prevista por variância na outra variável

$$r = \frac{\text{Quantidade da variância comum}}{\text{Quantidade da variância total}}$$

Espera e satisfação: hipóteses

Vamos testar a correlação populacional entre tempo de espera e satisfação.

Hipótese nula

$$H_0: \rho = 0$$

Não há associação linear entre as duas variáveis na população.

Hipótese alternativa

$$H_1: \rho \neq 0$$

Há associação linear entre as duas variáveis na população.

Teste bilateral, $\alpha = 0{,}05$. Esperamos sinal negativo, mas o teste considera as duas direções.

Dados simulados para fins didáticos

Passos do teste de hipóteses

3. Descreva a distribuição da hipótese nula.

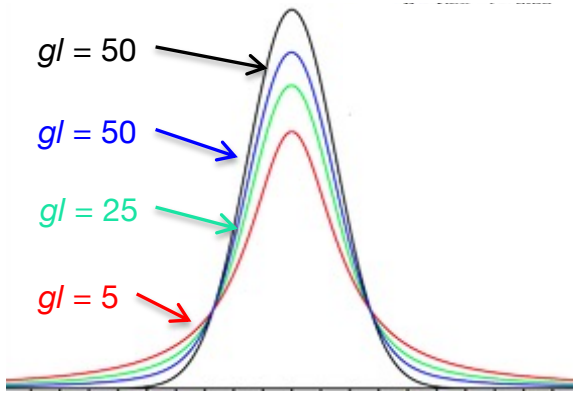
- Não é um passo único para as correlações...
- ... Então vamos apenas usar este passo para ter certeza de que sabemos o nosso gl

Passos do teste de hipóteses

3. Descreva a distribuição da hipótese nula.

- Nos bastidores, os r's são testados com t's, assim como uma família de distribuições com base em gl

maior gl = distribuição mais estreita



- Porque nós estaremos calculando variância para cada variável, nós perdemos dois graus de liberdade
  - $gl = n - 2$

Espera e satisfação: graus de liberdade

Temos n = 10 pares de medidas. Cada pessoa contribui com um valor de espera e um de satisfação.

Para o teste de Pearson, os graus de liberdade são n – 2.

gl = n – 2

gl = 10 – 2 = 8

Usamos gl = 8 para consultar a tabela de r crítico.

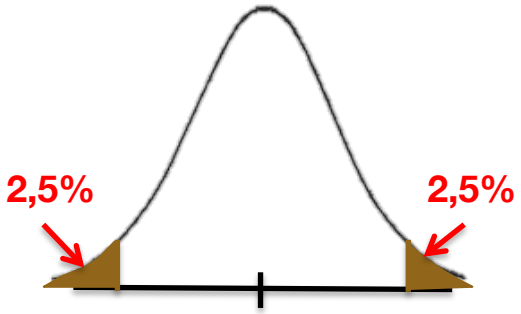
Dados simulados para fins didáticos

Passos do teste de hipóteses

4. Determinar os valores críticos.

Hipóteses não direcionais

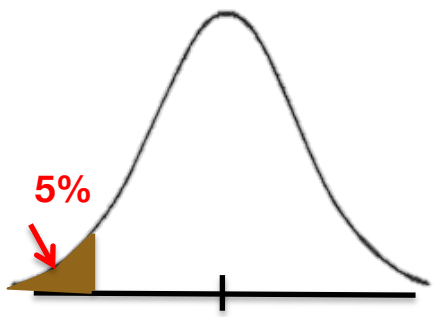
$H_1: \mu_1 \neq \mu_2$



t crítico: 2,5% por cauda?

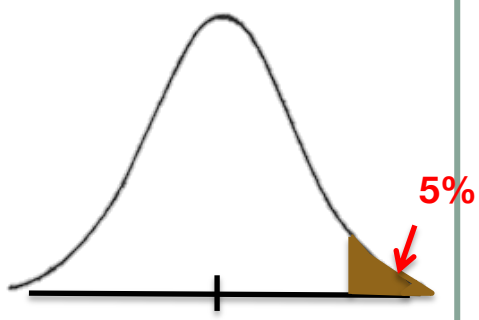
Hipóteses direcionais

$H_1: \mu_1 < \mu_2$



t crítico para 5% à esquerda?

$H_1: \mu_1 > \mu_2$



t crítico para 5% à direita?

Valores críticos da correlação

4. Determinar os valores críticos

Consultar o Quadro.

Se o número de graus de liberdade não estiver na tabela, usar o menor valor disponível.

gl = n – 2

Em cada coluna: α unilateral / α bilateral

gl	0,05 / 0,10	0,025 / 0,05	0,01 / 0,02	0,005 / 0,01
1	0,988	0,997	0,9995	0,9999
2	0,900	0,950	0,980	0,990
3	0,805	0,878	0,934	0,959
4	0,729	0,811	0,882	0,917
5	0,669	0,754	0,833	0,874
6	0,622	0,707	0,789	0,834
7	0,582	0,666	0,750	0,798
8	0,549	0,632	0,716	0,765
9	0,521	0,602	0,685	0,735
10	0,497	0,576	0,658	0,708
11	0,476	0,553	0,634	0,684
12	0,458	0,532	0,612	0,661
13	0,441	0,514	0,592	0,641
14	0,426	0,497	0,574	0,623
15	0,412	0,482	0,558	0,606

Espera e satisfação: valores críticos

Com 10 pessoas, temos gl = 8. Para α = 0,05 bilateral, consultamos a coluna correspondente.

Colunas: α unilateral / α bilateral

gl	0,05 / 0,10	0,025 / 0,05	0,01 / 0,02	0,005 / 0,01
1	0,988	0,997	0,9995	0,9999
2	0,900	0,950	0,980	0,990
3	0,805	0,878	0,934	0,959
4	0,729	0,811	0,882	0,917
5	0,669	0,754	0,833	0,874
6	0,622	0,707	0,789	0,834
7	0,582	0,666	0,750	0,798
8	**0,549**	**0,632**	**0,716**	**0,765**
9	0,521	0,602	0,685	0,735
10	0,497	0,576	0,658	0,708

Dados simulados para fins didáticos

gl = 8

α = 0,05 bilateral

r crítico = ±0,632

Rejeitamos H_0 se:
r < –0,632 ou r > 0,632.

Passos do teste de hipóteses

5. Calcular a estatística do teste.

$$r = \frac{\text{Quantidade da variância comum}}{\text{Quantidade da variância total}}$$

- Variância comum: O que é “compartilhado” entre as duas variáveis
  - O que os faz "ir juntos" (se eles fazem)
- Variância total: Toda a variância em nossas variáveis

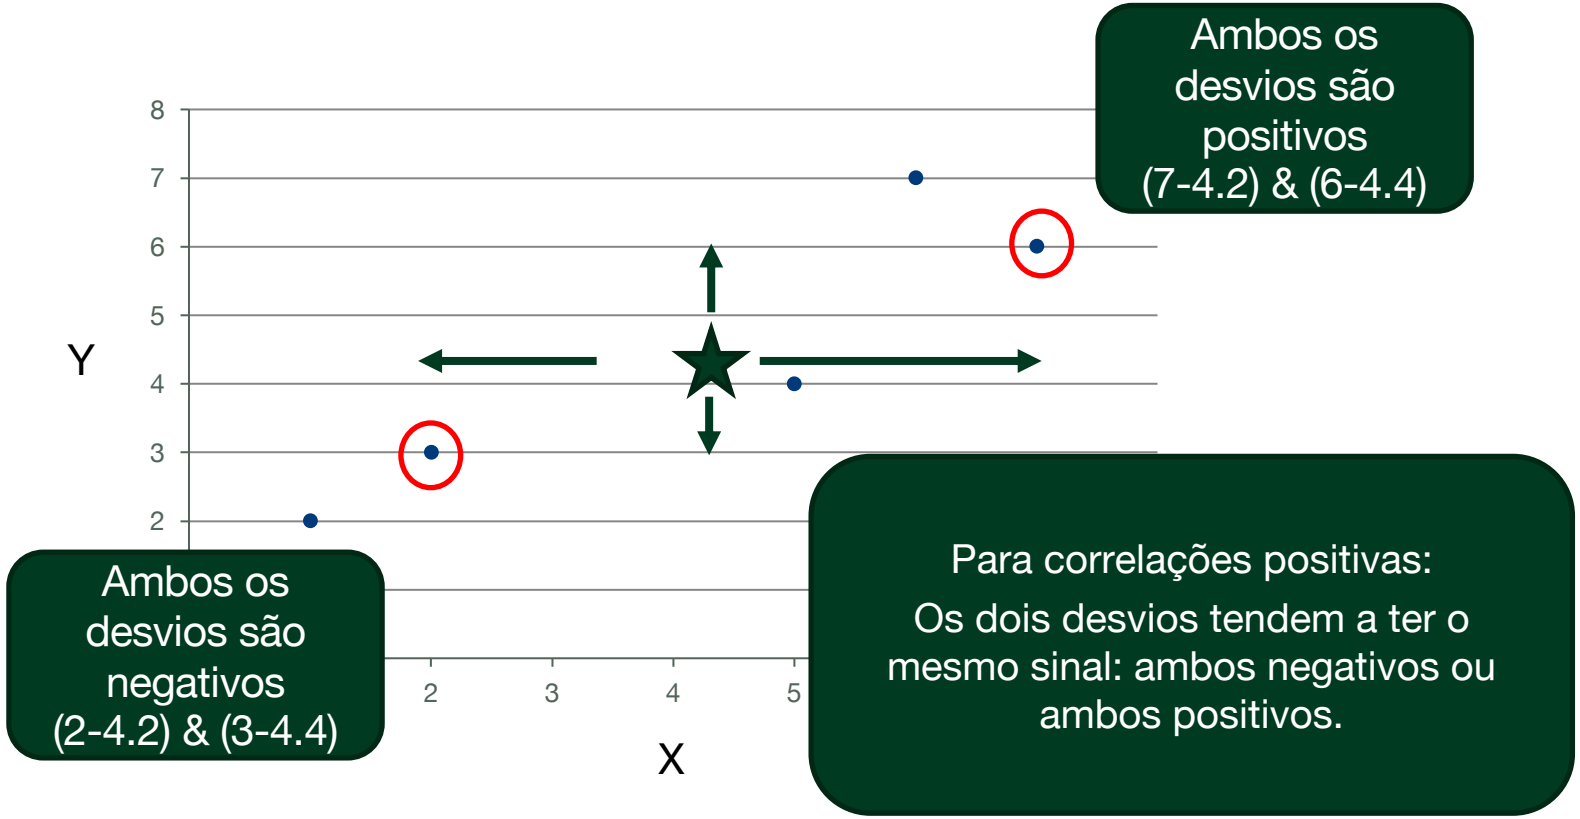
Calculando r

- O nosso velho amigo, o desvio!
  - X – M
- Mas agora temos dois desvios por pontuação bruta
  - X – MX
  - Y – MY

Pessoa	X	Y
A	1	2
B	2	3
C	5	4
D	6	7
E	7	6
	M = 4.2	M = 4.4

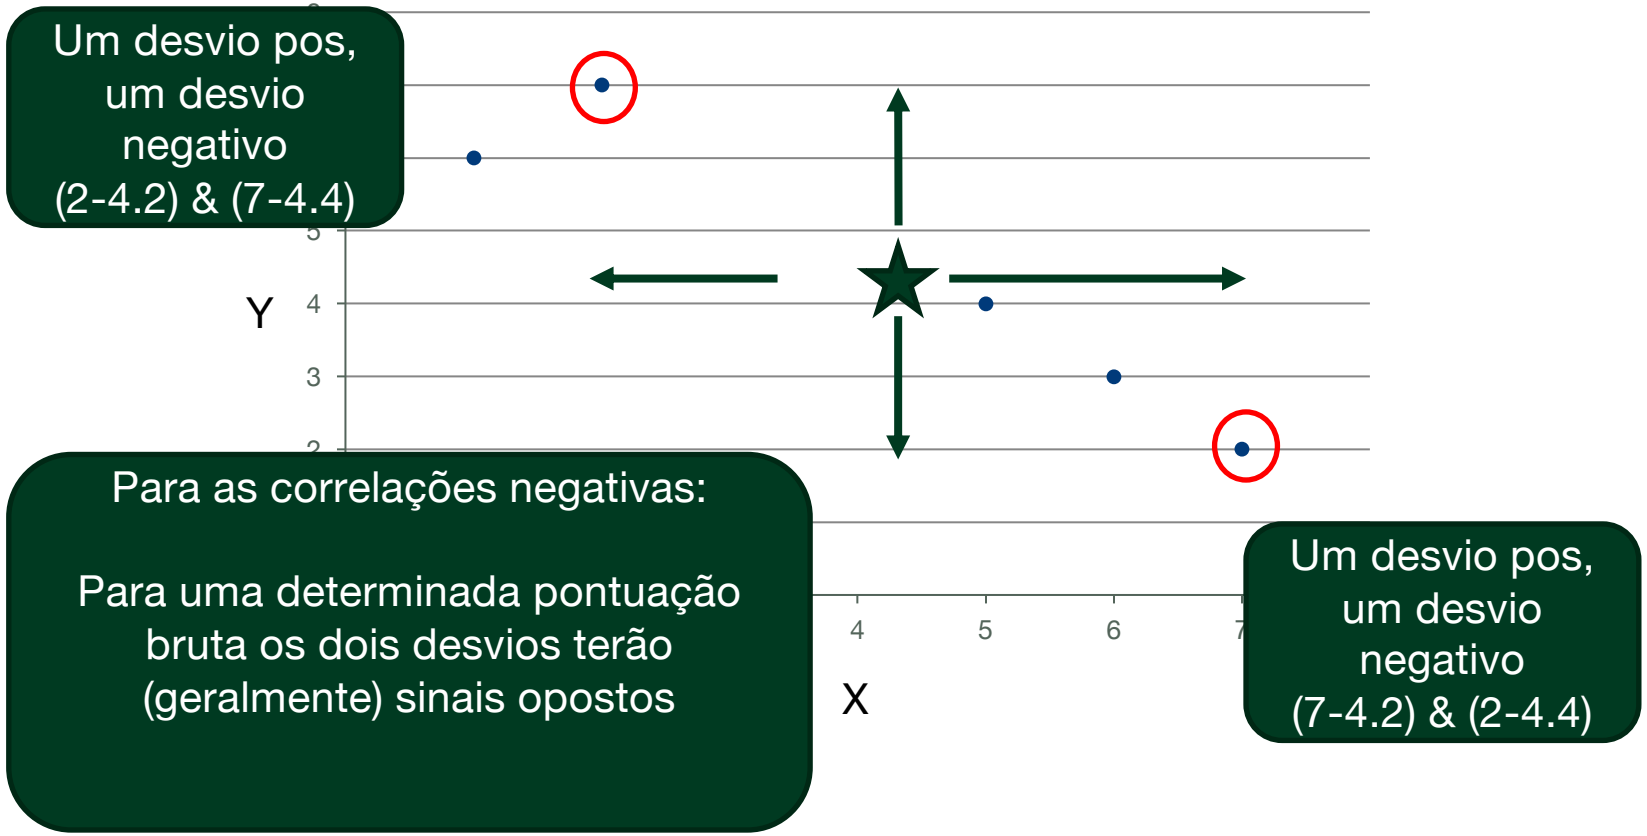
Calculando r

- Visualizando desvios conjuntos em correlação positiva



Calculando r

- Visualizando desvios conjuntos em correlação negativa



Calculando r

- Numerador de r é a soma de produtos – SP

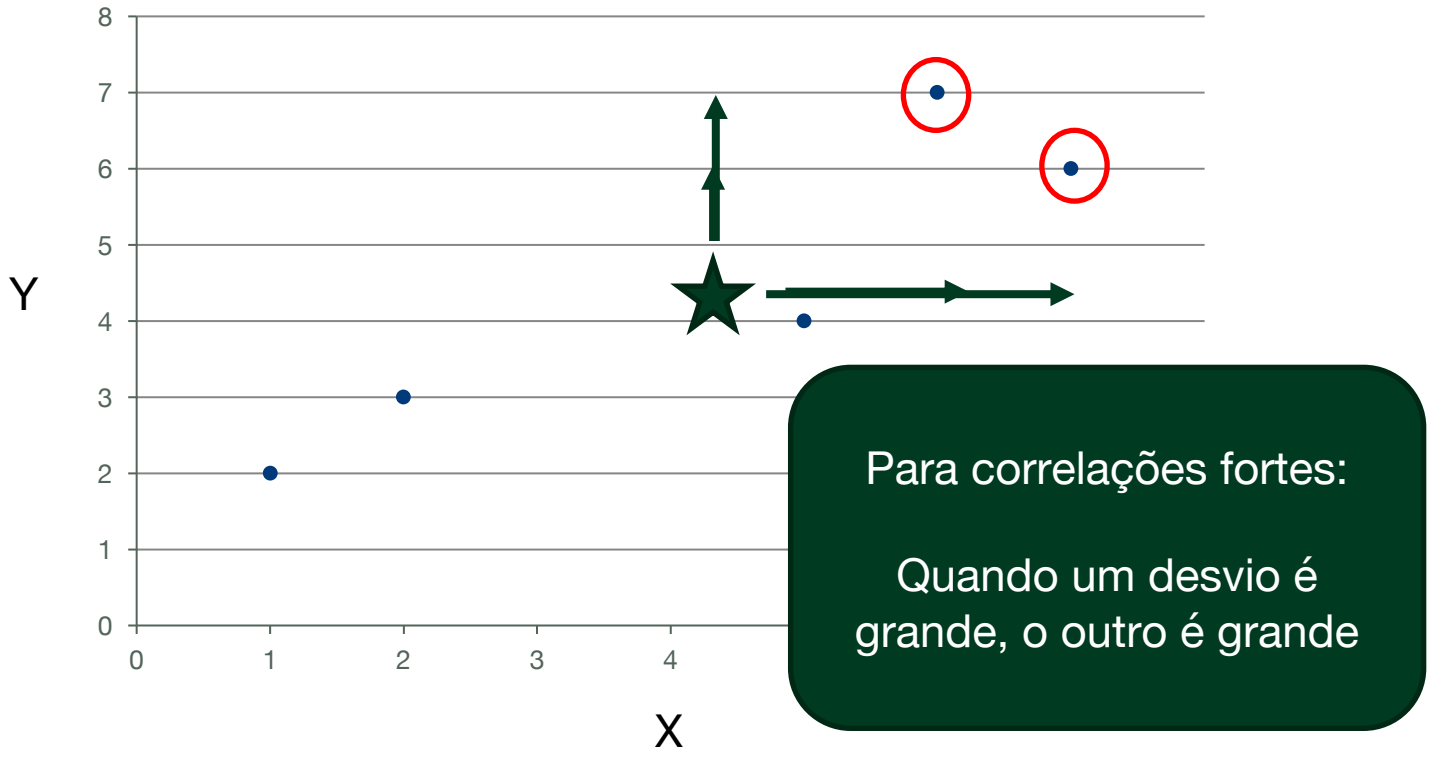
$$SP = \Sigma[(X - M_x)(Y - M_Y)]$$

- Criado multiplicando os dois desvios e depois somando
- As correlações positivas terão produtos positivos
  - + vezes + é +
  - - vezes - é +
- Correlações negativas terão produtos negativos
  - + vezes - é -

$$r = \frac{\text{Quantidade da variância comum}}{\text{Quantidade da variância total}}$$

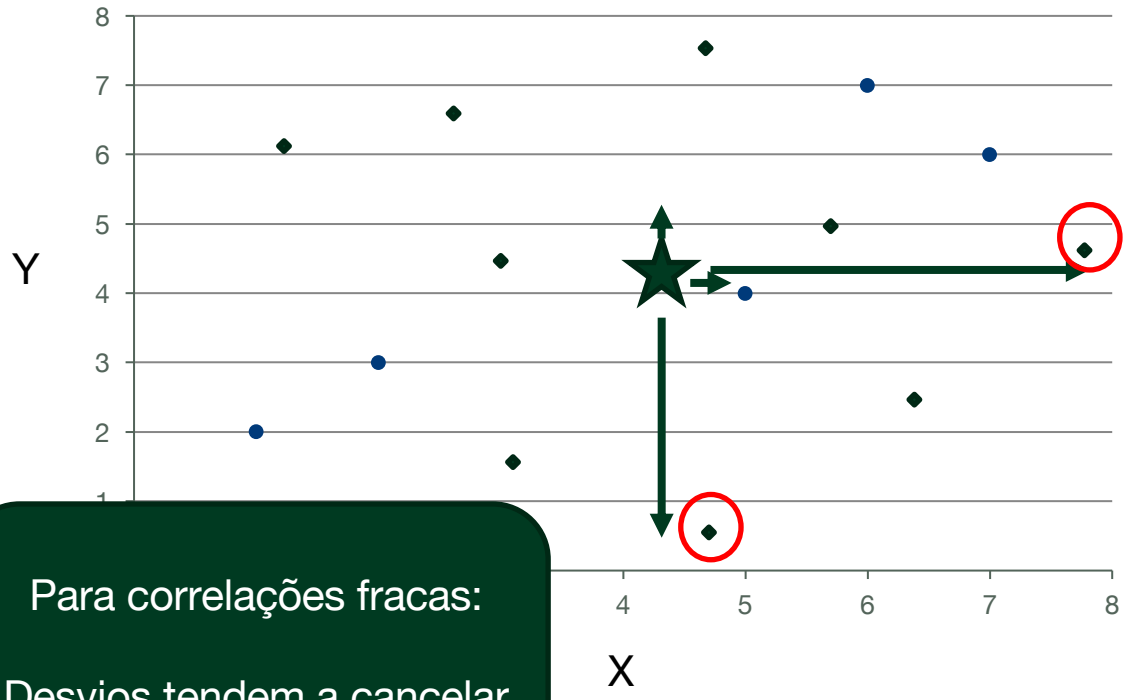
Calculando r

- Os produtos também refletem a força da correlação



Calculando r

- Os produtos também refletem a força da correlação



Para correlações fracas:

Desvios tendem a cancelar uns aos outros

Calculando r

- Agora precisamos comparar isso com a variabilidade global (esperada)
  - Começamos com SQ para cada variável
  - Então nós tomamos a raiz quadrada do produto
  - Esta medida da variabilidade global é o nosso denominador:

$$\sqrt{(SQ_x \times SQ_Y)}$$

$$r = \frac{\text{Quantidade da variância comum}}{\text{Quantidade da variância total}}$$

Calculando r

- Portanto, o coeficiente de correlação é apenas a forma padronizada de SP
  - Padronizado de modo que varia de -1 a 1

$$r = SP / \sqrt{(SQ_x \times SQ_y)}$$
$$r = \Sigma[(X - M_x)(Y - M_y)] / \sqrt{(SQ_x \times SQ_y)}$$

$$r = \frac{\text{Quantidade da variância comum}}{\text{Quantidade da variância total}}$$

Espera e satisfação: soma dos produtos

O numerador de r é SP, a soma dos produtos dos desvios.

X (min)	Y (0–10)	$X - M_x$	$Y - M_y$	Produto
5	9	–22,5	2,4	–54,0
10	8	–17,5	1,4	–24,5
15	10	–12,5	3,4	–42,5
20	6	–7,5	–0,6	4,5
25	7	–2,5	0,4	–1,0
30	8	2,5	1,4	3,5
35	4	7,5	–2,6	–19,5
40	6	12,5	–0,6	–7,5
45	3	17,5	–3,6	–63,0
50	5	22,5	–1,6	–36,0

Dados simulados para fins didáticos

M_x = 27,5 min
M_y = 6,6 pontos

SP = –240

Somamos os produtos dos desvios das 10 pessoas.

Espera e satisfação: somas de quadrados

Elevamos cada desvio ao quadrado e somamos separadamente para X e Y.

X	Y	$X - M_x$	$Y - M_y$	$(X - M_x)^2$	$(Y - M_y)^2$
5	9	–22,5	2,4	506,25	5,76
10	8	–17,5	1,4	306,25	1,96
15	10	–12,5	3,4	156,25	11,56
20	6	–7,5	–0,6	56,25	0,36
25	7	–2,5	0,4	6,25	0,16
30	8	2,5	1,4	6,25	1,96
35	4	7,5	–2,6	56,25	6,76
40	6	12,5	–0,6	156,25	0,36
45	3	17,5	–3,6	306,25	12,96
50	5	22,5	–1,6	506,25	2,56

$M_x = 27,5$
$M_y = 6,6$

$SQ_x = 2.062,5$

$SQ_y = 44,4$

$\sqrt{(SQ_x \times SQ_y)} \approx 302,61$

Dados simulados para fins didáticos

Espera e satisfação: cálculo de r

Dividimos SP pela raiz quadrada do produto das duas somas de quadrados.

Soma dos produtos	SQ_x	SQ_y
–240	2.062,5	44,4

$$r = SP / \sqrt{(SQ_x \times SQ_y)}$$

$$r = -240 / \sqrt{(2.062{,}5 \times 44{,}4)} \approx -0{,}793$$

Dados simulados para fins didáticos

Passos do teste de hipóteses

5. Tome uma decisão.

- Compare seu r calculado com o r crítico a partir do passo 4
- **Rejeitar ou não rejeitar a hipótese nula**
  - Neste exemplo, rejeitamos H_0: $p < 0,05$

Espera e satisfação: conclusão

r = –0,793

r crítico = ±0,632

|r| = 0,793 > 0,632

r(8) = –0,793
p = 0,006 (bilateral)

Dados simulados para fins didáticos

Rejeitamos H_0

Nesta amostra, maior tempo de espera está associado a menor satisfação com o atendimento.

A associação não demonstra que a espera, sozinha, causou a insatisfação.

Tamanho do efeito e variabilidade compartilhada

$r = -0{,}793$

O sinal indica a direção negativa. A magnitude mostra a força da associação linear neste conjunto.

$r^2 \approx 0{,}629$

Cerca de 62,9% da variabilidade da satisfação é contabilizada pelo ajuste linear que usa o tempo de espera.

r^2 descreve o ajuste nesta amostra. Não demonstra causalidade.

Dados simulados para fins didáticos

Correlação parcial

- As pessoas mais altas têm vozes mais grossas?
- E se você encontrou r = .60?
- Existe uma TERCEIRA VARIÁVEL que realmente está conduzindo este efeito?
- Sexo?
  - Homens mais altos em média
  - Homens vozes mais grossas em média
  - Pode ser gênero, e não a altura que gera o efeito

Correlação parcial

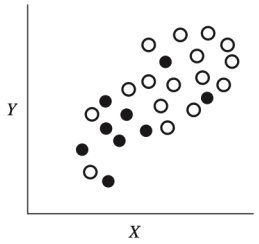
- Quando criamos uma correlação parcial nós:
  - Controle para, remover, parcial para fora...
  - ...variância de uma variável que potencialmente obscurece ou altera a correlação entre duas outras variáveis

- Uma vez que partimos o sexo da correlação entre altura e tom de voz, resta alguma correlação?

- As correlações parciais permitem “descontaminar” as correlações
  - Muitas vezes útil quando não tem controle experimental completo

Visualizando correlação parcial

Genuíno: a correlação mantém-se em ambos os grupos



Não Genuíno: a correlação mantém-se em 1 grupo, não em outro

Grupo 1 ○
Grupo 2 ●

Não genuíno: sem correlação dentro dos grupos.

Diferenças entre as médias criam a correlação agregada.

Não genuíno: a associação se inverte dentro dos grupos.

Diferenças entre as médias criam a correlação agregada.

Correlação parcial

- Todas as três variáveis também podem ser contínuas
- E se houvesse correlação entre idade e salário?
  - Será que as pessoas simplesmente dão mais dinheiro aos trabalhadores mais velhos?
  - Ou é simplesmente que os trabalhadores mais velhos têm mais anos de experiência?
  - Anos de experiência parcial para ver se ainda existe uma correlação entre idade e salário
- Prefiguração: E se houver contribuições independentes de idade e anos de experiência?

Ceia de Natal: pratos e reclamações

Um professor suspeita que, quanto mais pratos prepara para a ceia de Natal, menos seu irmão reclama da comida.

Em cinco ceias, ele registrou o número de pratos e a quantidade de reclamações.

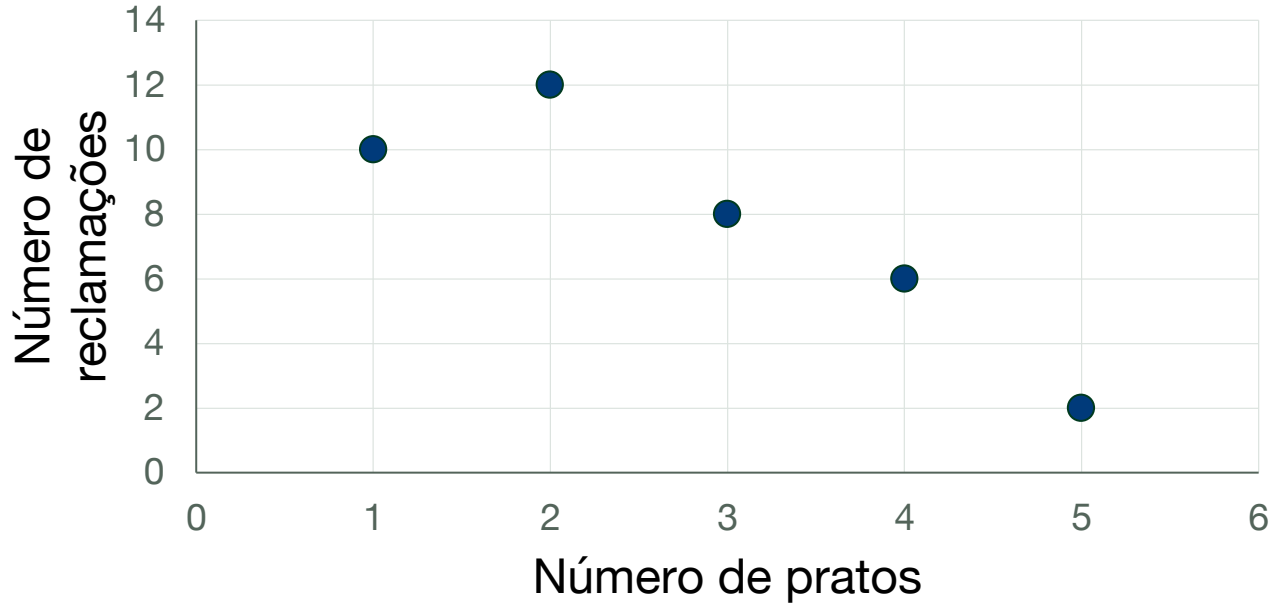
Há evidência dessa associação negativa, com α = 0,05?

Ceia	Pratos X	Reclamações Y
1	2	12
2	4	6
3	5	2
4	3	8
5	1	10

Dados do exercício didático

Ceia de Natal: gráfico de dispersão

Cada ponto representa uma ceia de Natal.



O gráfico sugere uma associação negativa.

Ceias com mais pratos tendem a apresentar menos reclamações neste conjunto.

Dados do exercício didático

Ceia de Natal: hipóteses

A pergunta é direcional: esperamos uma correlação populacional negativa.

Hipótese nula

$$H_0: \rho \geq 0$$

A correlação populacional não é negativa.

Hipótese alternativa

$$H_1: \rho < 0$$

A correlação populacional é negativa.

Teste unilateral à esquerda, com $\alpha = 0{,}05$.

Ceia de Natal: graus de liberdade

Temos cinco pares de medidas, um para cada ceia.

$$gl = n - 2$$

$$gl = 5 - 2 = 3$$

Usaremos gl = 3 para consultar o valor crítico da correlação.

Dados do exercício didático

Ceia de Natal: valor crítico

Na tabela de r, usamos gl = 3 e α = 0,05 unilateral.

gl	α unilateral	|r crítico|
3	0,05	0,805

A hipótese prevê sinal negativo.

r crítico = –0,805

Rejeitamos H_0 se r < –0,805.

Dados do exercício didático

Ceia de Natal: soma dos produtos

Multiplicamos os desvios de X e Y e somamos os produtos.

X	Y	$X - M_x$	$Y - M_Y$	Produto
2	12	–1	4,4	–4,4
4	6	1	–1,6	–1,6
5	2	2	–5,6	–11,2
3	8	0	0,4	0,0
1	10	–2	2,4	–4,8

$$SP = \Sigma[(X - M_x)(Y - M_Y)]$$

$M_x = 3$

$M_Y = 7{,}6$

SP = –22

Ceia de Natal: somas de quadrados

Elevamos os desvios ao quadrado e somamos cada coluna.

X	Y	$X - M_x$	$Y - M_y$	$(X - M_x)^2$	$(Y - M_y)^2$
2	12	–1	4,4	1	19,36
4	6	1	–1,6	1	2,56
5	2	2	–5,6	4	31,36
3	8	0	0,4	0	0,16
1	10	–2	2,4	4	5,76

$SQ_x = 10$

$SQ_y = 59{,}2$

$\sqrt{(SQ_x \times SQ_y)} = \sqrt{592} \approx 24{,}33$

Ceia de Natal: cálculo de r

$$r = SP / \sqrt{(SQ_x \times SQ_y)}$$

$$r = -22 / \sqrt{(10 \times 59{,}2)}$$

$$r \approx -0{,}904$$

Associação linear negativa de grande magnitude neste conjunto de cinco ceias.

Dados do exercício didático

Ceia de Natal: decisão e conclusão

$-0{,}904 < -0{,}805$

$r(3) = -0{,}904$
$p = 0{,}018$ (unilateral)

Rejeitamos H_0

Neste exercício, há evidência de associação negativa: ceias com mais pratos tendem a ter menos reclamações.

A associação não demonstra que preparar mais pratos causou a redução das reclamações.

Inferência ilustrativa: assumimos independência e condições adequadas ao teste.