Unidade 4: Correlação

r de Pearson, inferência e introdução à correlação

Robert Vidigal

MQAPP / UnB • 2026.2

Comparação de médias

Até esse ponto da disciplina, as perguntas eram deste tipo:

- **Teste t ou Z de uma amostra:** a média de uma população difere de um valor de referência? Por exemplo: a média de uma turma difere de 7?

Comparação de médias

Até esse ponto da disciplina, as perguntas eram deste tipo:

- **Teste t ou Z de uma amostra:** a média de uma população difere de um valor de referência? Por exemplo: a média de uma turma difere de 7?

- **Teste t de amostras independentes:** as médias de dois grupos diferem? Por exemplo: estudantes do turno diurno e do noturno têm médias diferentes?

Da comparação de médias à associação entre variáveis

Na correlação, a pergunta muda. Em uma amostra de estudantes, podemos registrar **duas medidas para cada pessoa.**

Da comparação de médias à associação entre variáveis

Na correlação, a pergunta muda. Em uma amostra de estudantes, podemos registrar **duas medidas para cada pessoa.**

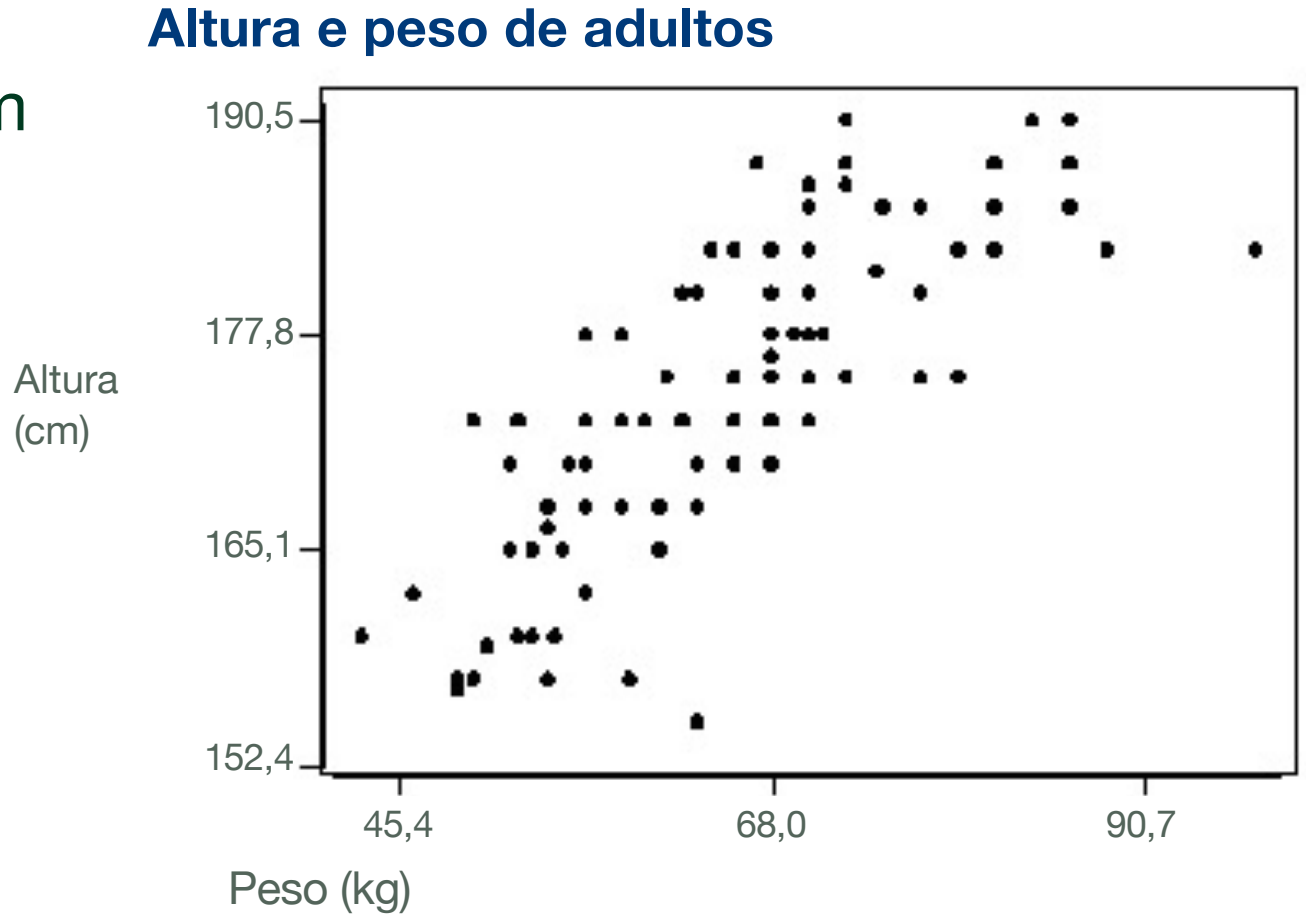
Agora, vamos investigar outra pergunta:

quando uma variável aumenta, a outra tende a aumentar, diminuir ou não apresentar um padrão linear?

Exemplo: qual é a relação entre horas de estudo e nota?

Correlação

As correlações representam a relação sistemática entre duas variáveis.



Correlação

- Duas propriedades principais de uma correlação:
  - Direção
    - A natureza da relação entre as variáveis

Correlação

- Duas propriedades principais de uma correlação:
  - Direção
    - A natureza da relação entre as variáveis

Positivo

as variáveis vão na mesma direção



Correlação

- Duas propriedades principais de uma correlação:
  - Direção
    - A natureza da relação entre as variáveis

Positivo

as variáveis vão na mesma direção

↑ Variável X ↑ Variável Y

↓ Variável X ↓ Variável Y

Correlação

- Duas propriedades principais de uma correlação:
  - Direção
    - A natureza da relação entre as variáveis

Positivo

as variáveis vão na mesma direção

↑ Variável X ↑ Variável Y

↓ Variável X ↓ Variável Y

Negativo

as variáveis vão direções opostas

↑ Variável X ↓ Variável Y

Correlação

- Duas propriedades principais de uma correlação:
  - Direção
    - A natureza da relação entre as variáveis

Positivo

as variáveis vão na mesma direção

↑ Variável X ↑ Variável Y

↓ Variável X ↓ Variável Y

Negativo

as variáveis vão direções opostas

↑ Variável X ↓ Variável Y

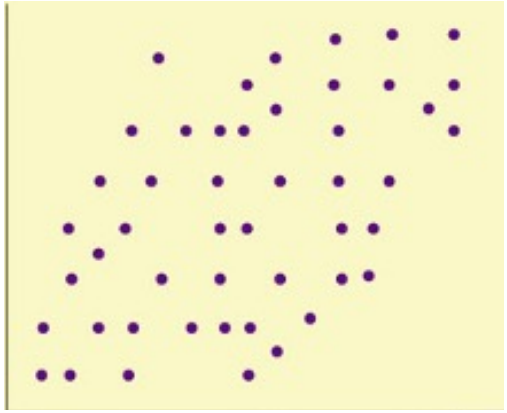
↓ Variável X ↑ Variável Y

Força da correlação

A força indica a consistência da relação entre as variáveis.

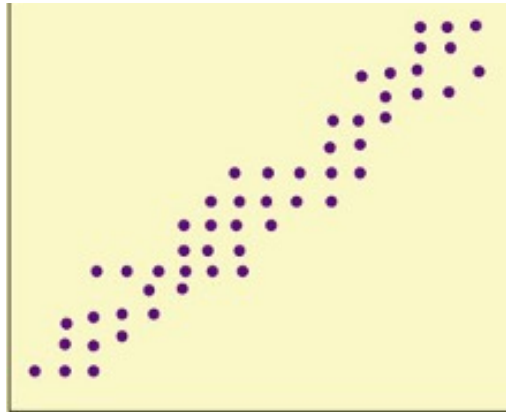
Associação fraca

As observações ficam mais dispersas.
A relação é menos consistente.



Associação forte

Valores extremos de X tendem a acompanhar valores extremos de Y.



Correlação

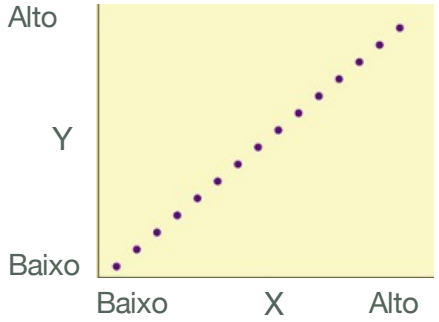
- Essas relações são quantificadas por um coeficiente de correlação
  - Vamos usar o coeficiente de correlação de Pearson: r
    - *r pode ter qualquer valor de -1,00 a +1,00*
    - O sinal de r (- / +) indica a direção da relação
    - O valor absoluto (magnitude) de r indica a força da relação

Pequeno	.10
Médio	.30
Grande	.50

Diagramas de dispersão

As correlações podem ser visualizadas usando um gráfico de dispersão.

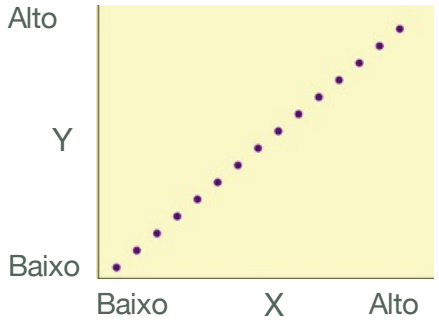
Positiva perfeita



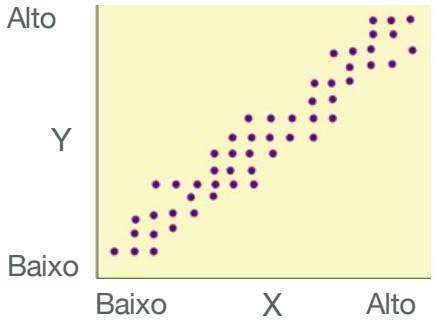
Diagramas de dispersão

As correlações podem ser visualizadas usando um gráfico de dispersão.

Positiva perfeita



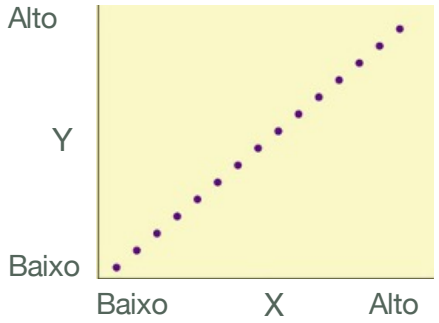
Positiva forte



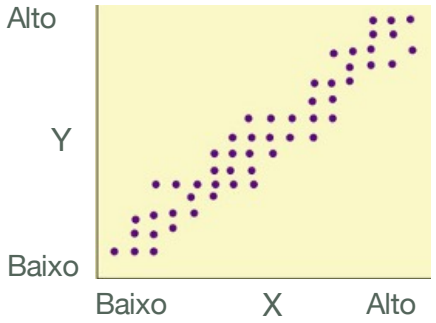
Diagramas de dispersão

As correlações podem ser visualizadas usando um gráfico de dispersão.

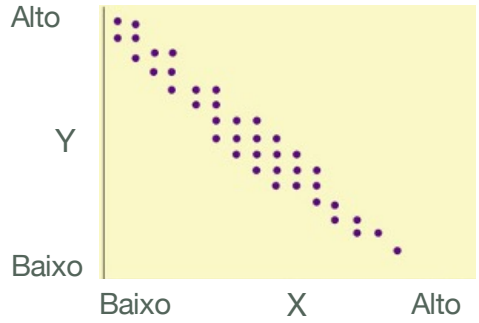
Positiva perfeita



Positiva forte



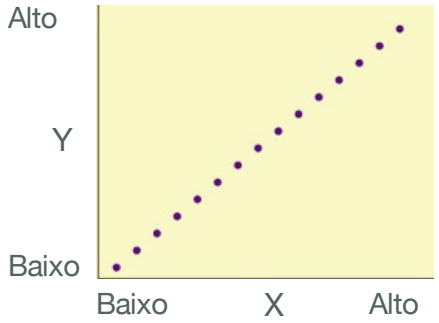
Negativa forte



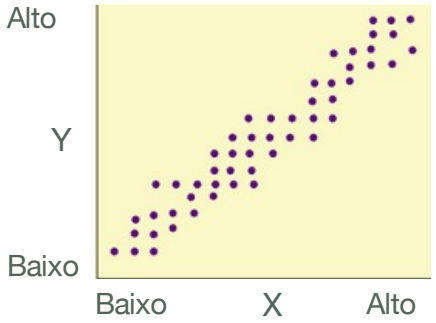
Diagramas de dispersão

As correlações podem ser visualizadas usando um gráfico de dispersão.

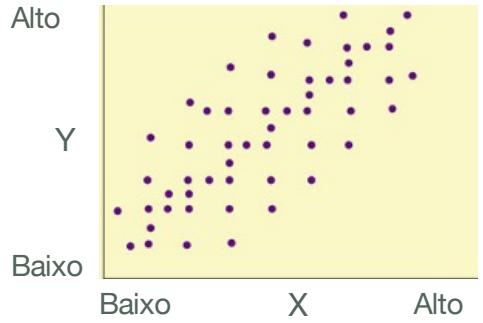
Positiva perfeita



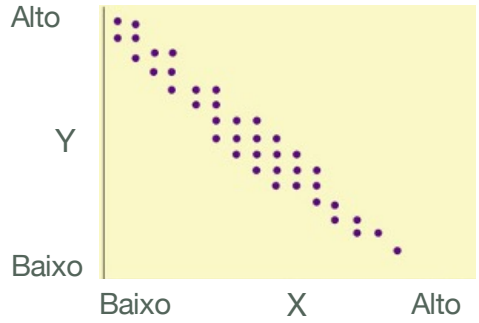
Positiva forte



Positiva moderada



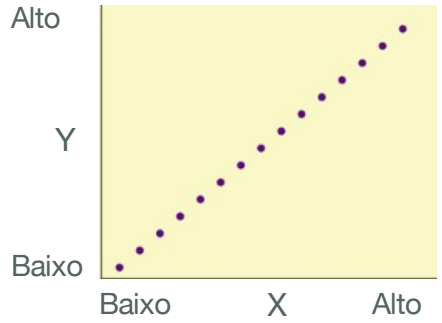
Negativa forte



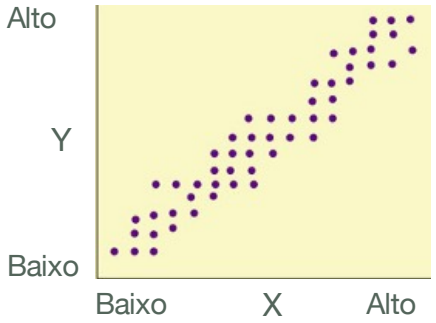
Diagramas de dispersão

As correlações podem ser visualizadas usando um gráfico de dispersão.

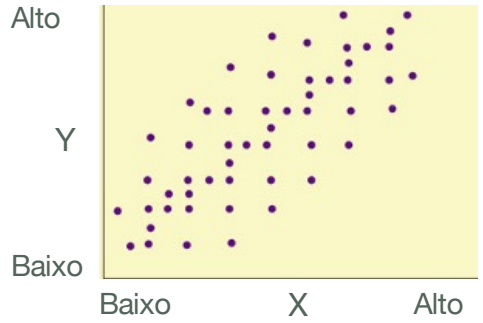
Positiva perfeita



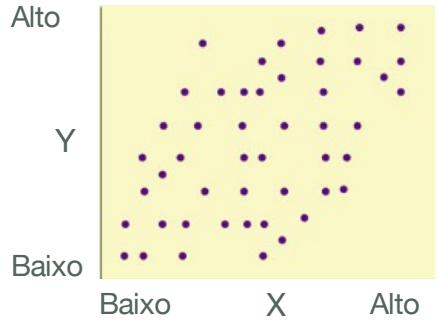
Positiva forte



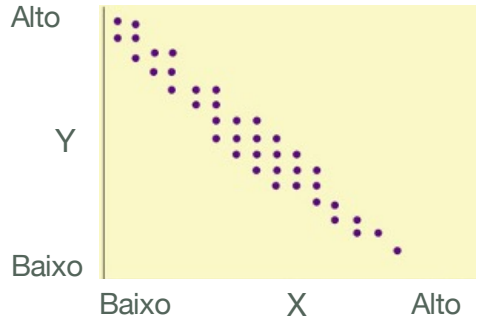
Positiva moderada



Positiva fraca



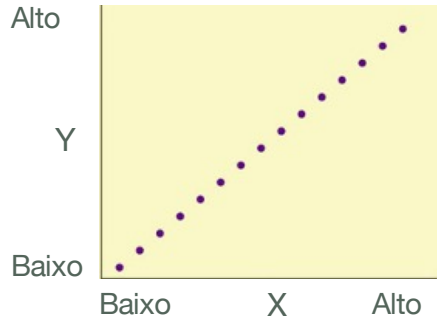
Negativa forte



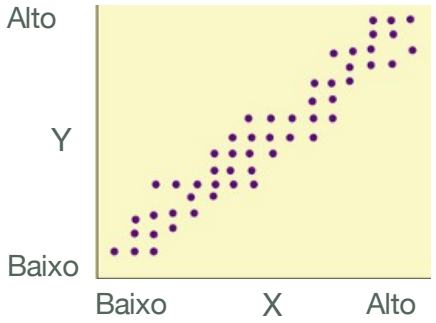
Diagramas de dispersão

As correlações podem ser visualizadas usando um gráfico de dispersão.

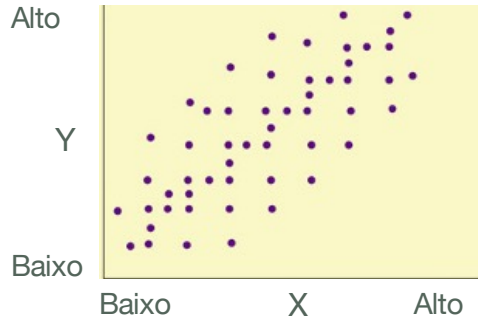
Positiva perfeita



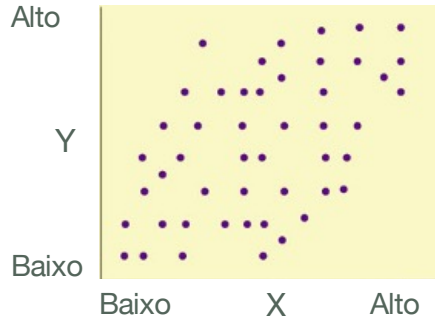
Positiva forte



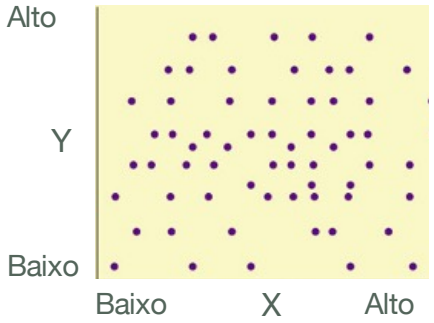
Positiva moderada



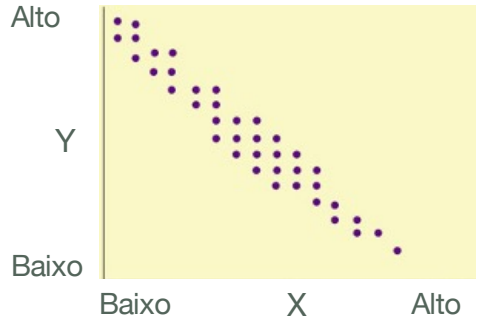
Positiva fraca



Aproximadamente zero



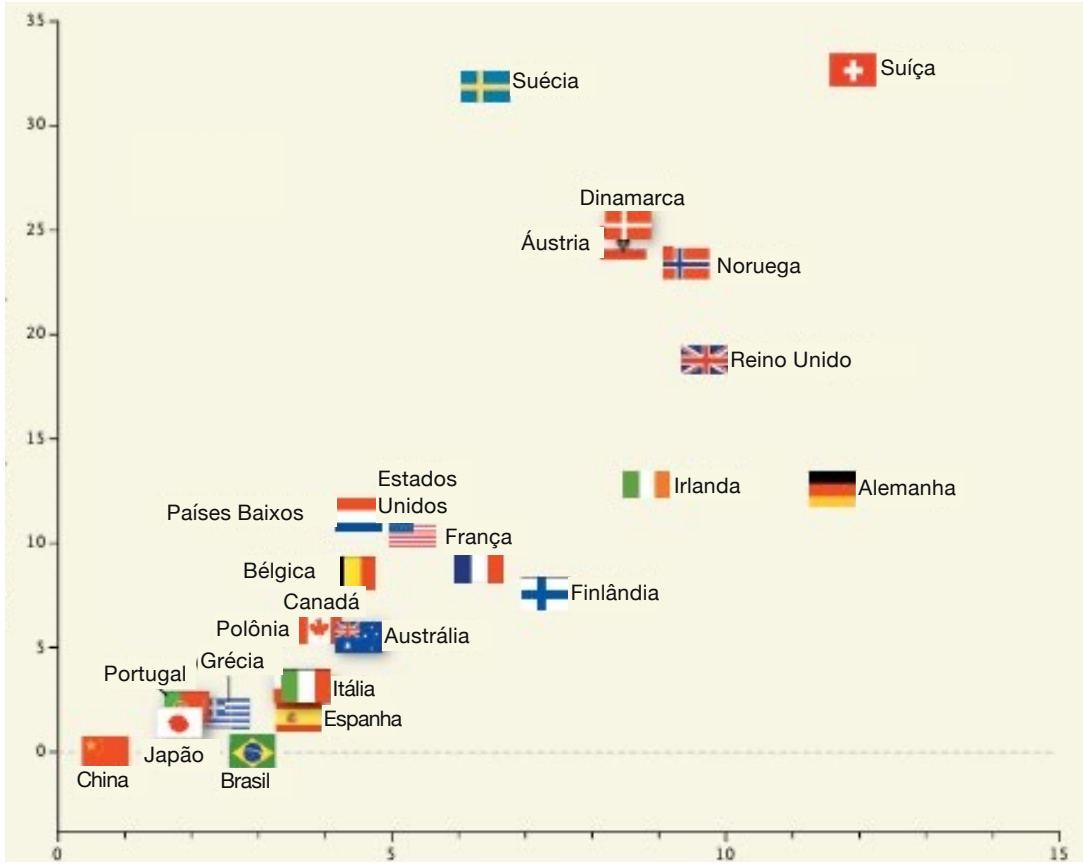
Negativa forte



Correlação não implica causalidade

Consumo de chocolate e prêmios Nobel

Relação entre o consumo anual por habitante e o número de laureados com o Nobel por país.

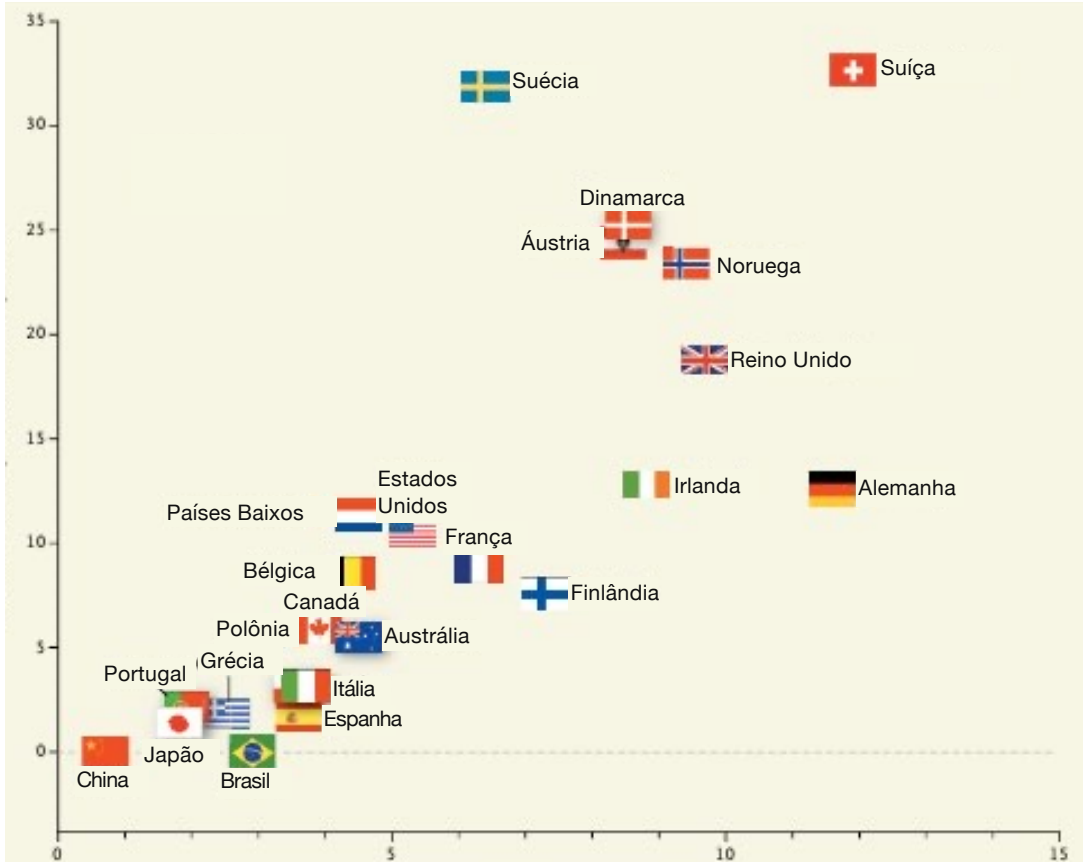


Correlação não implica causalidade

Consumo de chocolate e prêmios Nobel

Relação entre o consumo anual por habitante e o número de laureados com o Nobel por país.

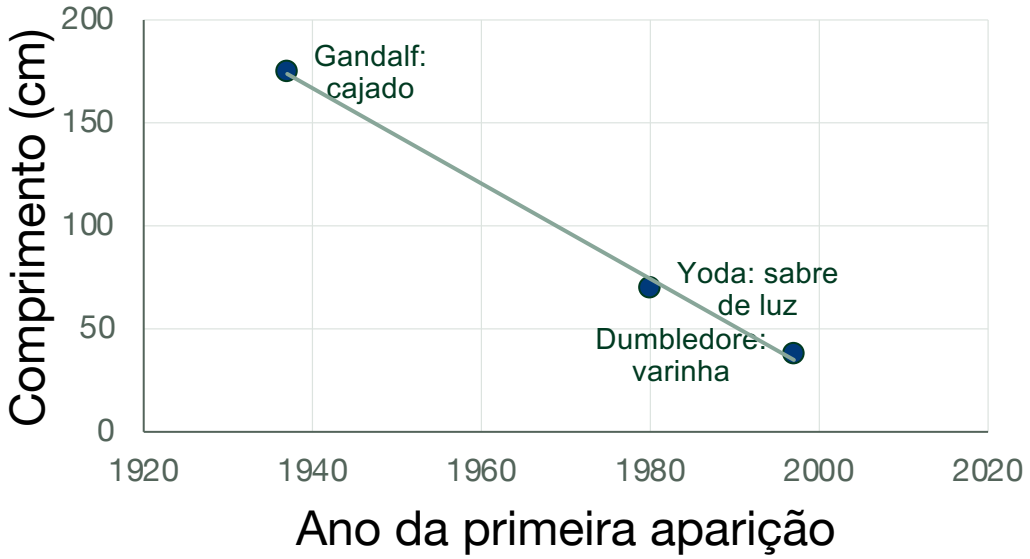
r = 0,791
p < 0,0001



Correlações na literatura e no cinema

Cada ponto é um personagem. O ano é da obra; a idade pertence à história.

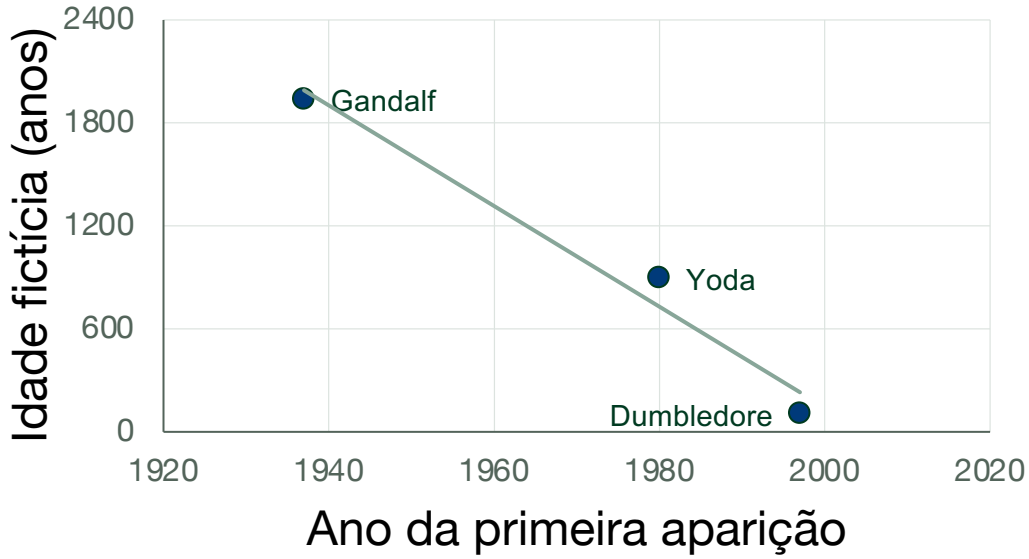
Comprimento do objeto



r = –0,9985

y = 4656,434 – 2,314x

Idade fictícia do personagem



r = –0,9863

y = 58789,986 – 29,324x

À direita, os personagens de aparição mais recente têm idades fictícias menores.

Correlação

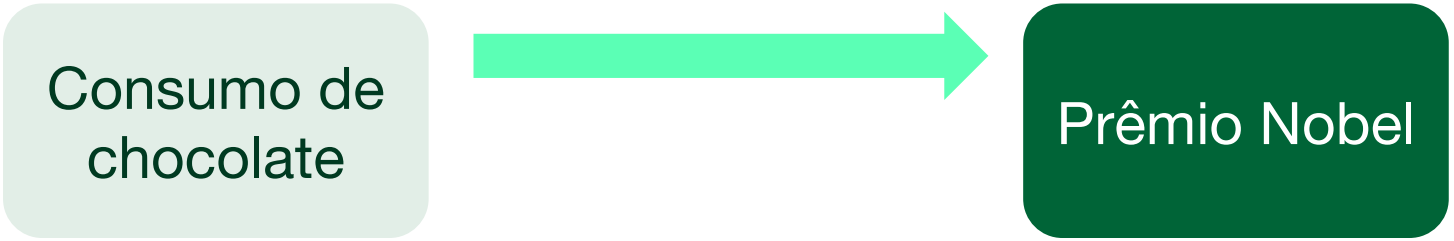
- Limitações
  - Direção causal
    - Ambos os sentidos de causalidade são possíveis

Consumo de chocolate

Prêmio Nobel

Correlação

- Limitações
  - Direção causal
    - Ambos os sentidos de causalidade são possíveis



Correlação

- Limitações
  - Direção causal
    - Ambos os sentidos de causalidade são possíveis



Correlação

- Limitações
  - Terceira variável
    - Algumas outras variáveis estão relacionadas tanto com nossas variáveis quanto com sua relação (ilusória)



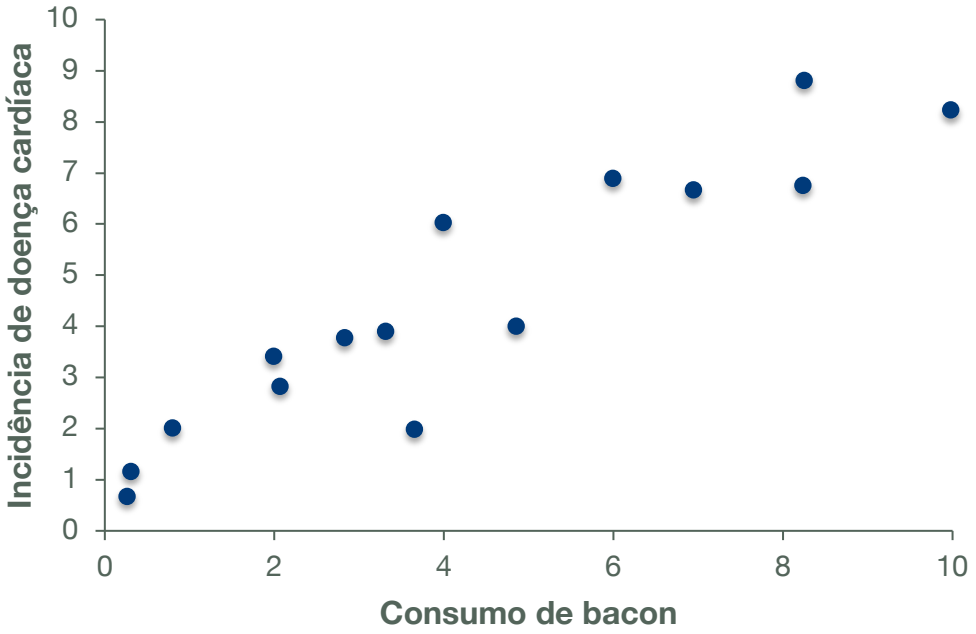
Correlação

- Limitações
  - Terceira variável
    - Algumas outras variáveis estão relacionadas tanto com nossas variáveis quanto com sua relação (ilusória)



Correlação

- Que tipo de correlação seria esperada entre o consumo de bacon e a incidência de doenças cardíacas?

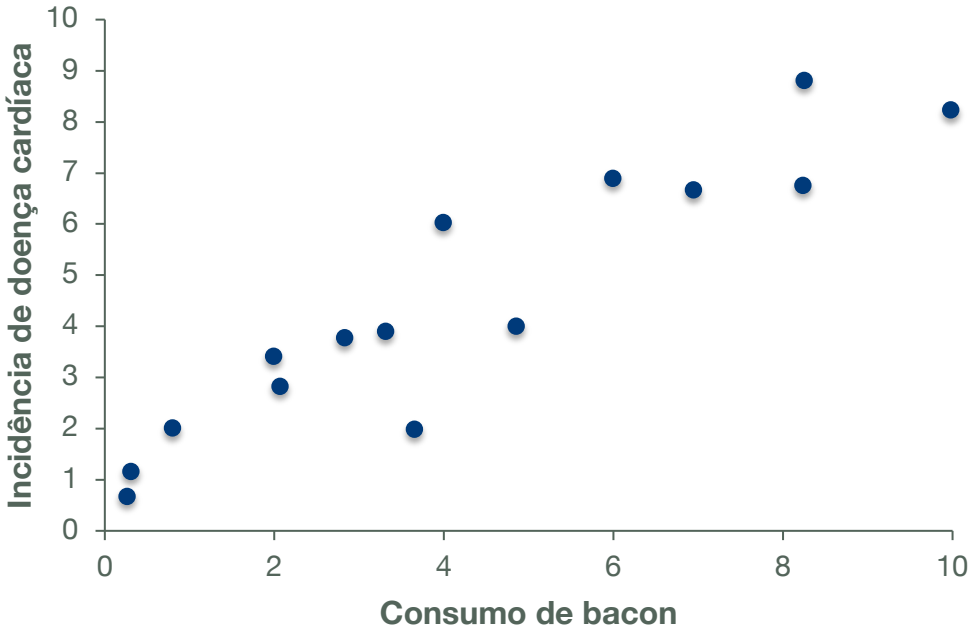


Correlação

- Que tipo de correlação seria esperada entre o consumo de bacon e a incidência de doenças cardíacas?

Correlação

- Que tipo de correlação seria esperada entre o consumo de bacon e a incidência de doenças cardíacas?

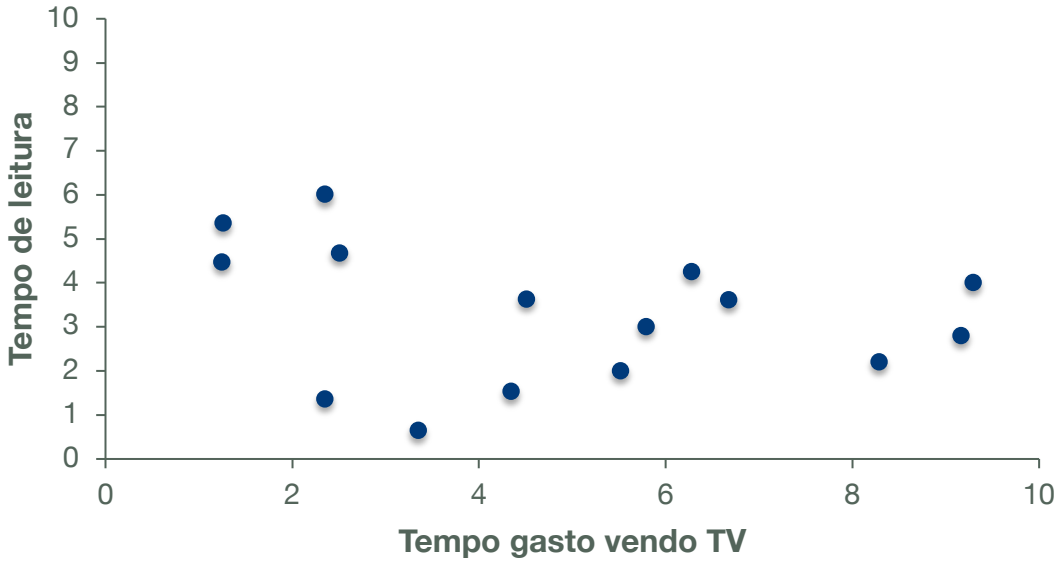


Grande positivo

***r* = .93**

Correlação

- Que tipo de correlação seria esperada entre a quantidade de tempo de lazer gasto lendo e a quantidade de tempo assistindo TV?

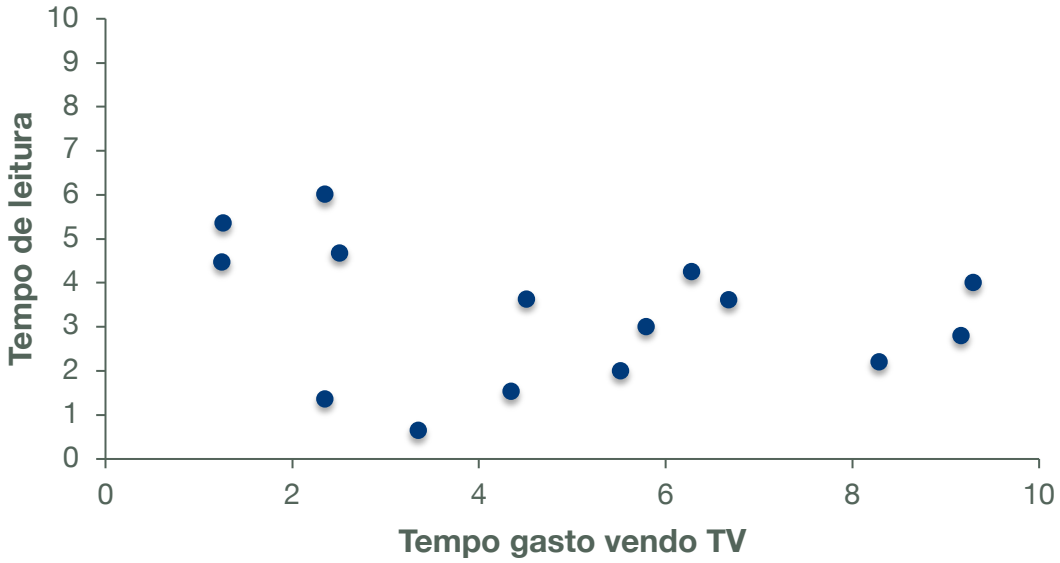


Correlação

- Que tipo de correlação seria esperada entre a quantidade de tempo de lazer gasto lendo e a quantidade de tempo assistindo TV?

Correlação

- Que tipo de correlação seria esperada entre a quantidade de tempo de lazer gasto lendo e a quantidade de tempo assistindo TV?

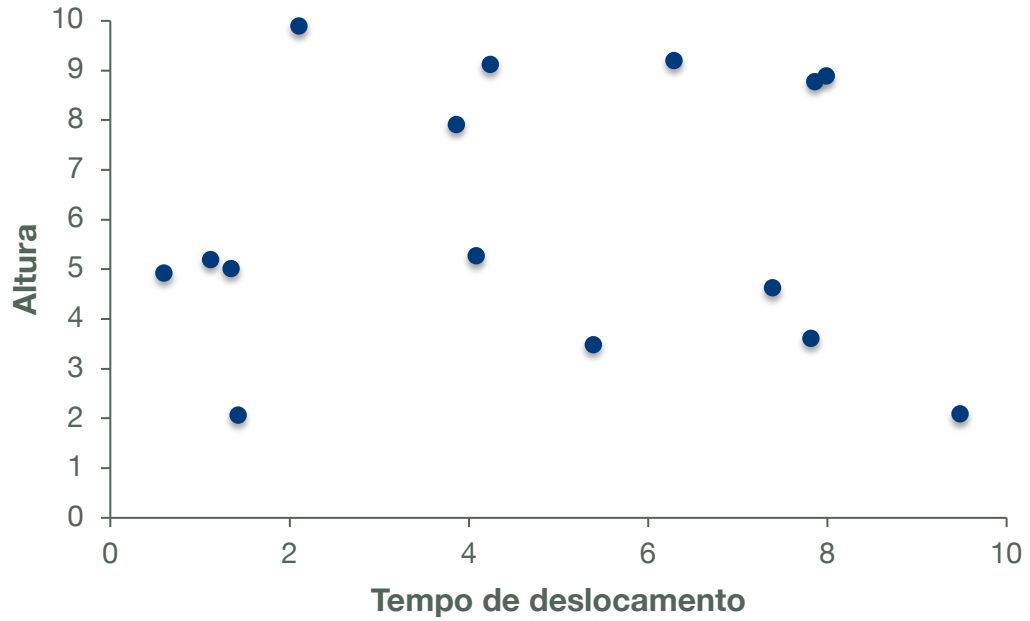


Pequeno negativo

***r* = -.04**

Correlação

- Que tipo de correlação seria esperada entre a altura de uma pessoa e a duração de seu trajeto diário?

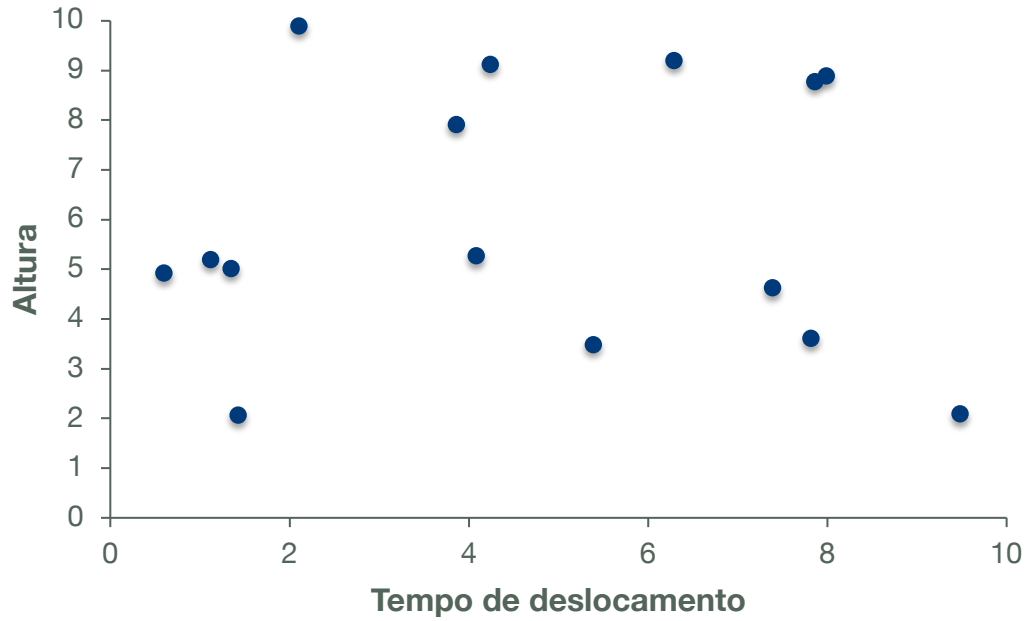


Correlação

- Que tipo de correlação seria esperada entre a altura de uma pessoa e a duração de seu trajeto diário?

Correlação

- Que tipo de correlação seria esperada entre a altura de uma pessoa e a duração de seu trajeto diário?



Nenhuma correlação

***r* = .02**

Antes do teste de Pearson

Começamos pelo desenho da pesquisa e pelo diagrama de dispersão.

Cada pessoa fornece um par (X, Y). As observações de pessoas diferentes devem ser independentes.

No gráfico, procuramos um padrão aproximadamente linear e verificamos dispersão e pontos extremos.

Espera e satisfação no serviço público

Um serviço público quer investigar se o tempo de espera está associado à satisfação com o atendimento.

Cada pessoa fornece duas medidas:
X: espera em minutos.
Y: satisfação de 0 a 10.

10 pessoas, duas medidas por pessoa

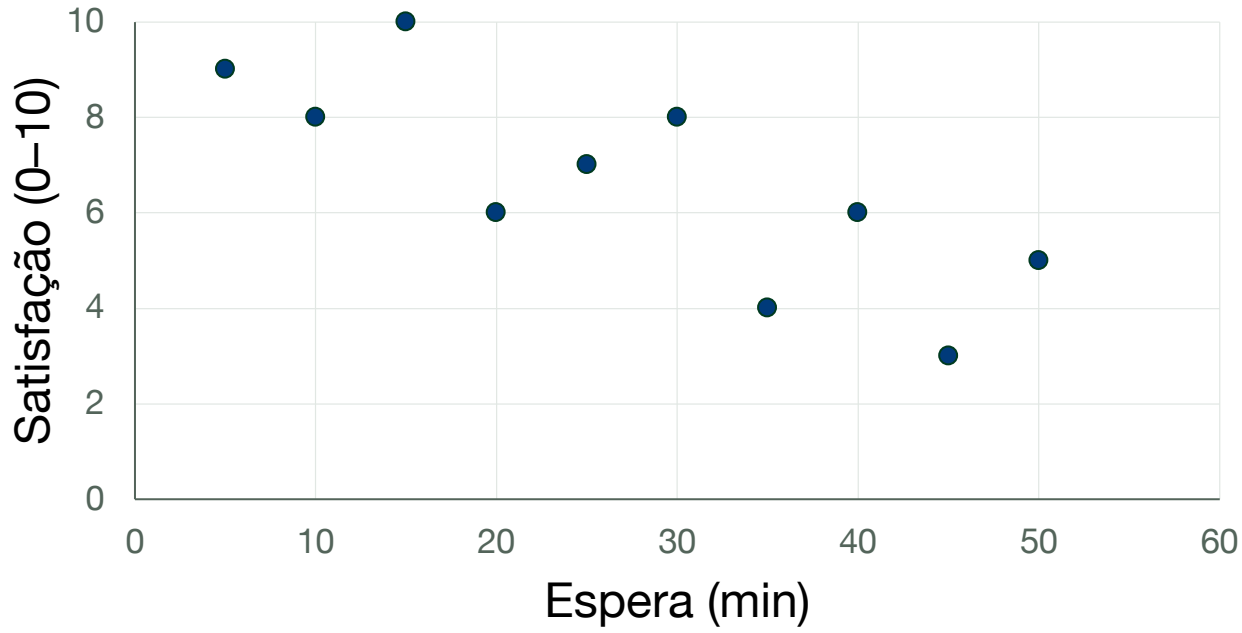
Pessoa	Espera X (min)	Satisfação Y (0–10)
1	5	9
2	10	8
3	15	10
4	20	6
5	25	7
6	30	8
7	35	4
8	40	6
9	45	3
10	50	5

Satisfação: 0 = pior avaliação; 10 = melhor avaliação.

Dados simulados para fins didáticos

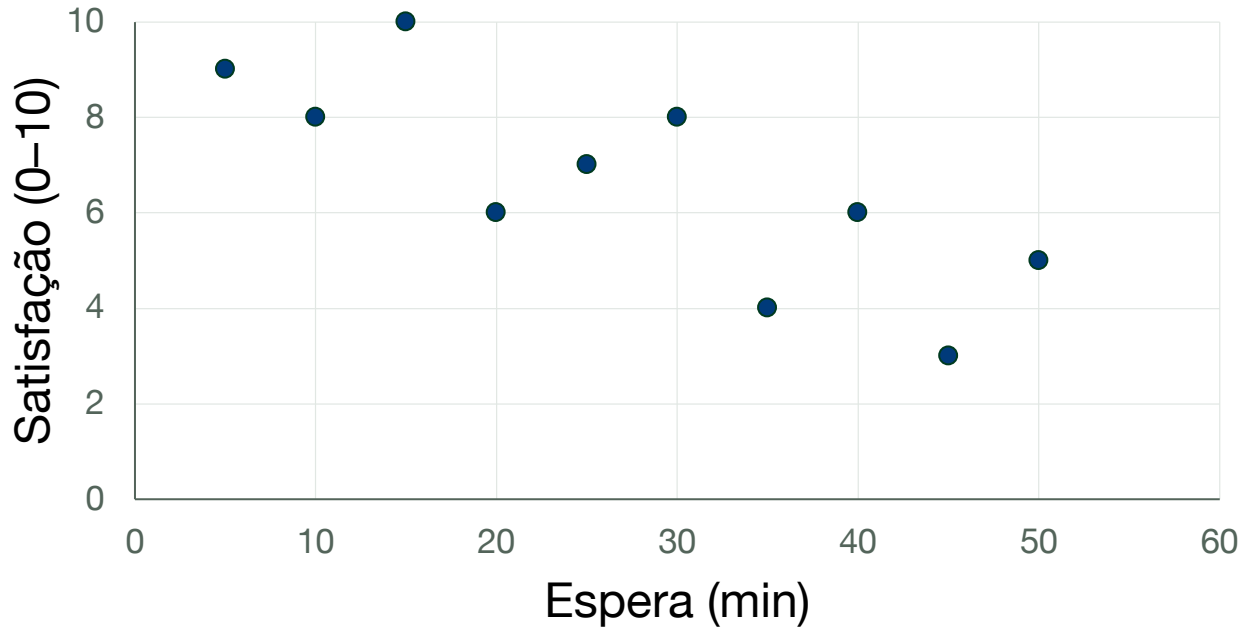
Tempo de espera e satisfação

Cada ponto representa uma pessoa, com duas medidas: espera e satisfação.



Tempo de espera e satisfação

Cada ponto representa uma pessoa, com duas medidas: espera e satisfação.



O gráfico sugere uma associação negativa.

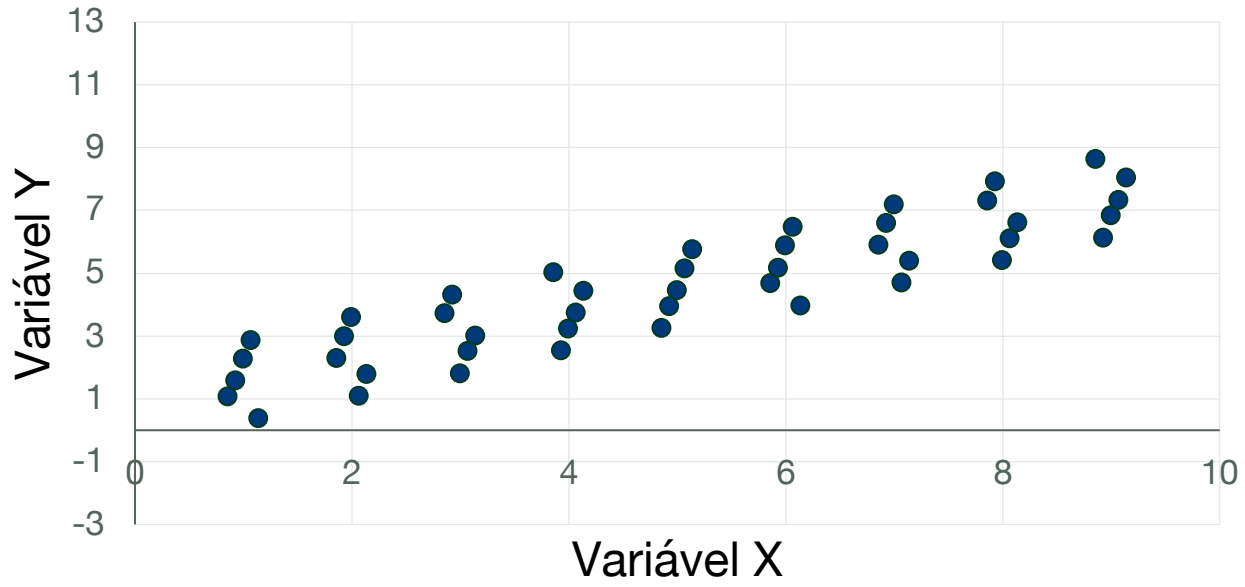
Essa tendência na amostra é evidência de associação na população?

Agora vamos verificar os dados e aprender a testar essa hipótese.

Dados simulados para fins didáticos

Dispersão semelhante ao longo de X

A faixa vertical dos pontos mantém uma espessura parecida ao longo do eixo X.



X e Y podem ter unidades e variâncias diferentes.

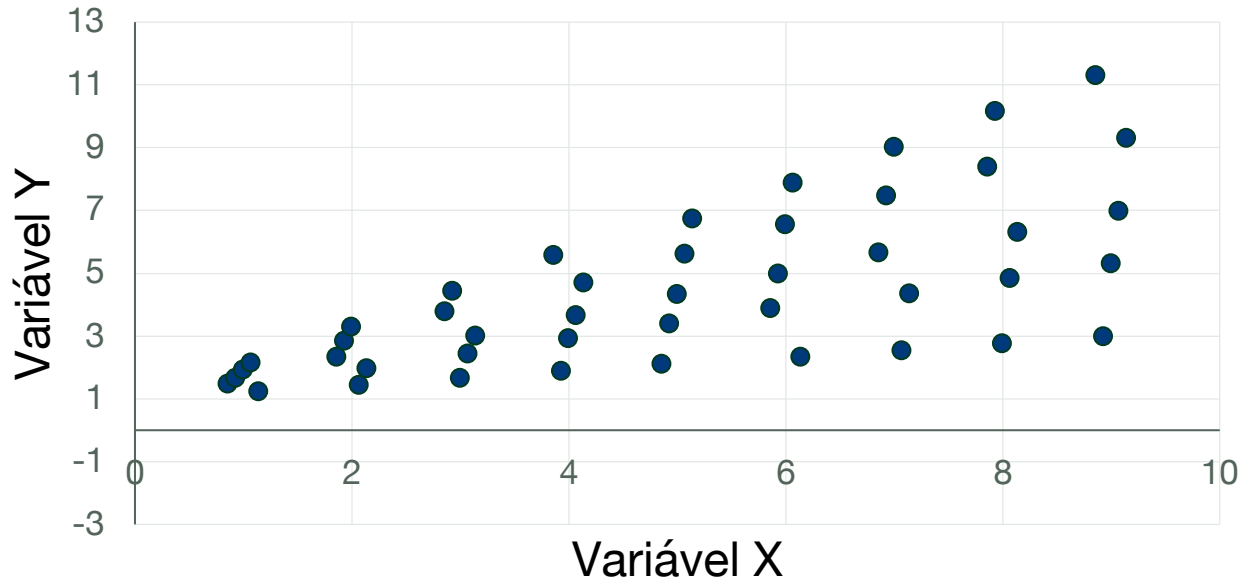
O que observar

Compare a distância dos pontos em relação à tendência, ao longo do eixo X.

Esse padrão é chamado homoscedasticidade.

Dispersão que muda ao longo de X

Neste exemplo, a faixa de pontos se alarga à medida que X aumenta.



O que observar

Para X baixo, os pontos ficam próximos da tendência. Para X alto, ficam mais espalhados.

Esse formato de funil indica heteroscedasticidade.

Podemos calcular r, mas esse padrão exige cautela com a inferência usual.

Na próxima aula

Hoje foi: direção, força e limites da correlação

Como ler diagramas de dispersão e interpretar o sinal e a magnitude de r.

Para revisar para próxima aula

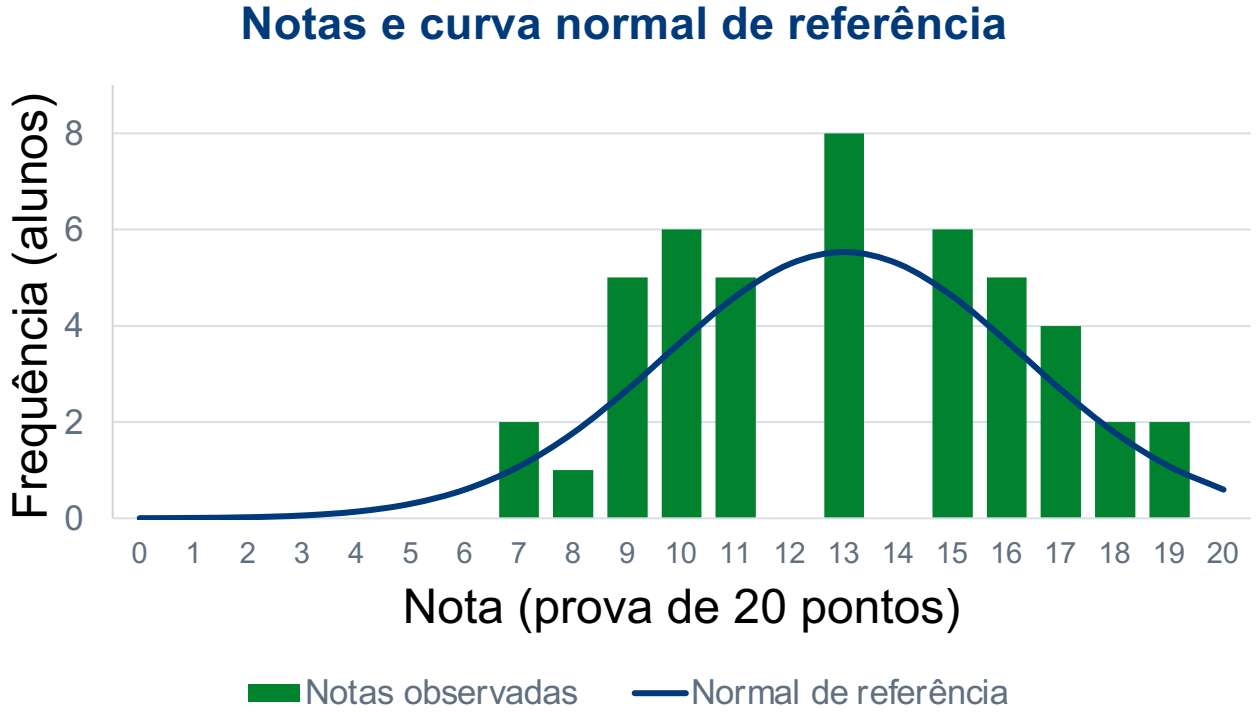
Uma correlação negativa significa uma associação fraca? Por que uma correlação forte não demonstra causalidade?

Na próxima aula: cuidados com os dados e teste da correlação de Pearson

Prova 3: estatísticas descritivas

46 notas acima de zero. Prova de 20 pontos. Sete zeros excluídos.

Estatística	Resultado
Média	**13,00 (65,0%)**
Mediana	**13,00**
Moda	**13,00**
Desvio-padrão	**3,32**
Variância	**11,00**
Mínimo / Máximo	**7 / 19**
Notas ≥ 10	**38 (82,6%)**

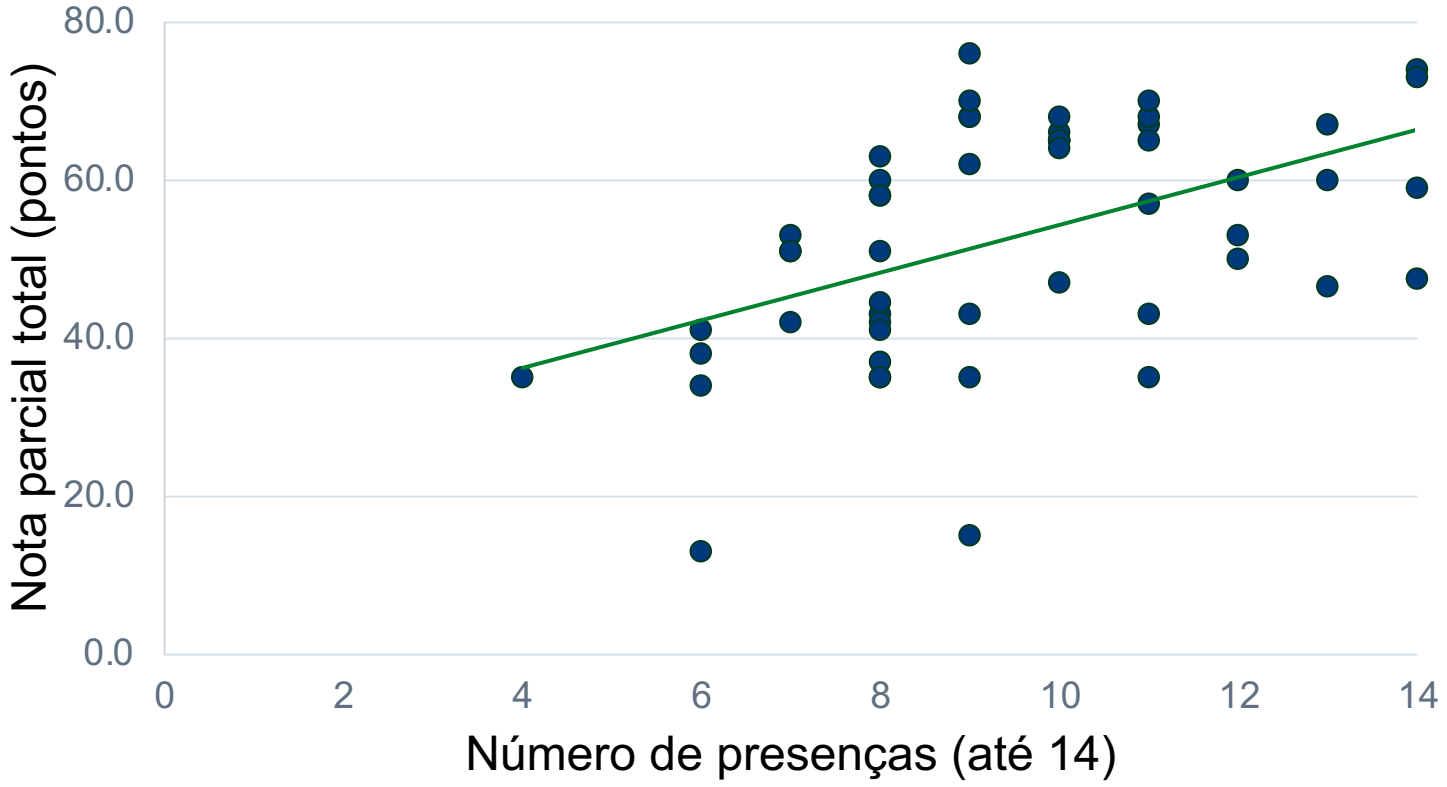


A curva normal permite comparar o formato esperado com as notas.

A semelhança visual com a curva não confirma normalidade.

Presenças e nota parcial total

53 alunos com notas e presenças correspondentes por matrícula. Chamada parcial de 14 aulas.



Correlação de Pearson

r = 0,486

Associação positiva moderada

Alunos com mais presenças tendem a ter notas parciais mais altas.

Spearman: ρ = 0,515

A correlação descreve uma associação e não estabelece causalidade.

Total conforme registrado, com um valor de 76 acima do máximo indicado de 75.

Correlação Parte 2

r de Pearson, inferência e correlação parcial

Robert Vidigal

MQAPP / UnB • 2026.2

Retomada: como interpretar r de Pearson

O sinal indica a direção

$r > 0$: valores maiores de X tendem a acompanhar valores maiores de Y.

$r < 0$: valores maiores de X tendem a acompanhar valores menores de Y.

A magnitude indica a força

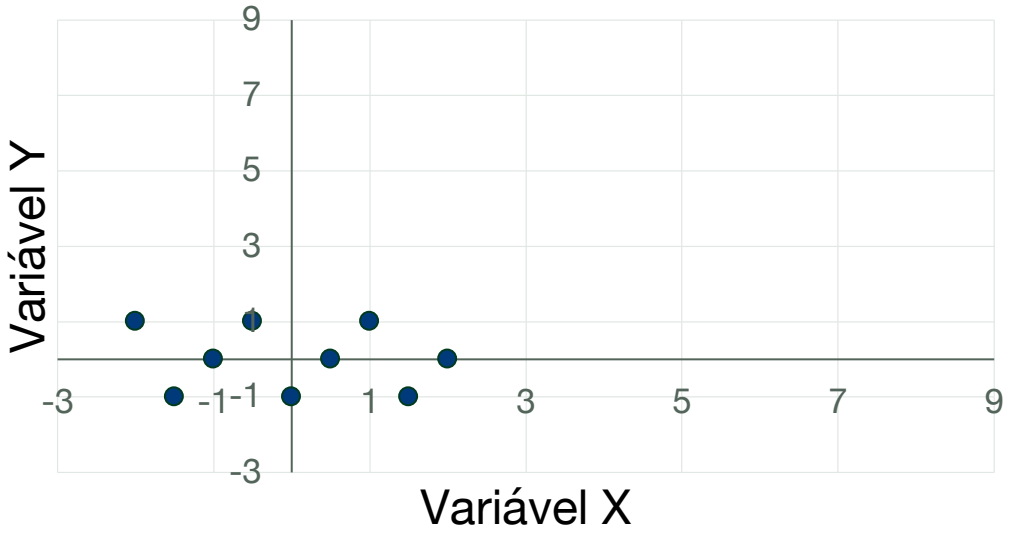
r = –0,80 é uma associação linear mais forte que r = +0,30.

r próximo de zero indica pouca associação linear.

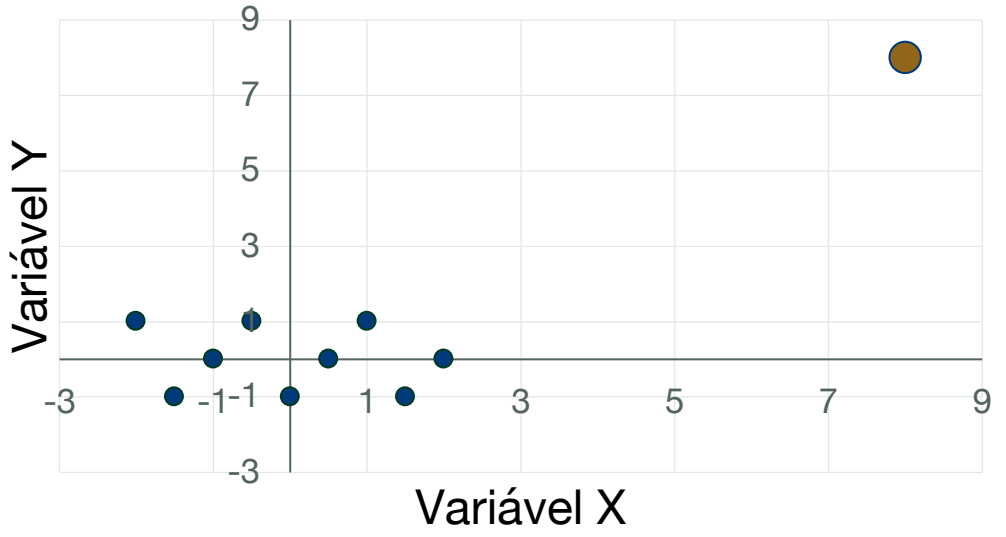
Correlação, por si só, não demonstra causa e efeito.

Um único ponto pode mudar r

Sem o ponto extremo: r = –0,16



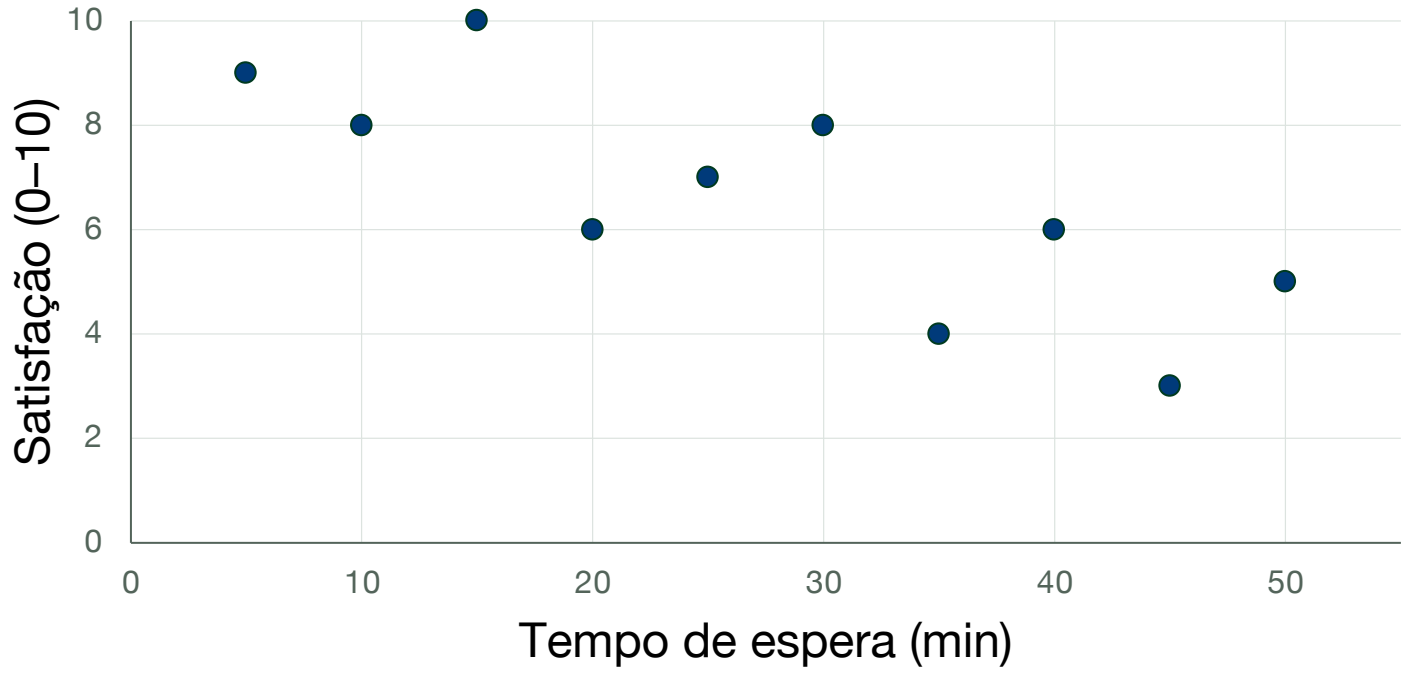
Com o ponto extremo: r = 0,83



Os nove pontos originais são os mesmos nos dois gráficos.

Espera e satisfação: gráfico de dispersão

Como a satisfação varia entre pessoas que esperaram tempos diferentes?



Cada ponto representa uma pessoa.

O gráfico sugere uma associação negativa: esperas maiores tendem a acompanhar notas menores.

Dados simulados para fins didáticos

Passos do teste de hipóteses

1. Selecione o teste apropriado para seus dados
2. Declarar as hipóteses nulas e de pesquisa
3. Descreva a distribuição da hipótese nula.
4. Determinar os valores críticos.
5. Calcular a estatística do teste.
6. Tome uma decisão.

Passos do teste de hipóteses

2. Declarar as hipóteses nulas e de pesquisa

- Descreva as duas possibilidades mutuamente exclusivas em palavras e simbolicamente
  - Hipóteses sobre a relação entre duas variáveis em toda a população
    - Coeficiente de correlação = variância em uma variável por variância na outra variável

$$r = \frac{\text{Quantidade da variância comum}}{\text{Quantidade da variância total}}$$

Espera e satisfação: hipóteses

Vamos testar a correlação populacional entre tempo de espera e satisfação.

Hipótese nula

$$H_0: \rho = 0$$

Não há associação linear (rho) entre as duas variáveis na população.

Hipótese alternativa

$$H_1: \rho \neq 0$$

Há associação linear (rho) entre as duas variáveis na população.

Teste bilateral, $\alpha = 0{,}05$. Esperamos sinal negativo, mas o teste considera as duas direções.

Passos do teste de hipóteses

3. Descreva a distribuição da hipótese nula.

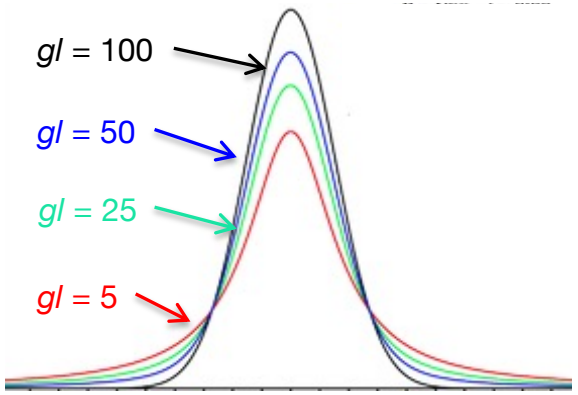
- Não é um passo único para as correlações...
- ... Então vamos apenas usar este passo para ter certeza de que sabemos o nosso grau de liberdade

Passos do teste de hipóteses

3. Descreva a distribuição da hipótese nula.

- Nos bastidores, os r's são testados com t's, assim como uma família de distribuições com base no grau de liberdade

  Quanto maior o grau de liberdade mais estreita a distribuição se torna



- Porque nós estaremos calculando variância para cada variável, nós perdemos dois graus de liberdade
  - $gl = n - 2$

Espera e satisfação: graus de liberdade

Temos n = 10 pares de medidas.
Cada pessoa contribui com um valor de espera e um de satisfação.

Para o teste de Pearson, os graus de liberdade são n – 2.

g.l. = n – 2

g.l. = 10 – 2 = 8

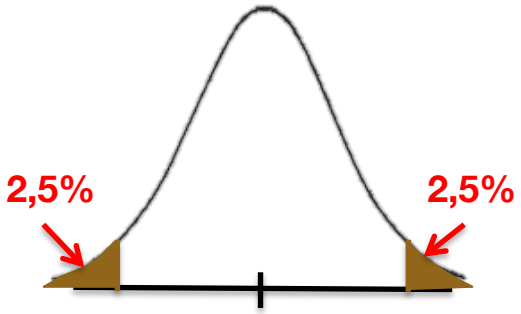
Usamos g.l. = 8 para consultar a tabela de valores críticos.

Passos do teste de hipóteses

4. Determinar os valores críticos.

Hipóteses não direcionais

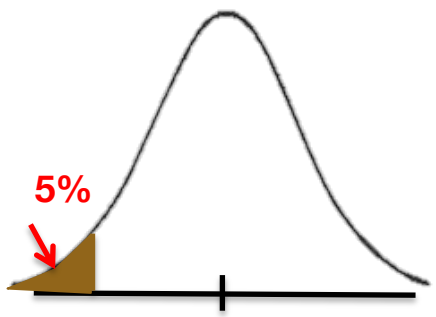
$H_1: \mu_1 \neq \mu_2$



t crítico: 2,5% por cauda

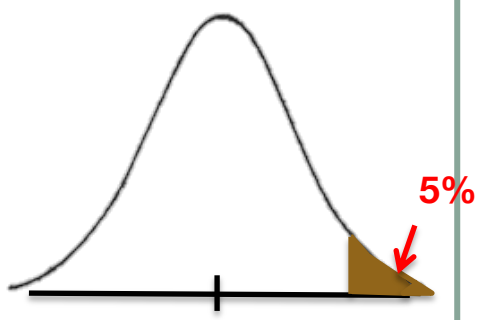
Hipóteses direcionais

$H_1: \mu_1 < \mu_2$



t crítico para 5% à esquerda

$H_1: \mu_1 > \mu_2$



t crítico para 5% à direita

Valores críticos da correlação

4. Determinar os valores críticos

Consultar o Quadro.

Se o número de graus de liberdade não estiver na tabela, usar o menor valor disponível.

g.l. = n – 2 = 10 – 2 = 8; α = 0,05

Em cada coluna: α unilateral / α bilateral

gl	0,05 / 0,10	0,025 / 0,05	0,01 / 0,02	0,005 / 0,01
1	0,988	0,997	0,9995	0,9999
2	0,900	0,950	0,980	0,990
3	0,805	0,878	0,934	0,959
4	0,729	0,811	0,882	0,917
5	0,669	0,754	0,833	0,874
6	0,622	0,707	0,789	0,834
7	0,582	0,666	0,750	0,798
8	0,549	0,632	0,716	0,765
9	0,521	0,602	0,685	0,735
10	0,497	0,576	0,658	0,708
11	0,476	0,553	0,634	0,684
12	0,458	0,532	0,612	0,661
13	0,441	0,514	0,592	0,641
14	0,426	0,497	0,574	0,623
15	0,412	0,482	0,558	0,606

Espera e satisfação: valores críticos

Com 10 pessoas, temos gl = 8. Para α = 0,05 bilateral:

Colunas: α unilateral / α bilateral

gl	0,05 / 0,10	0,025 / 0,05	0,01 / 0,02	0,005 / 0,01
1	0,988	0,997	0,9995	0,9999
2	0,900	0,950	0,980	0,990
3	0,805	0,878	0,934	0,959
4	0,729	0,811	0,882	0,917
5	0,669	0,754	0,833	0,874
6	0,622	0,707	0,789	0,834
7	0,582	0,666	0,750	0,798
8	**0,549**	**0,632**	**0,716**	**0,765**
9	0,521	0,602	0,685	0,735
10	0,497	0,576	0,658	0,708

gl = 8

α = 0,05 bilateral

r crítico = ±0,632

Rejeitamos H_0 se:
$r < -0,632$ ou $r > 0,632$.

Passos do teste de hipóteses

5. Calcular a estatística do teste.

$$r = \frac{\text{Quantidade da variância comum}}{\text{Quantidade da variância total}}$$

- Variância comum: O que é “compartilhado” entre as duas variáveis
  - O que os faz "ir juntos" (se eles forem)
- Variância total: Toda a variância em nossas variáveis

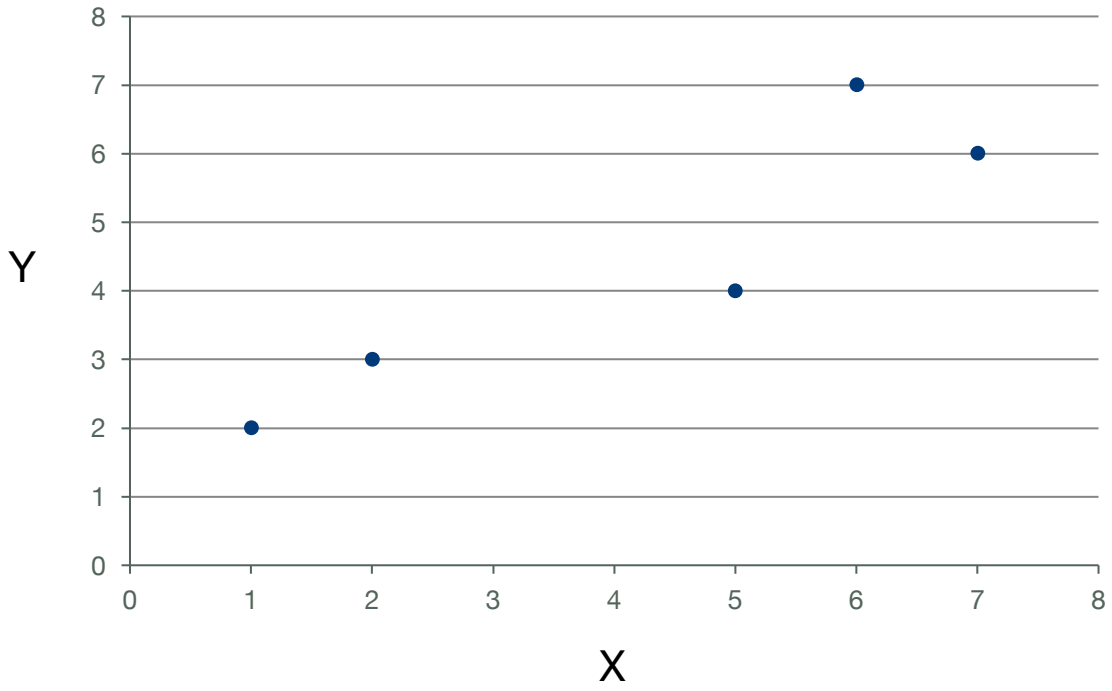
Calculando r

- O nosso velho amigo, o desvio!
  - (ESCORE – MÉDIA)
- Mas agora temos dois desvios por pontuação bruta
  - $X - M_X$
  - $Y - M_Y$

Pessoa	X	Y
A	1	2
B	2	3
C	5	4
D	6	7
E	7	6
	M = 4.2	M = 4.4

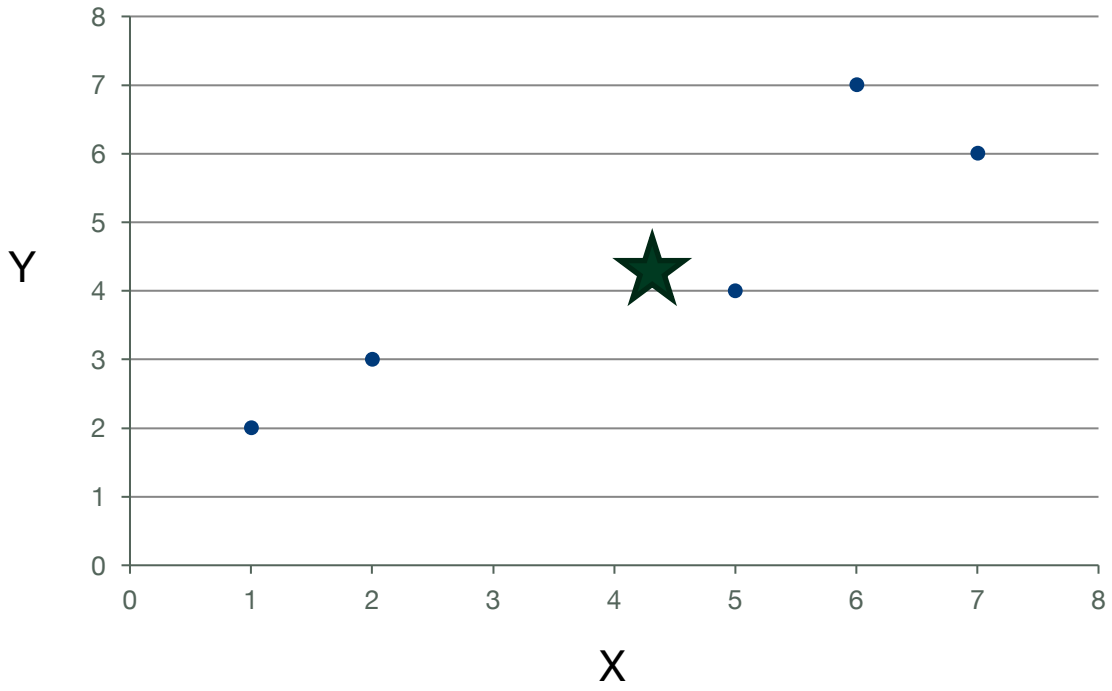
Calculando r

- Visualizando desvios conjuntos em correlação positiva



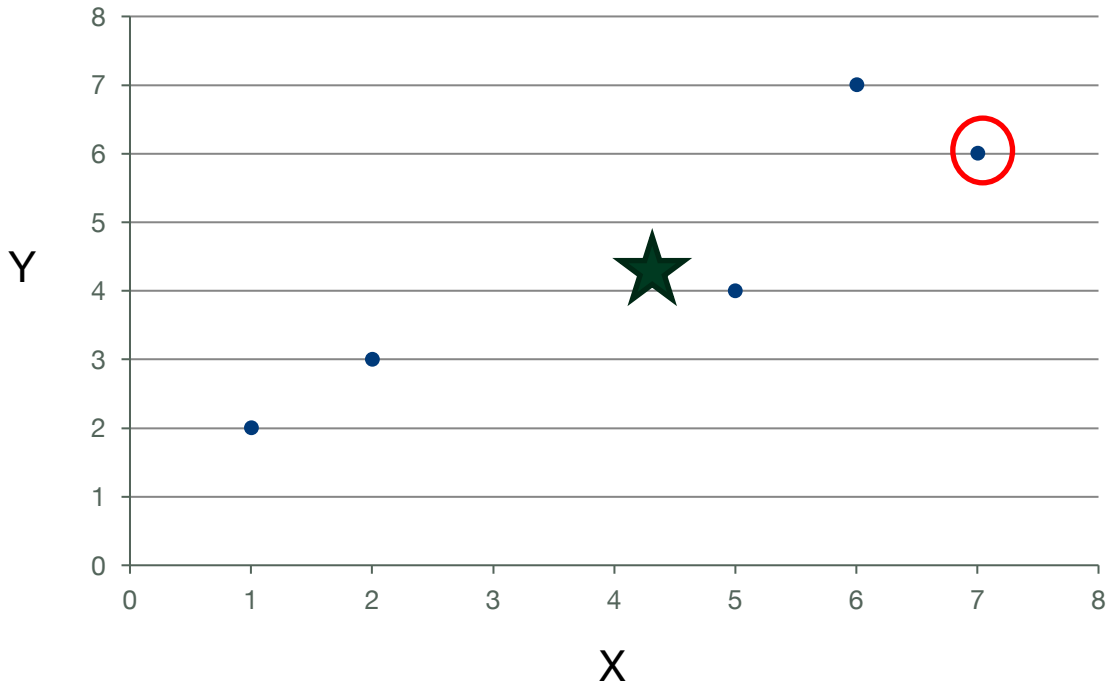
Calculando r

- Visualizando desvios conjuntos em correlação positiva



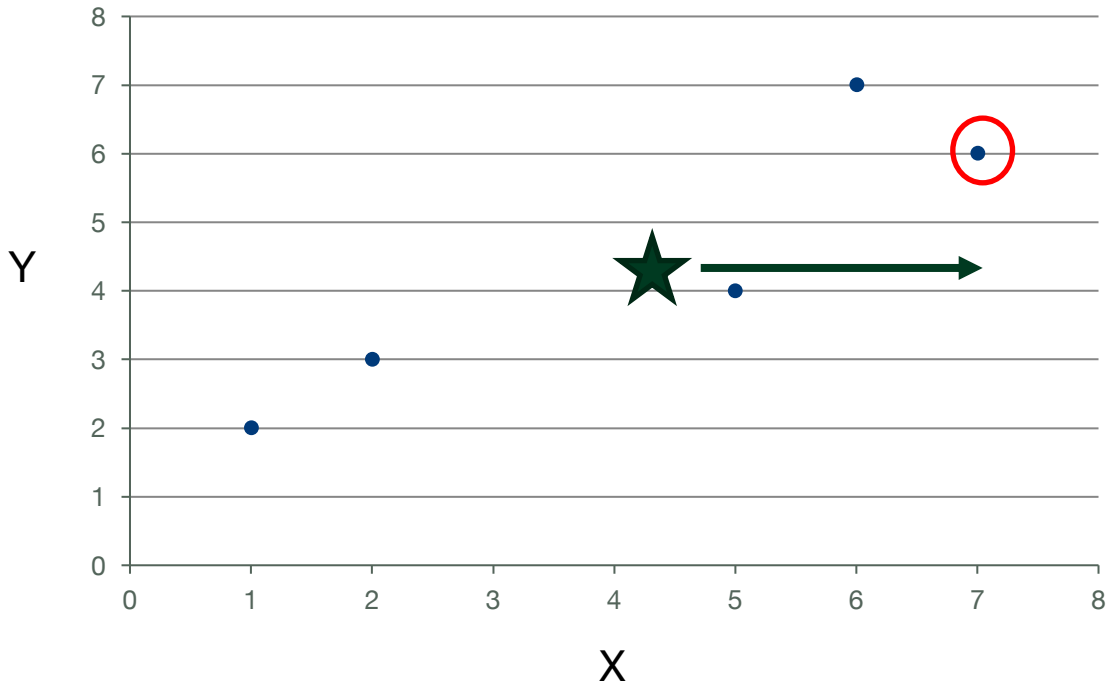
Calculando r

- Visualizando desvios conjuntos em correlação positiva



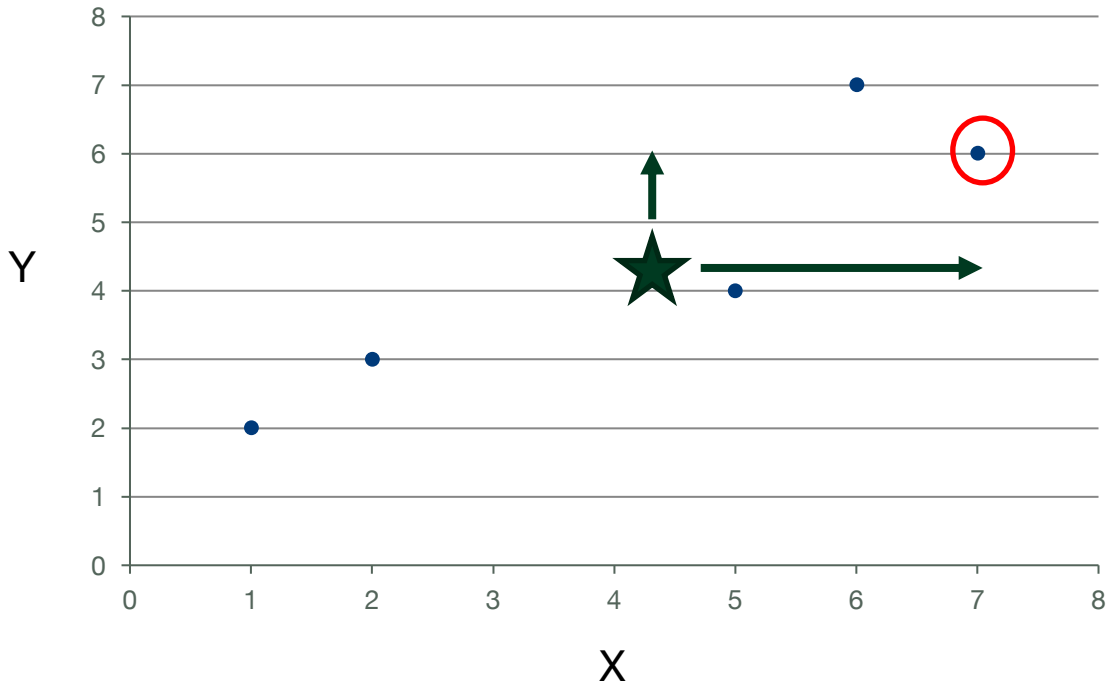
Calculando r

- Visualizando desvios conjuntos em correlação positiva



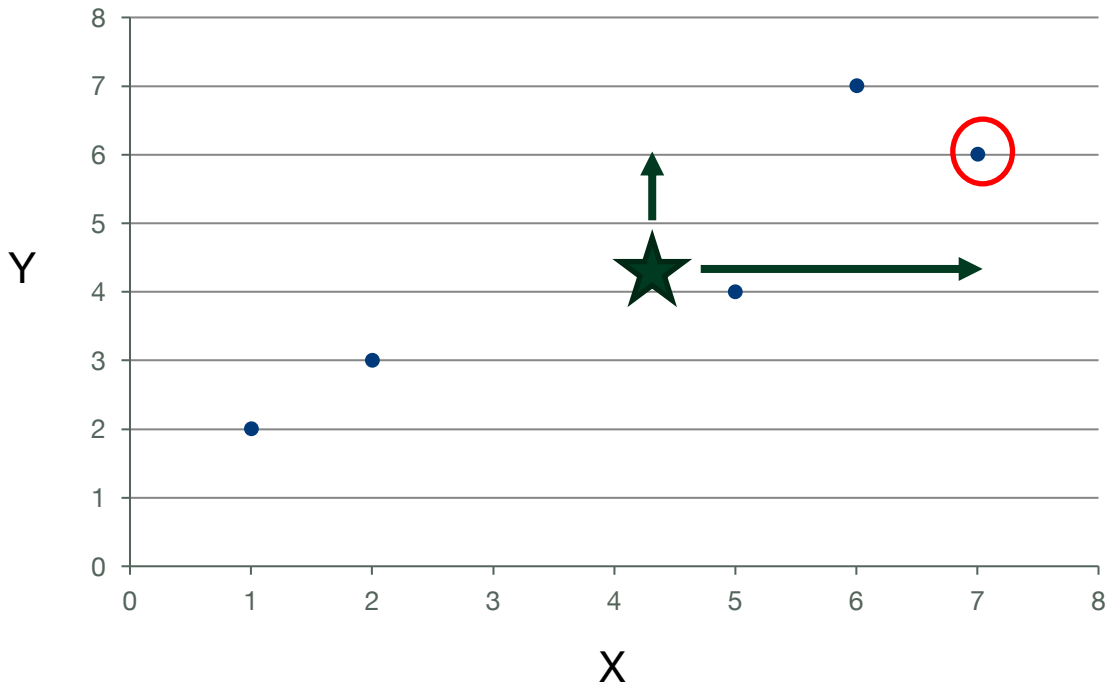
Calculando r

- Visualizando desvios conjuntos em correlação positiva



Calculando r

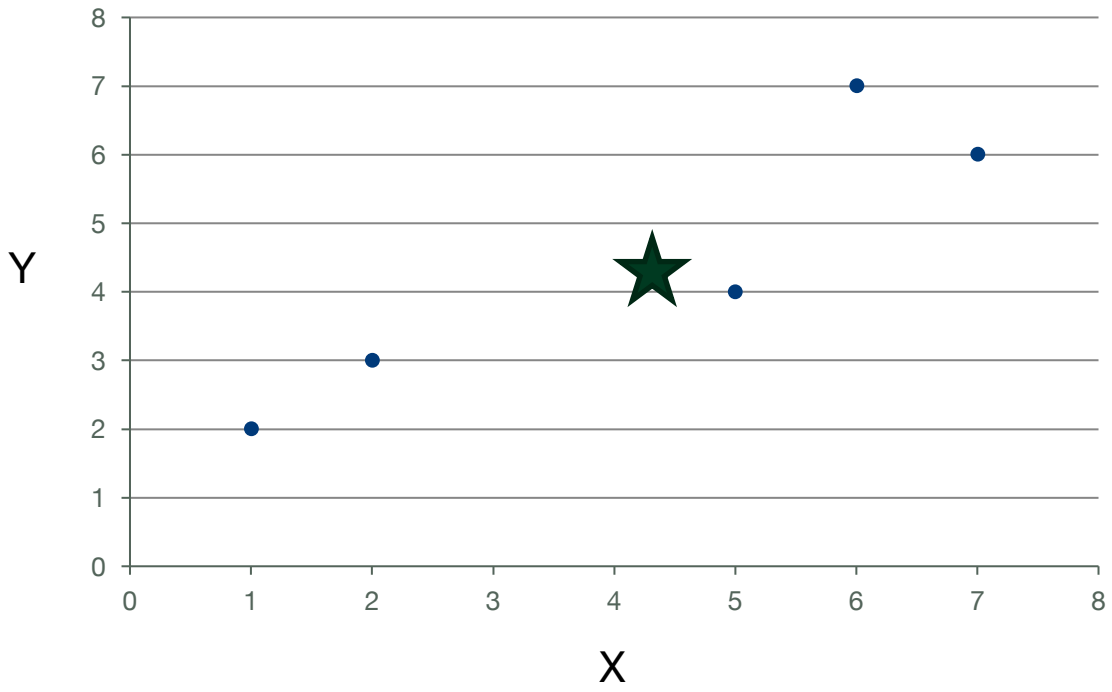
- Visualizando desvios conjuntos em correlação positiva



Ambos os desvios são positivos
(7-4.2) & (6-4.4)

Calculando r

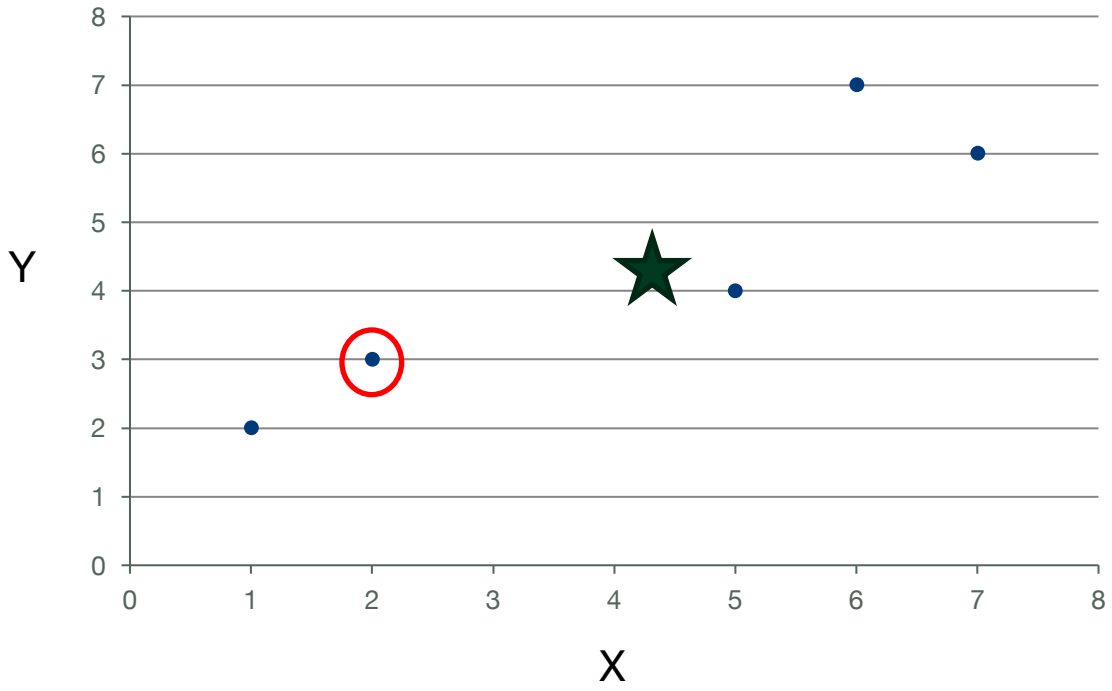
- Visualizando desvios conjuntos em correlação positiva



Ambos os desvios são positivos (7-4.2) & (6-4.4)

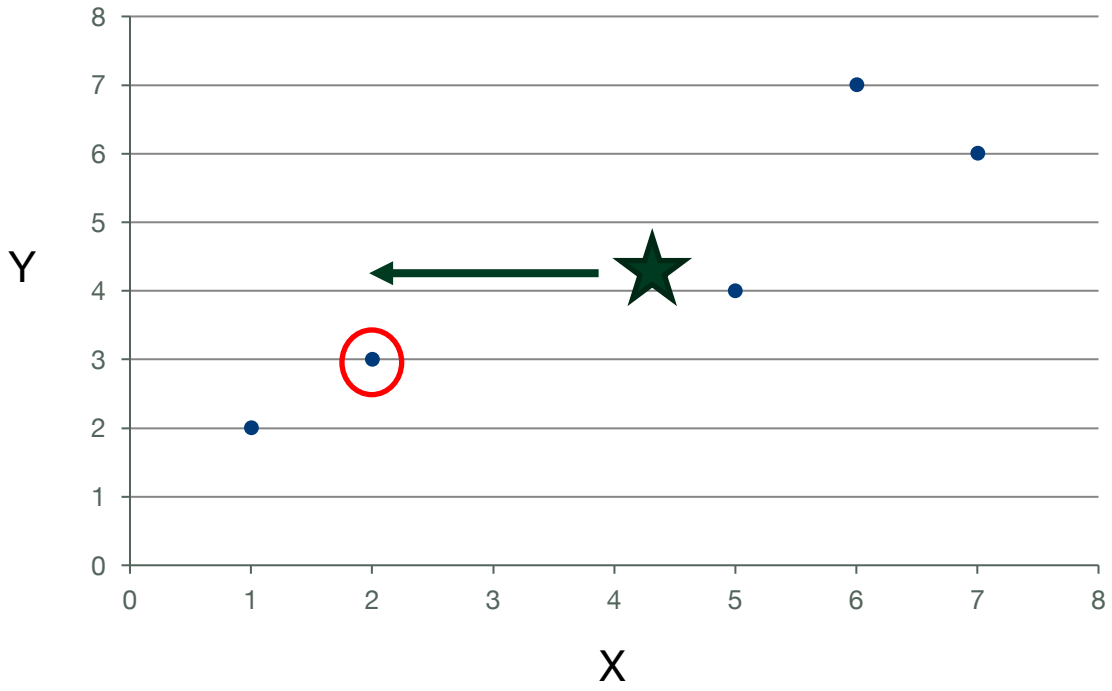
Calculando r

- Visualizando desvios conjuntos em correlação positiva



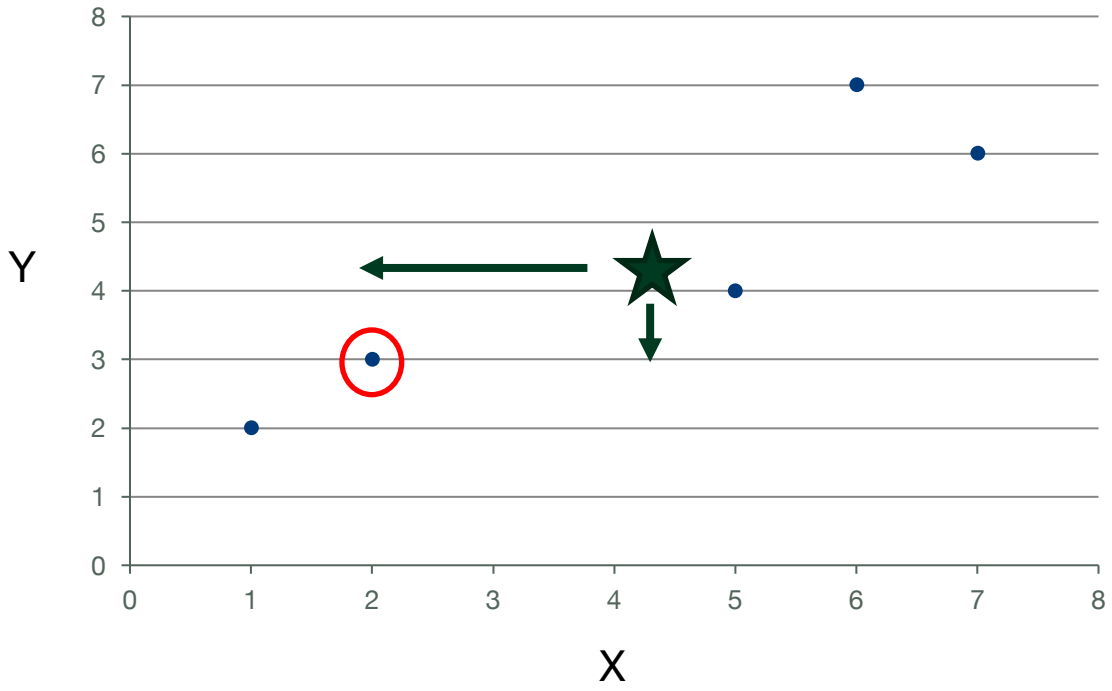
Calculando r

- Visualizando desvios conjuntos em correlação positiva



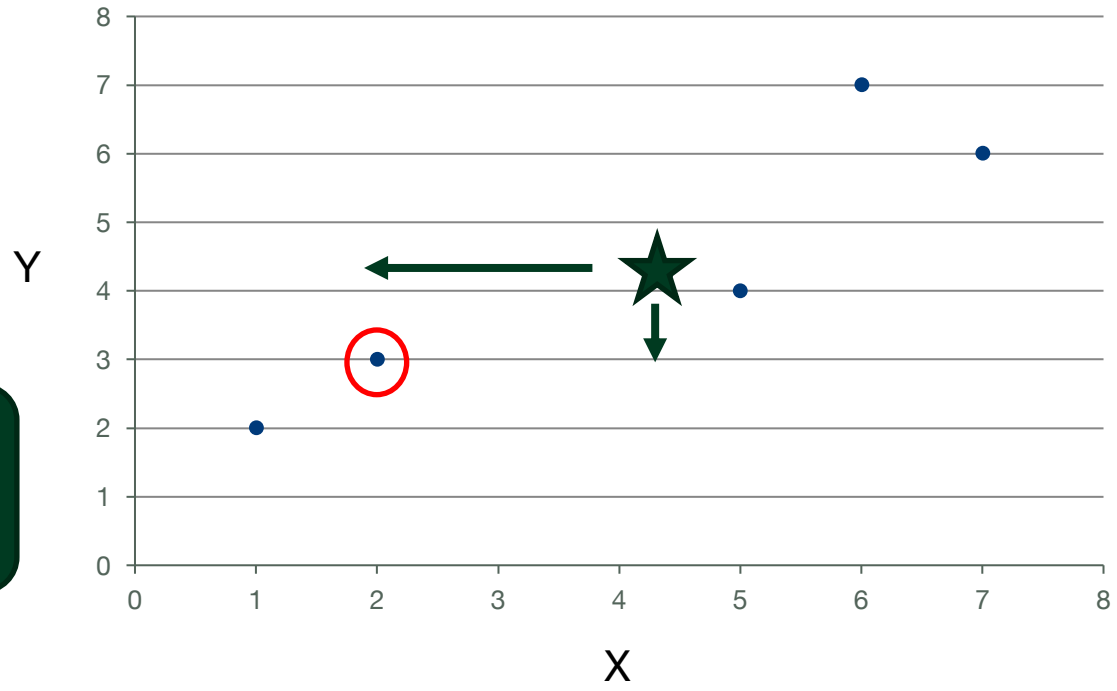
Calculando r

- Visualizando desvios conjuntos em correlação positiva



Calculando r

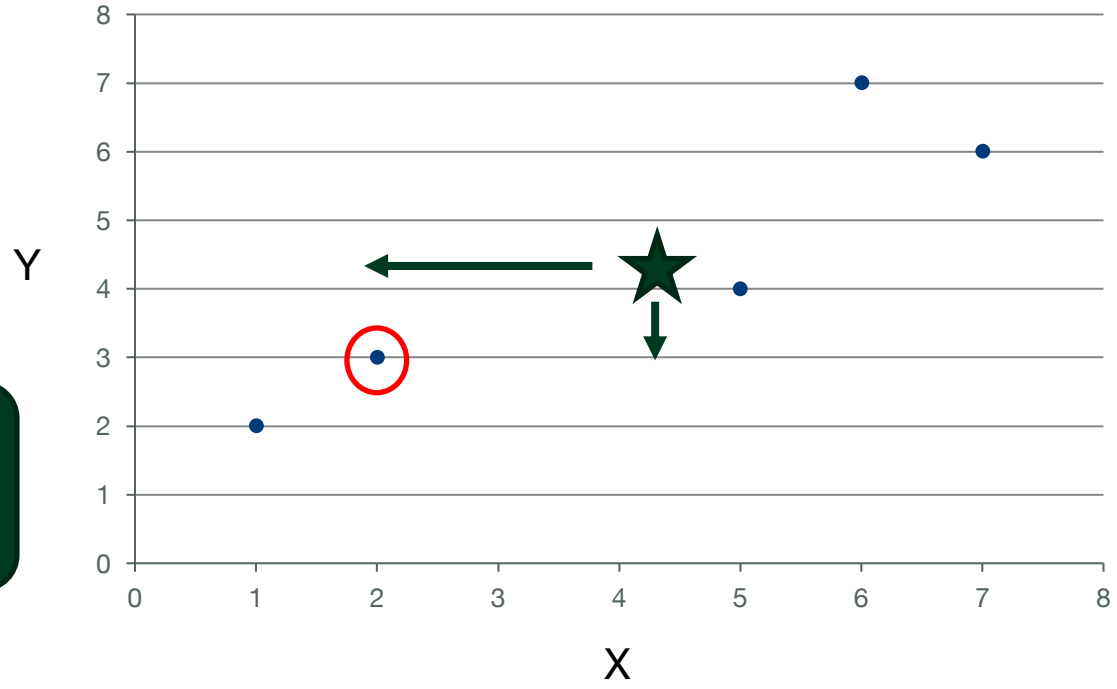
- Visualizando desvios conjuntos em correlação positiva



Ambos os desvios são negativos (2-4.2) & (3-4.4)

Calculando r

- Visualizando desvios conjuntos em correlação positiva



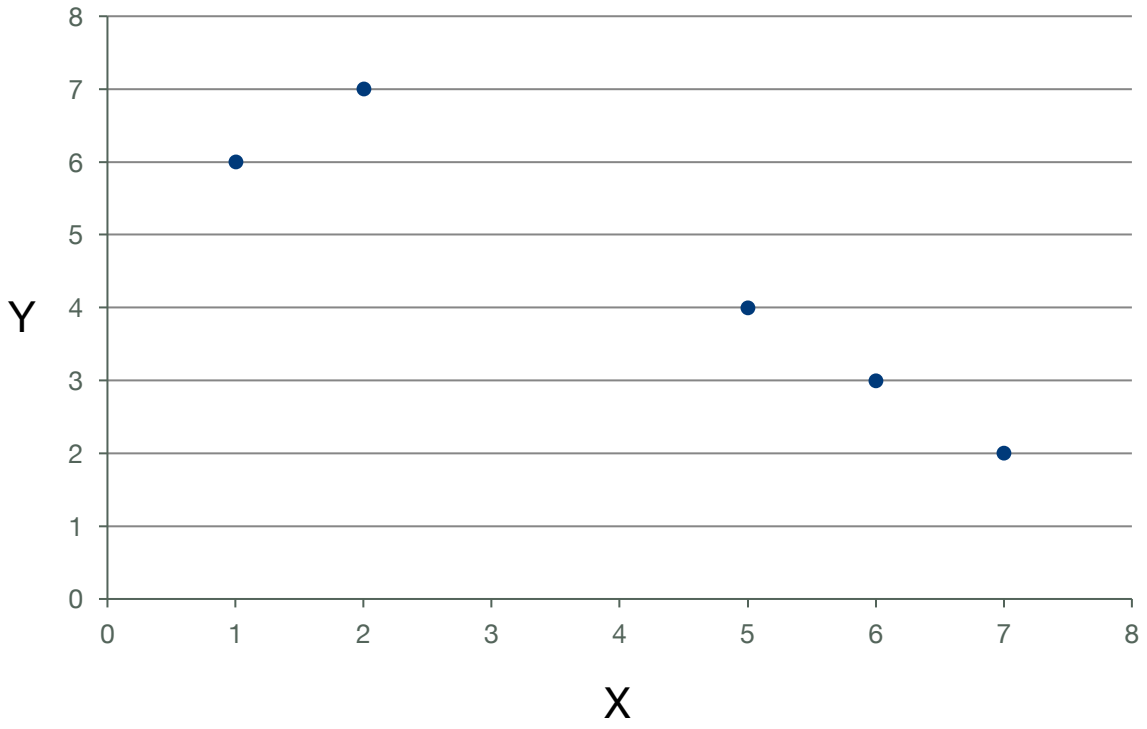
Ambos os desvios são negativos (2-4.2) & (3-4.4)

Para correlações positivas:

Os dois desvios tendem a ter o mesmo sinal:
ambos negativos ou ambos positivos.

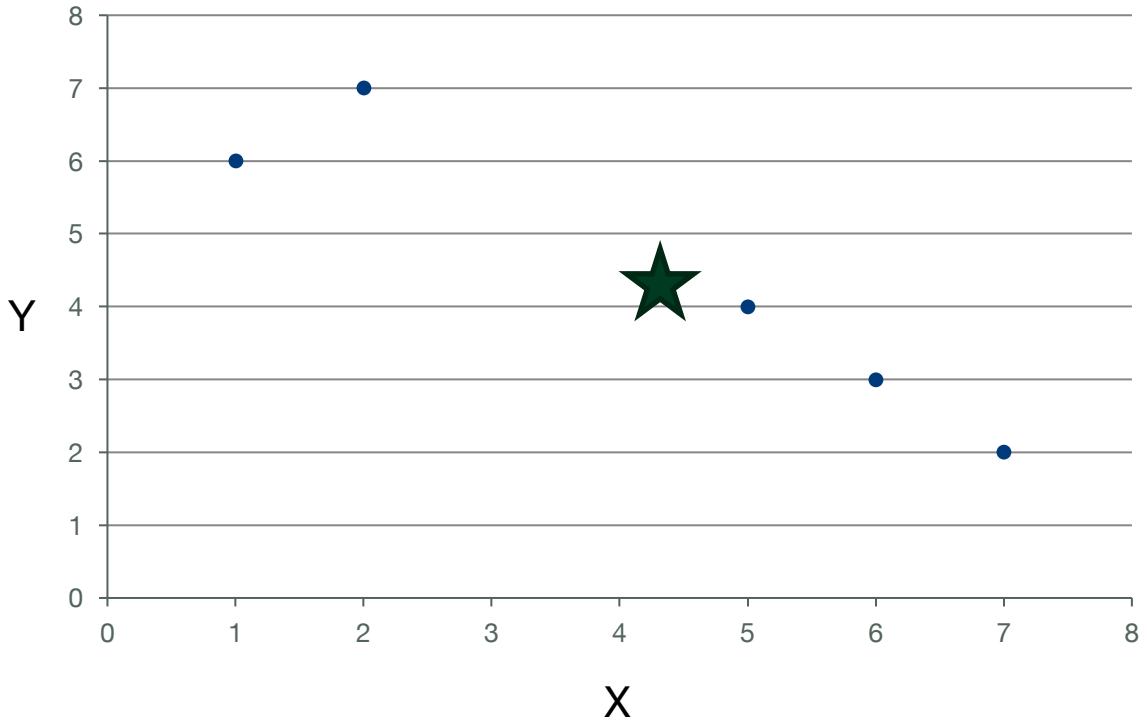
Calculando r

- Visualizando desvios conjuntos em correlação negativa



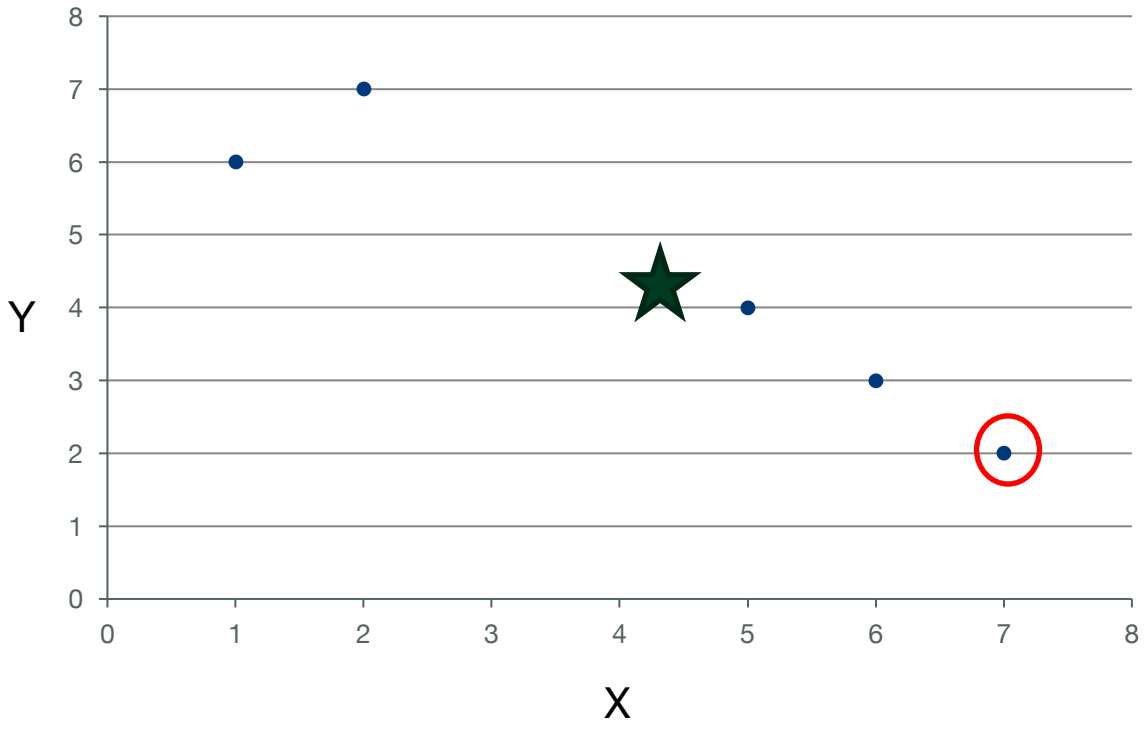
Calculando r

- Visualizando desvios conjuntos em correlação negativa



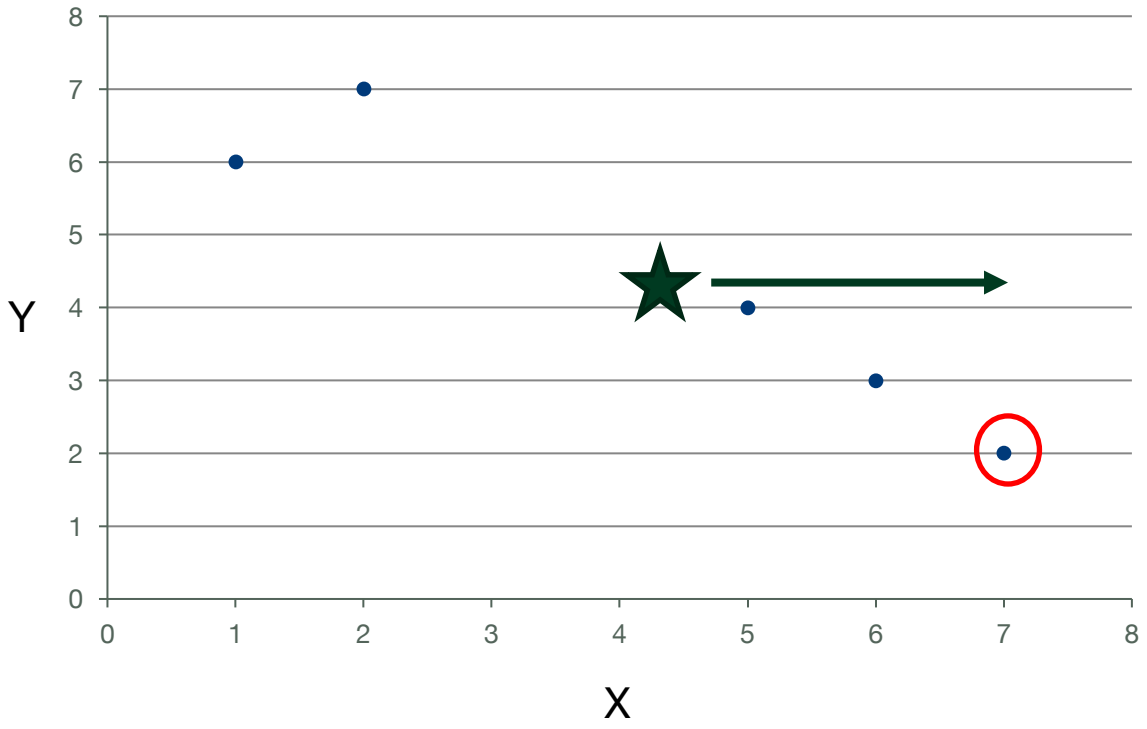
Calculando r

- Visualizando desvios conjuntos em correlação negativa



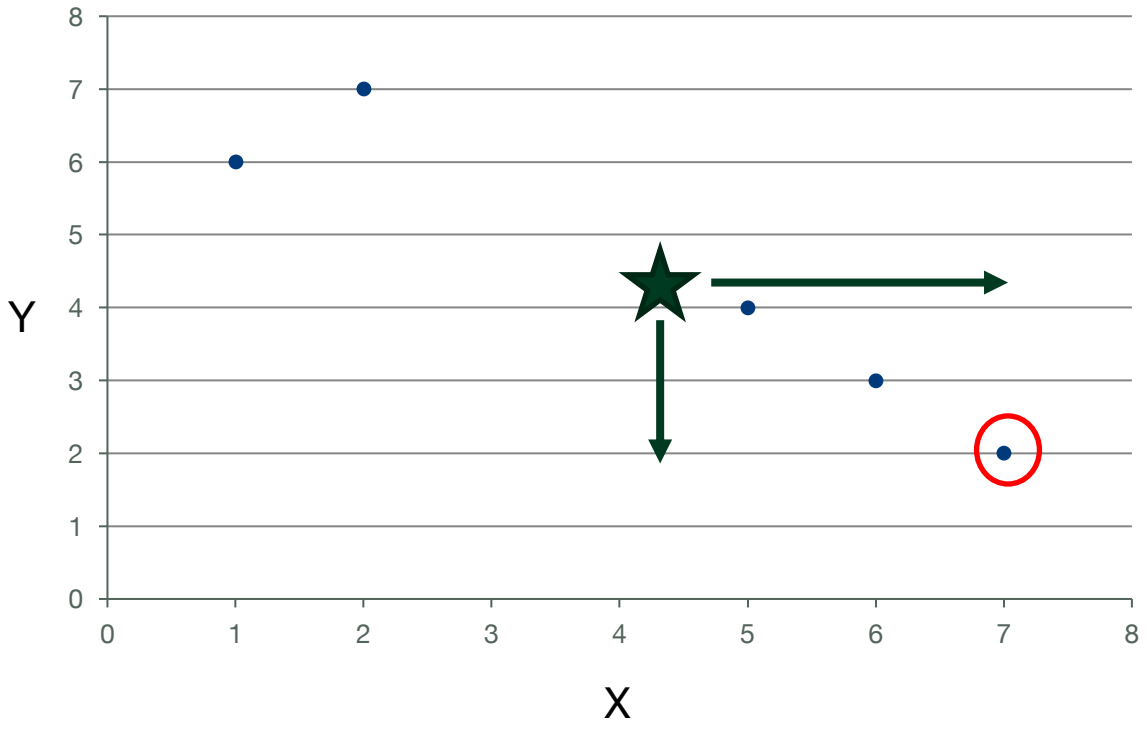
Calculando r

- Visualizando desvios conjuntos em correlação negativa



Calculando r

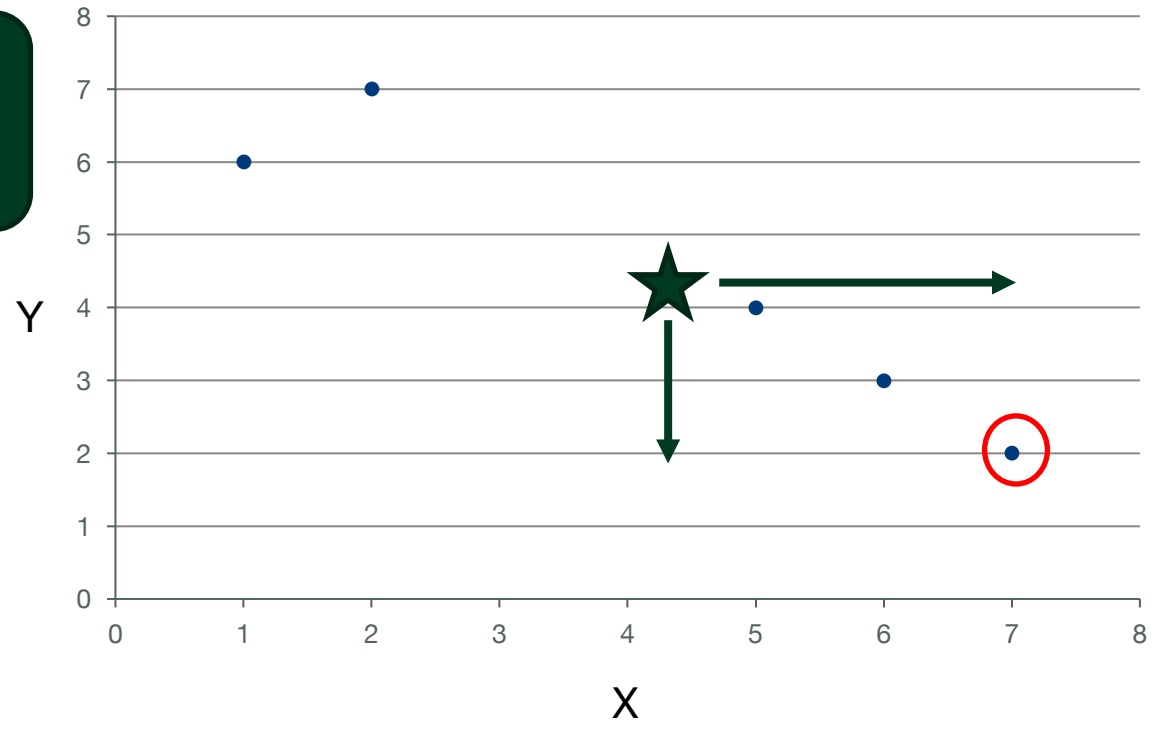
- Visualizando desvios conjuntos em correlação negativa



Calculando r

- Visualizando desvios conjuntos em correlação negativa

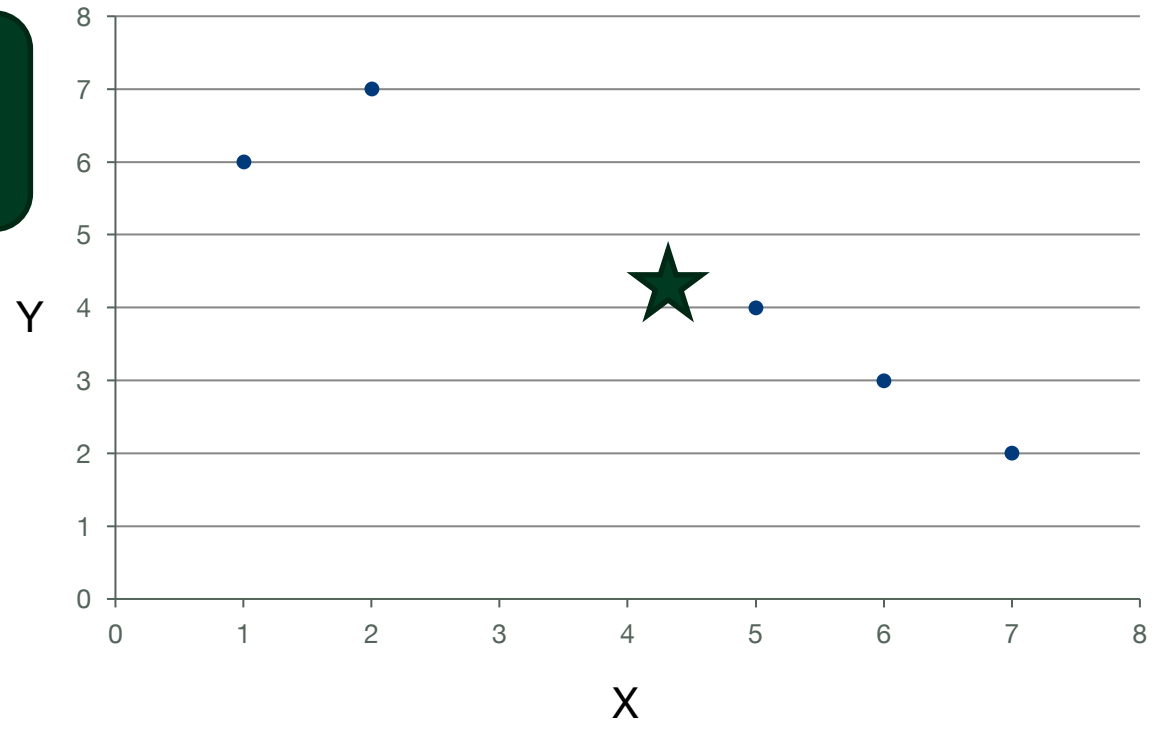
Um desvio pos, um desvio neg (2-4.2) & (7-4.4)



Calculando r

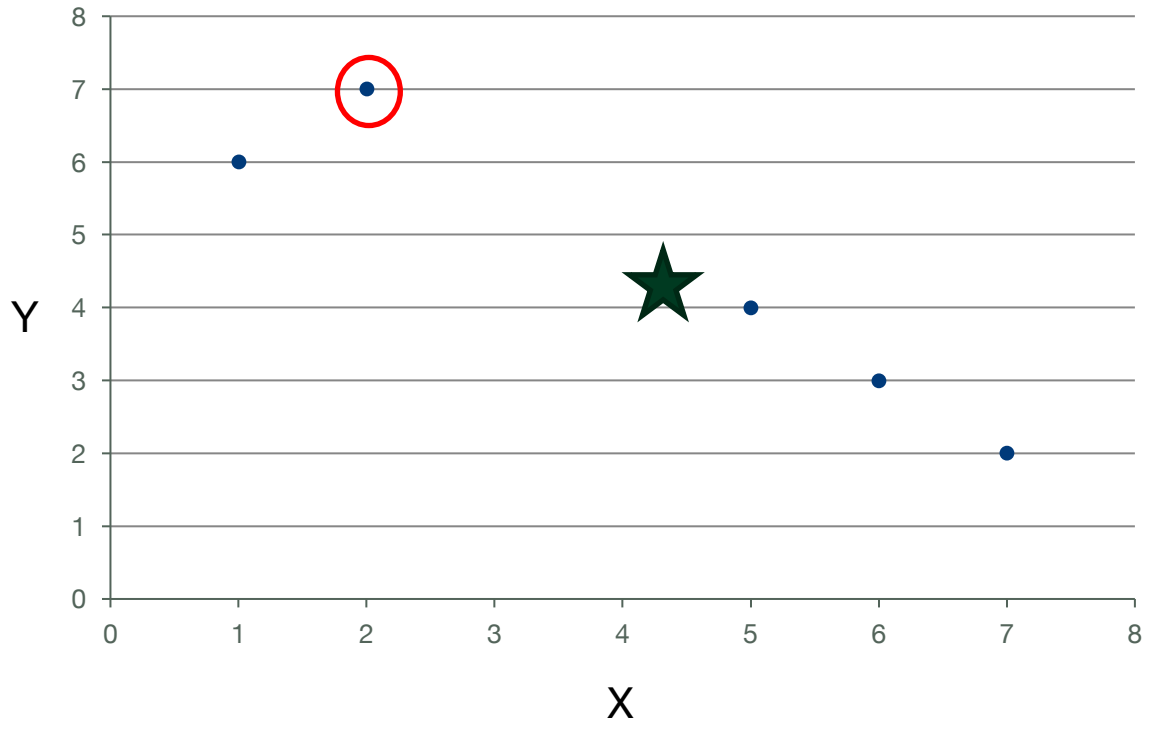
- Visualizando desvios conjuntos em correlação negativa

Um desvio pos, um desvio neg (2-4.2) & (7-4.4)



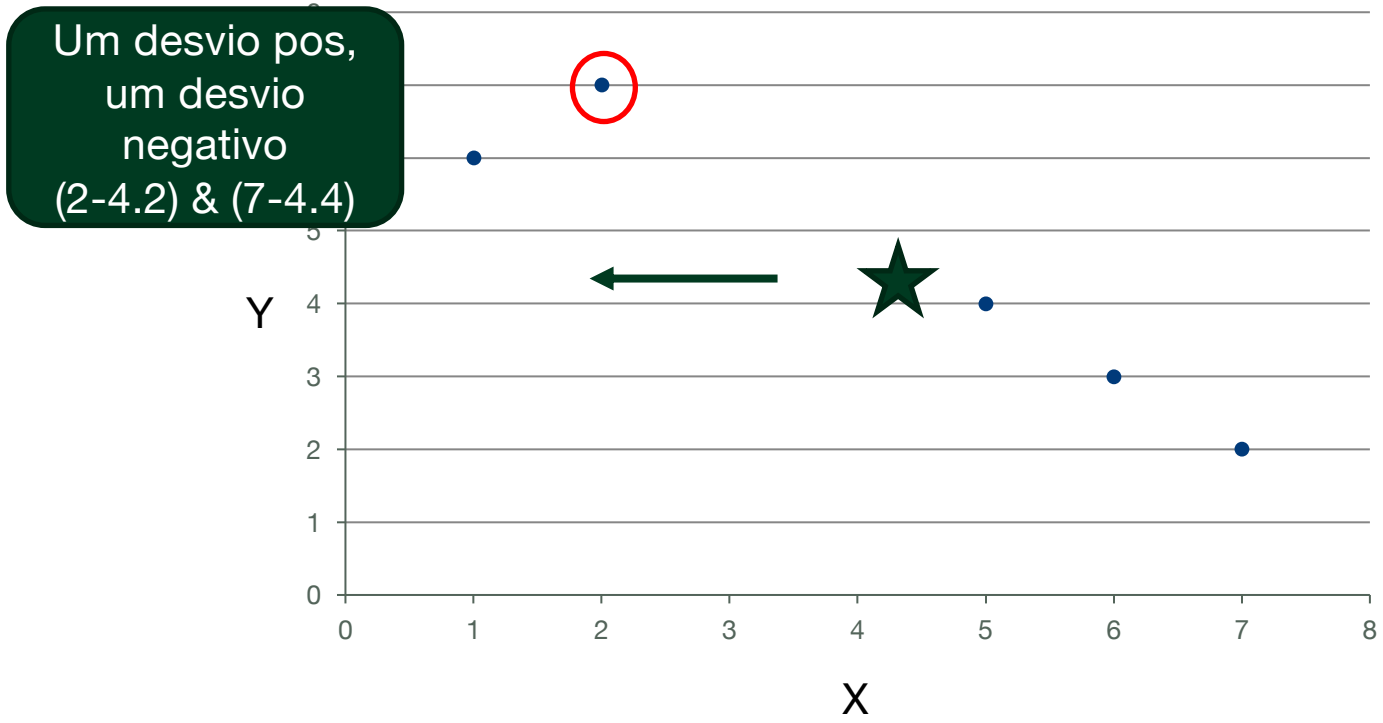
Calculando r

- Visualizando desvios conjuntos em correlação negativa



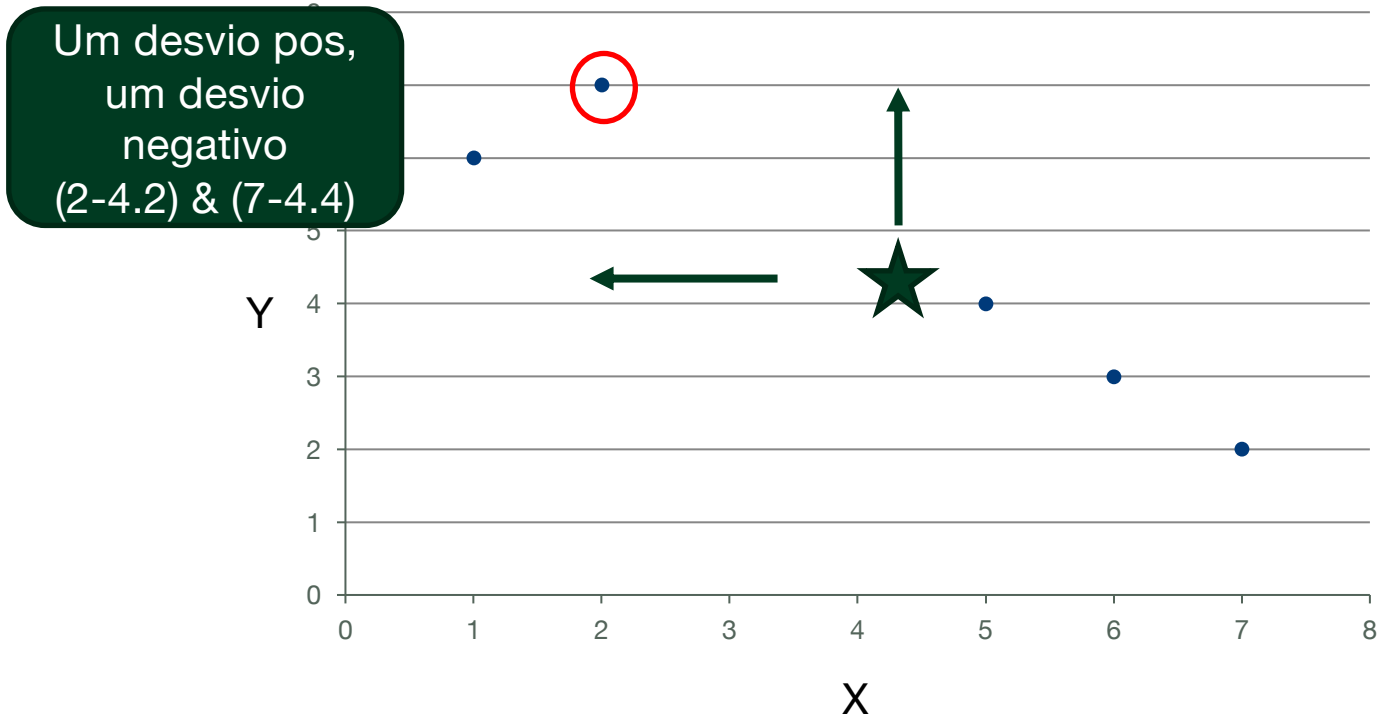
Calculando r

- Visualizando desvios conjuntos em correlação negativa



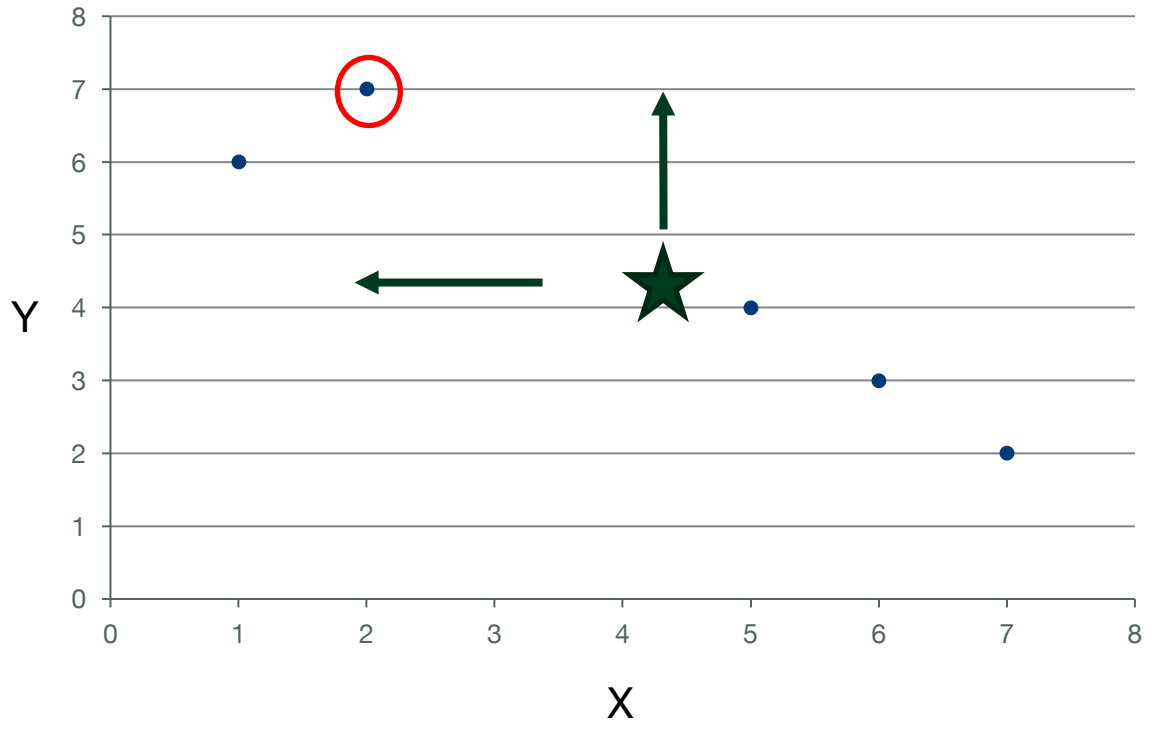
Calculando r

- Visualizando desvios conjuntos em correlação negativa



Calculando r

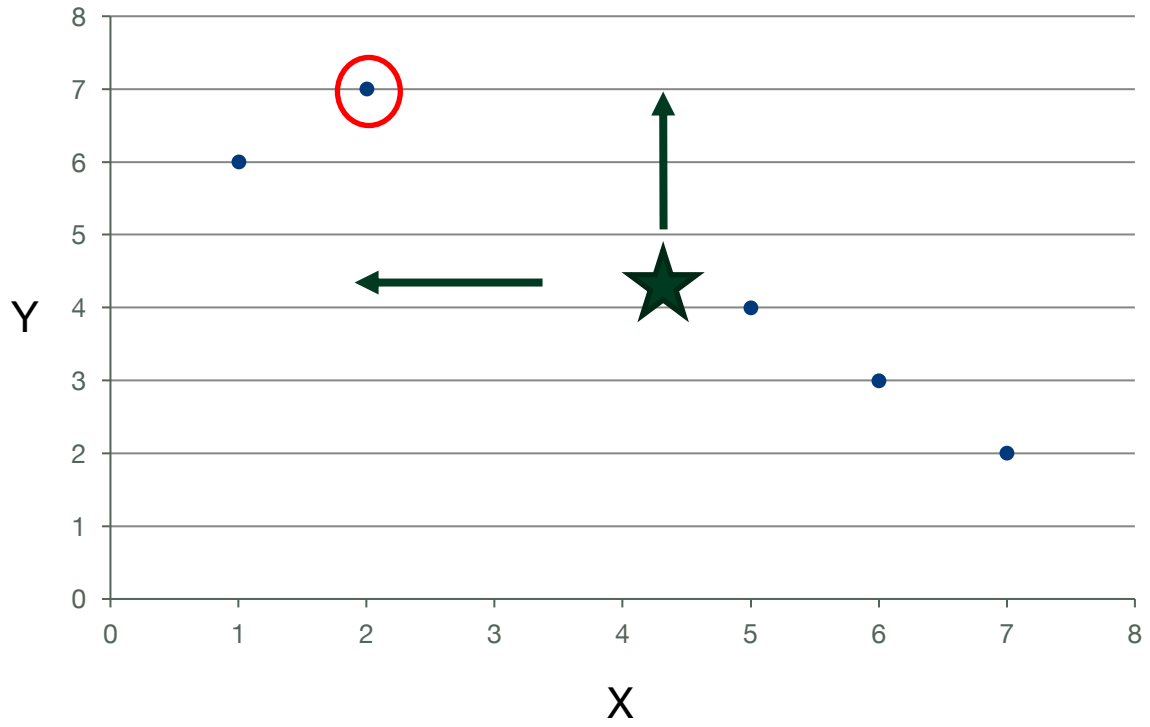
- Visualizando desvios conjuntos em correlação negativa



Um desvio pos, um desvio neg (7-4.2) & (2-4.4)

Calculando r

- Visualizando desvios conjuntos em correlação negativa



Um desvio pos, um desvio neg (7-4.2) & (2-4.4)

Para as correlações negativas:
Os dois desvios terão (geralmente) sinais opostos

Calculando o coeficiente de correlação: r

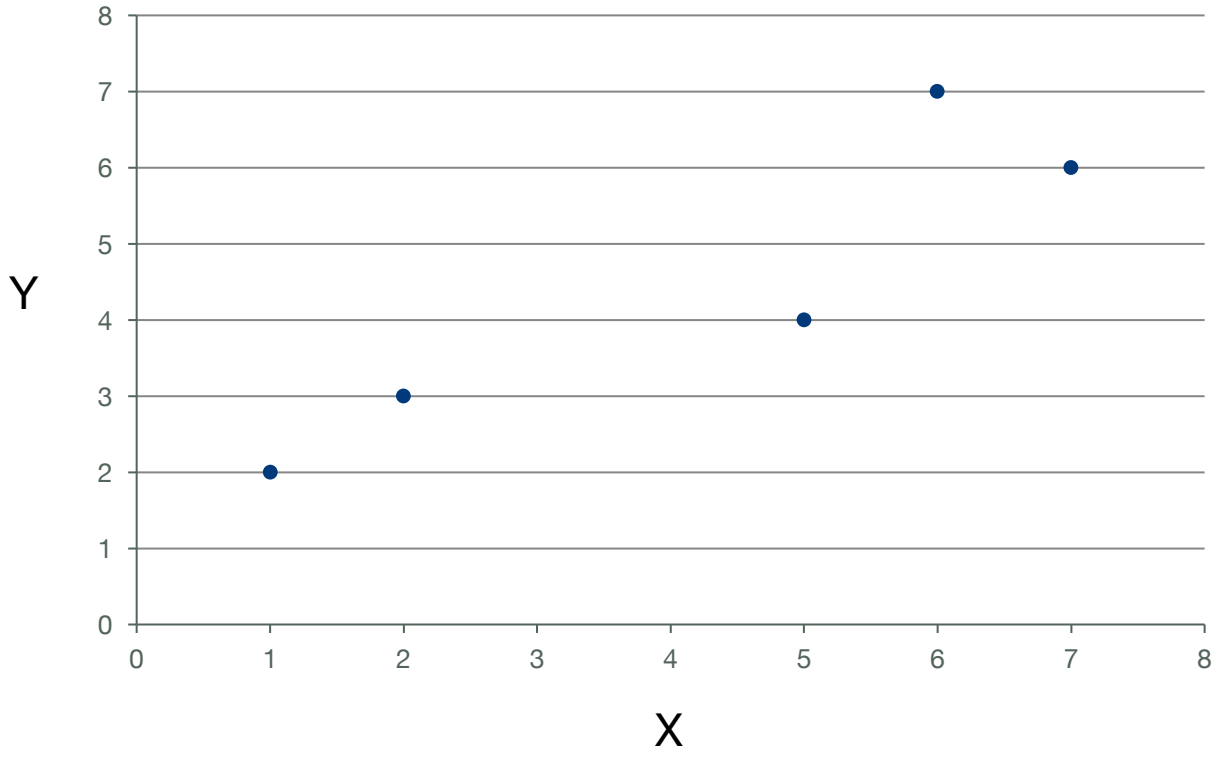
- O numerador de r é o somatório dos produtos dos desvios: SP

$$SP = \Sigma[(X - M_x)*(Y - M_y)]$$

- Criado multiplicando os dois desvios e depois somando
- As correlações positivas terão produtos positivos
  - + vezes + é +
  - - vezes - é +
- Correlações negativas terão produtos negativos
  - + vezes - é –

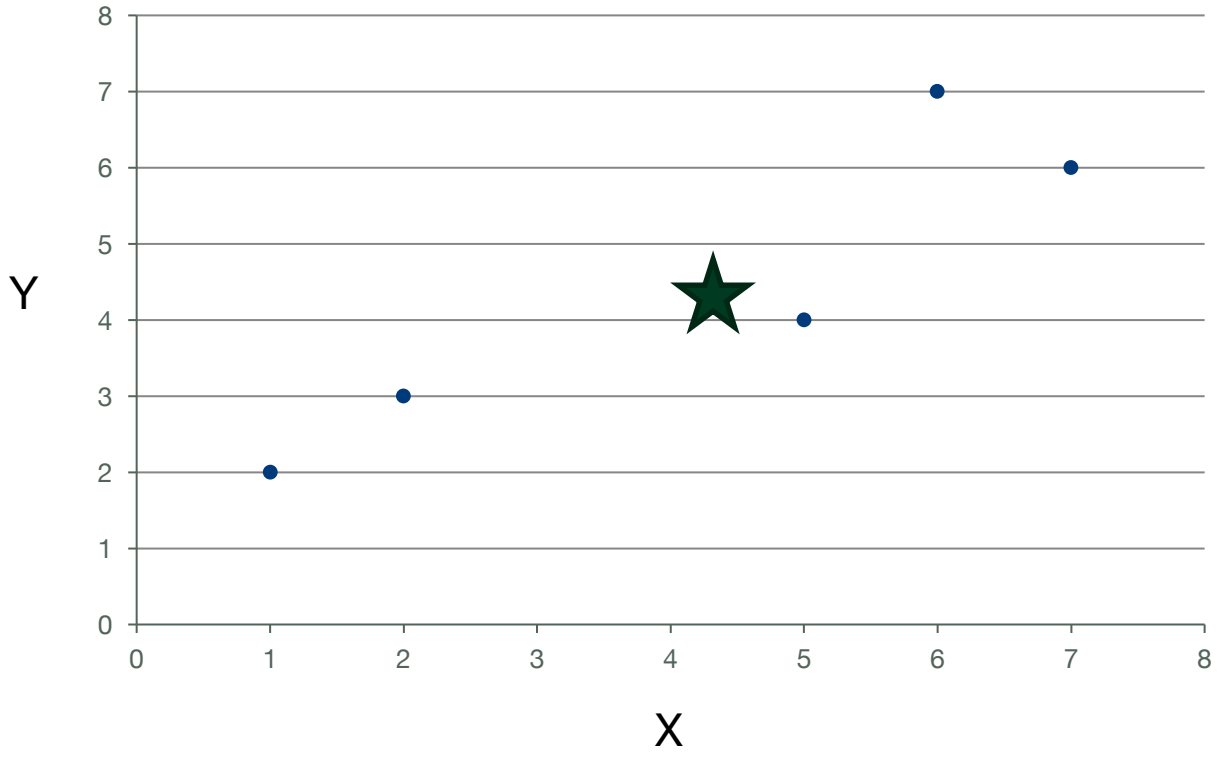
Calculando r

- Os produtos também refletem a força da correlação



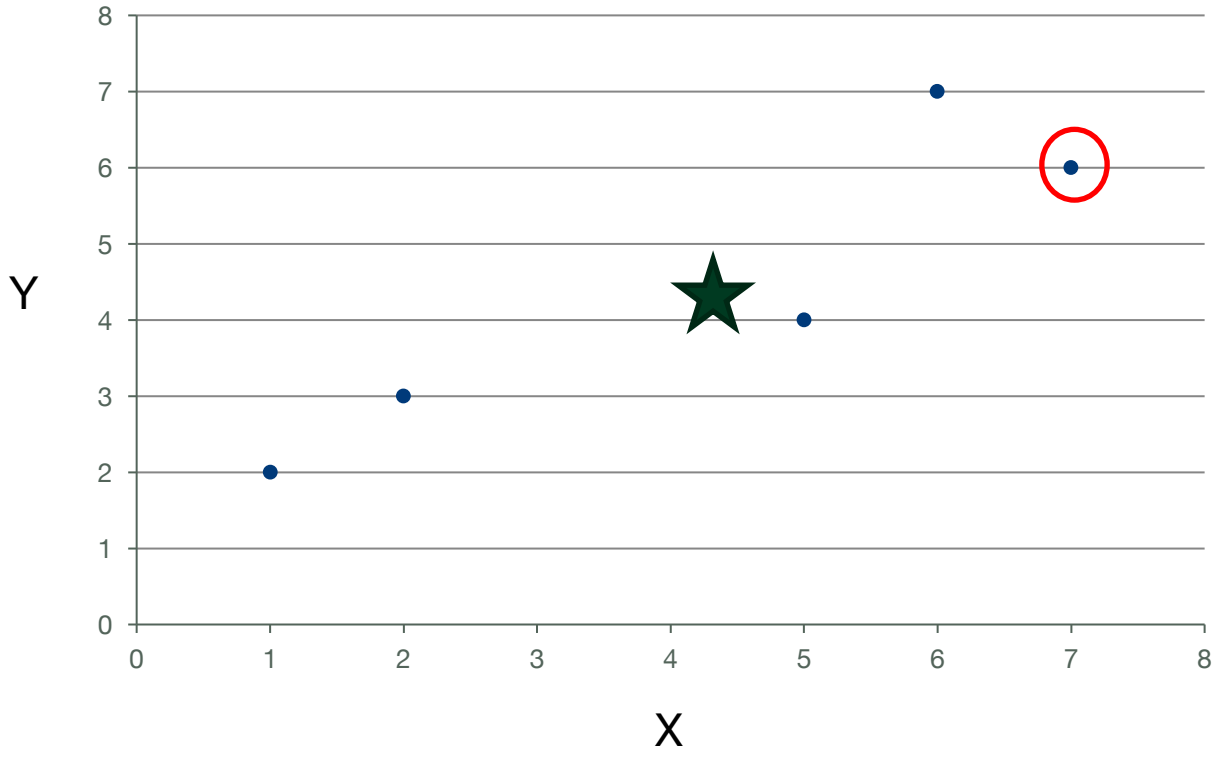
Calculando r

- Os produtos também refletem a força da correlação



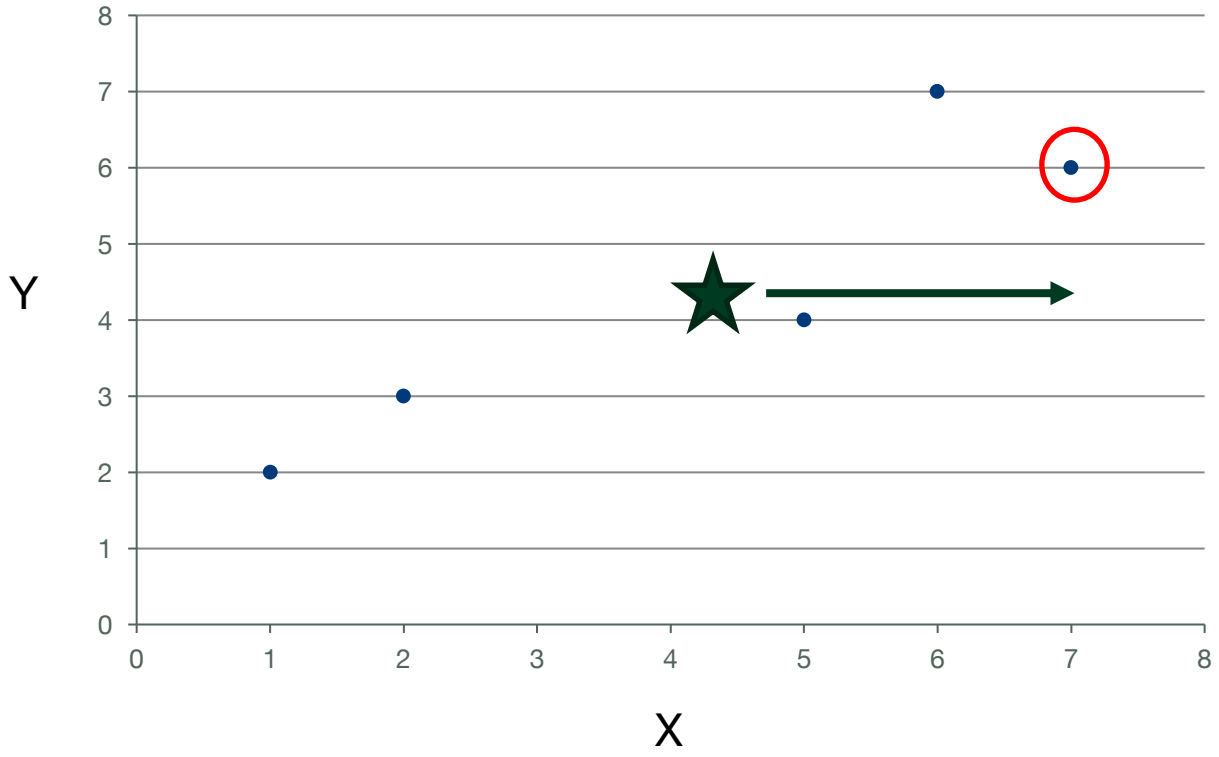
Calculando r

- Os produtos também refletem a força da correlação



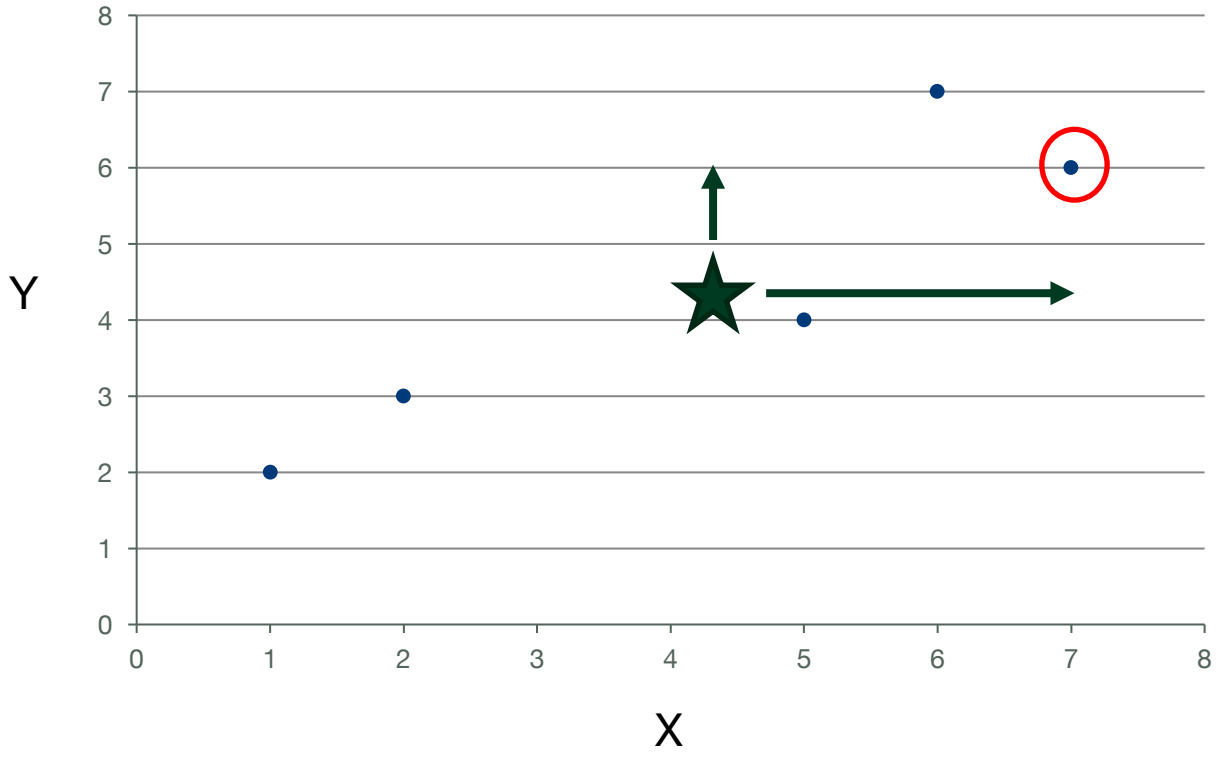
Calculando r

- Os produtos também refletem a força da correlação



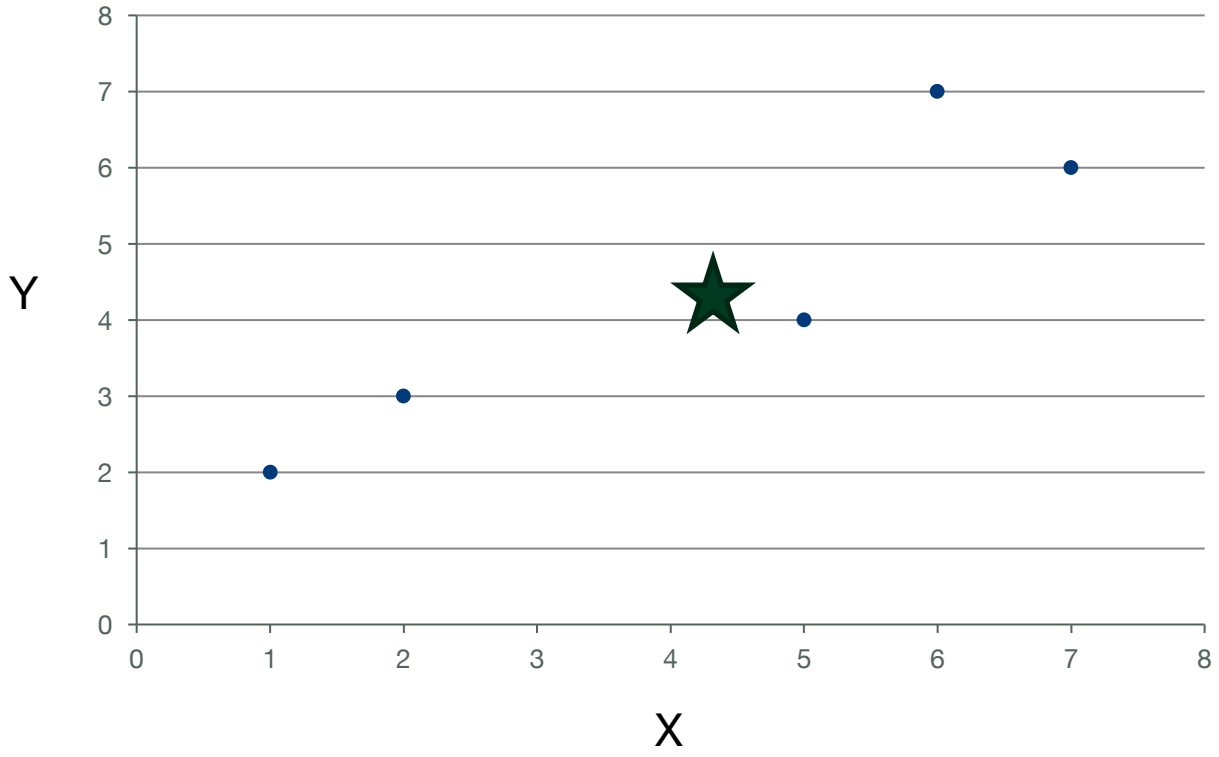
Calculando r

- Os produtos também refletem a força da correlação



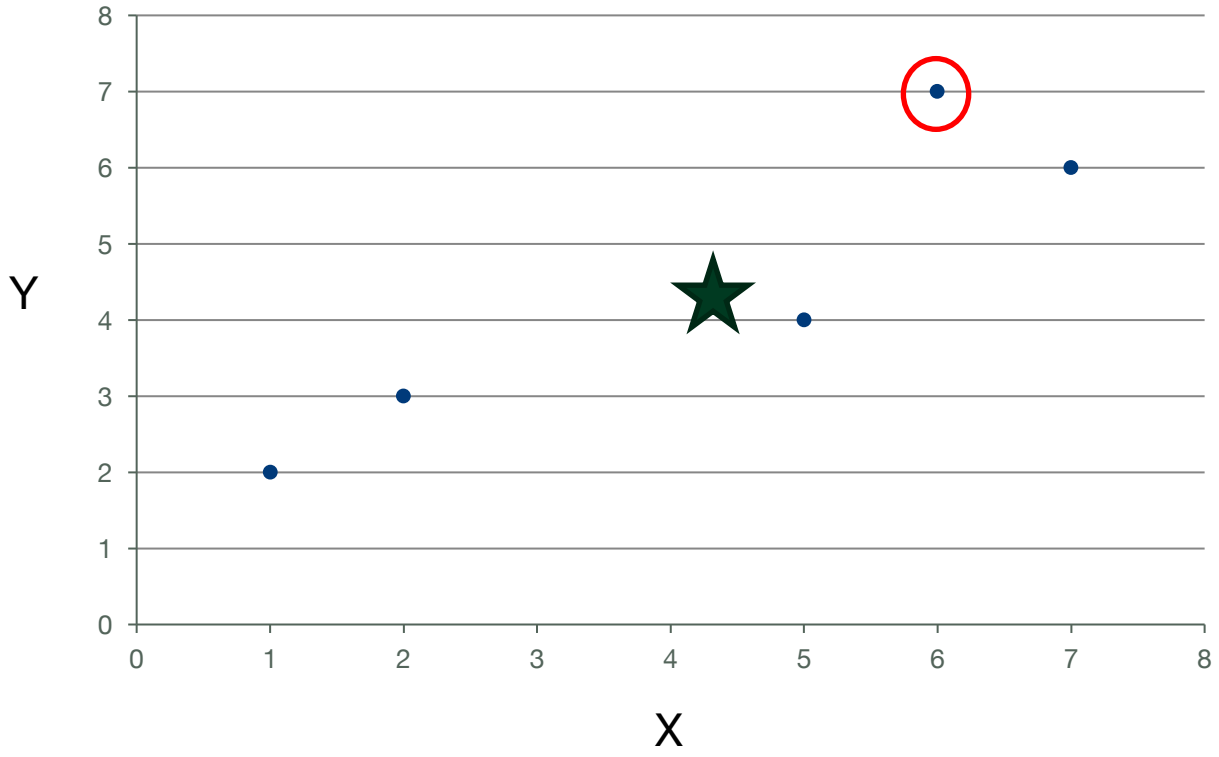
Calculando r

- Os produtos também refletem a força da correlação



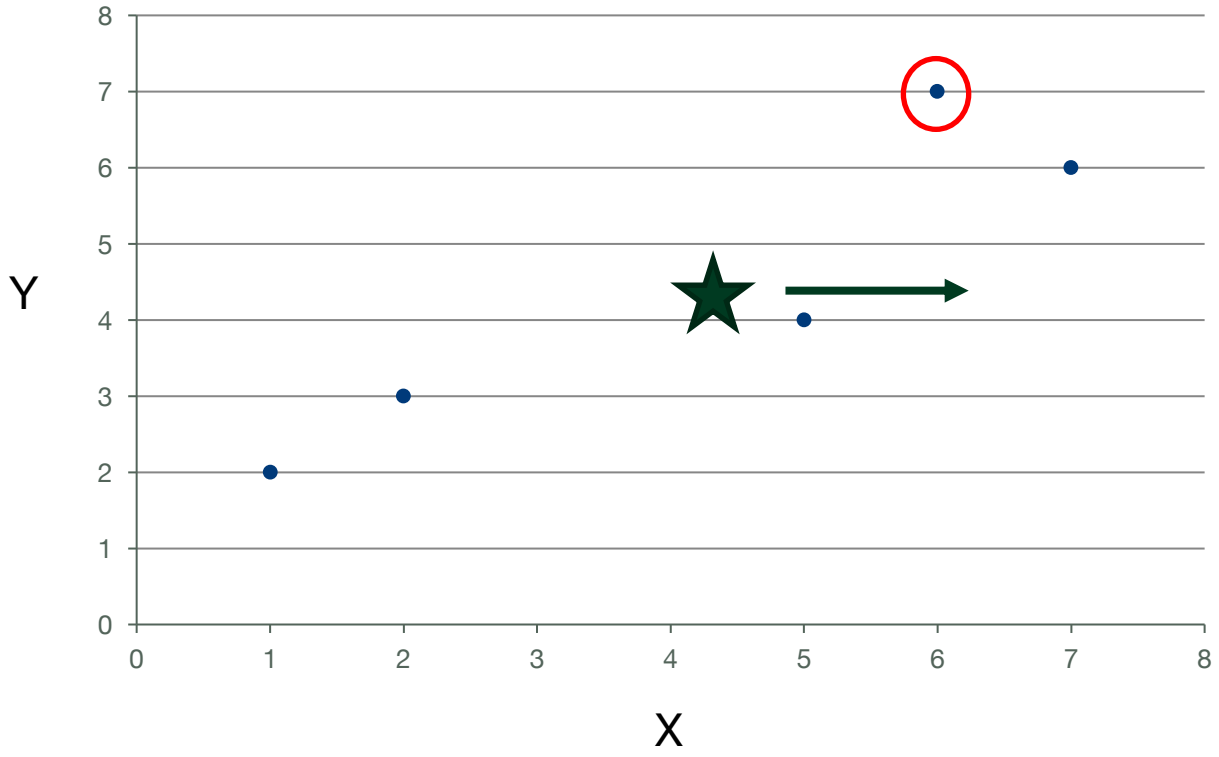
Calculando r

- Os produtos também refletem a força da correlação



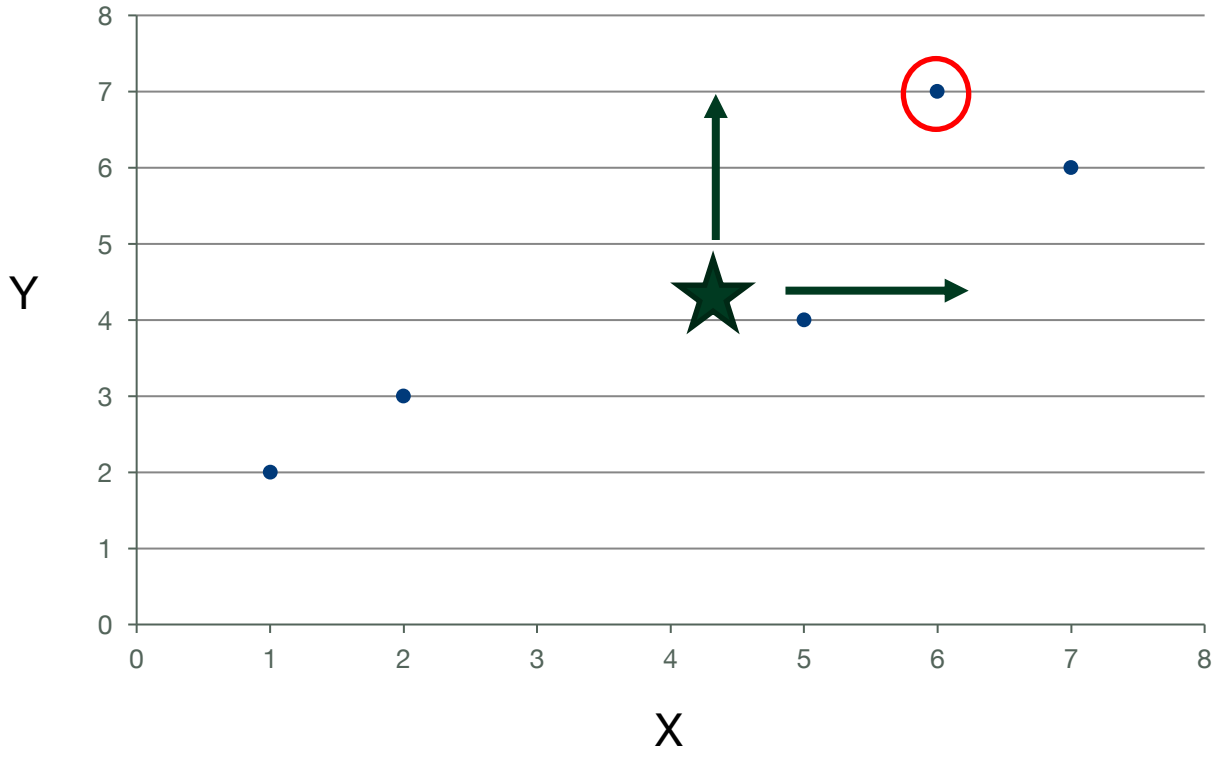
Calculando r

- Os produtos também refletem a força da correlação



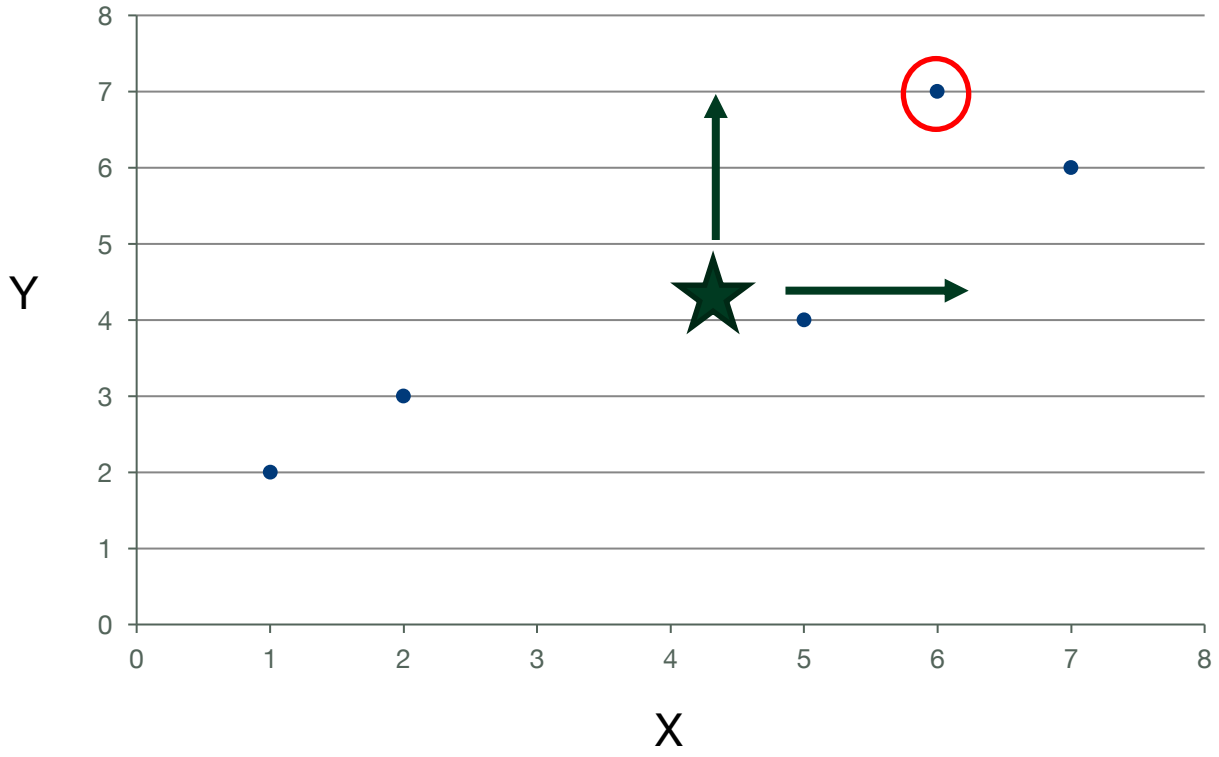
Calculando r

- Os produtos também refletem a força da correlação



Calculando r

- Os produtos também refletem a força da correlação

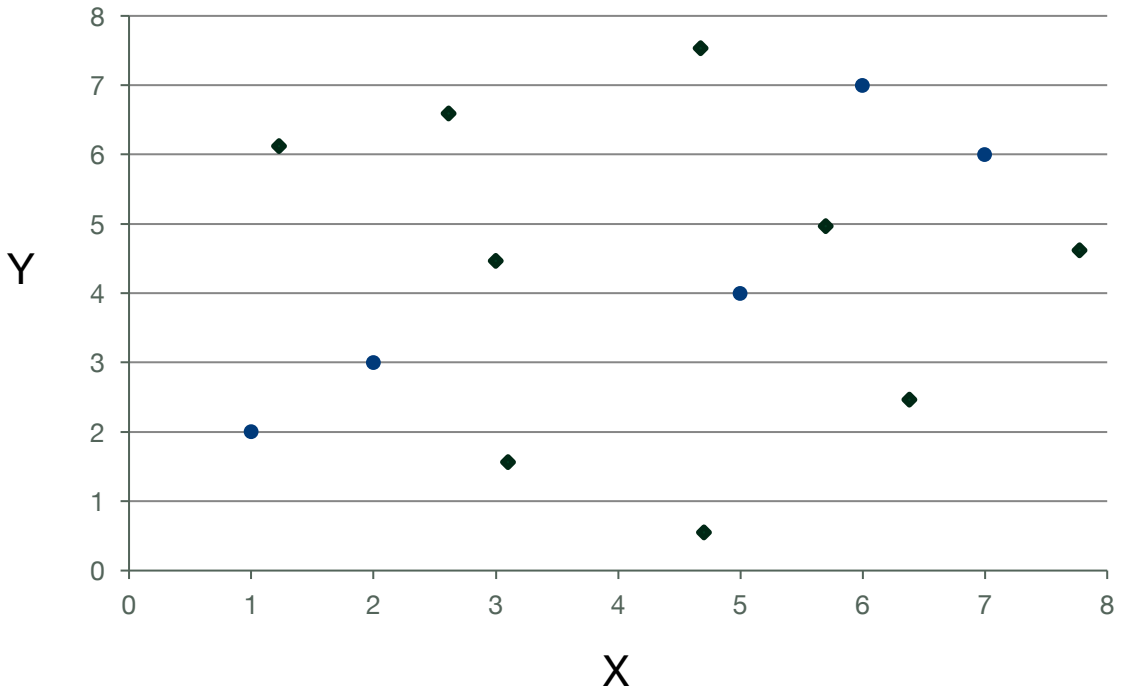


Para correlações fortes:

Quando um desvio é grande, o outro é grande

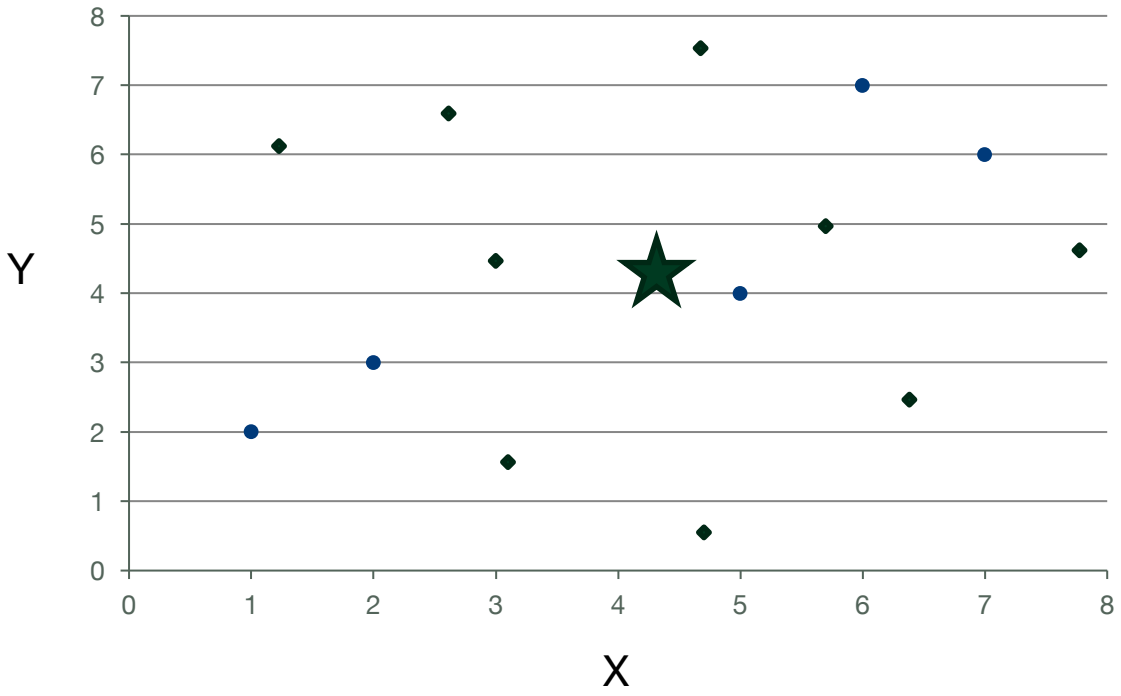
Calculando r

- Os produtos também refletem a força da correlação



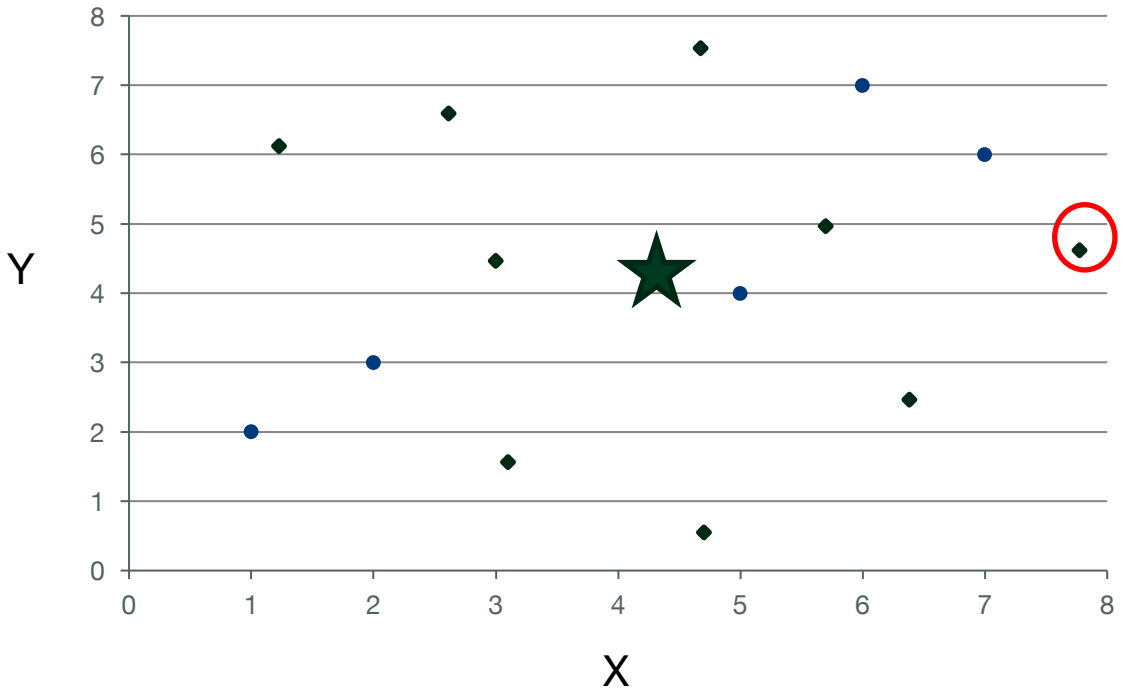
Calculando r

- Os produtos também refletem a força da correlação



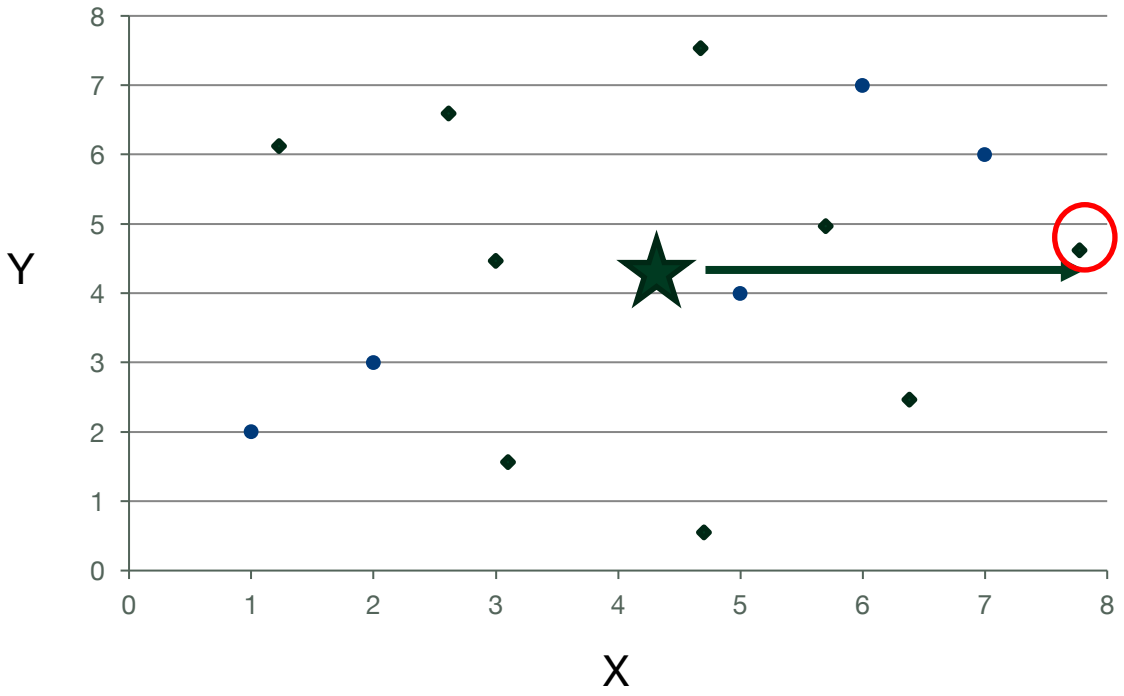
Calculando r

- Os produtos também refletem a força da correlação



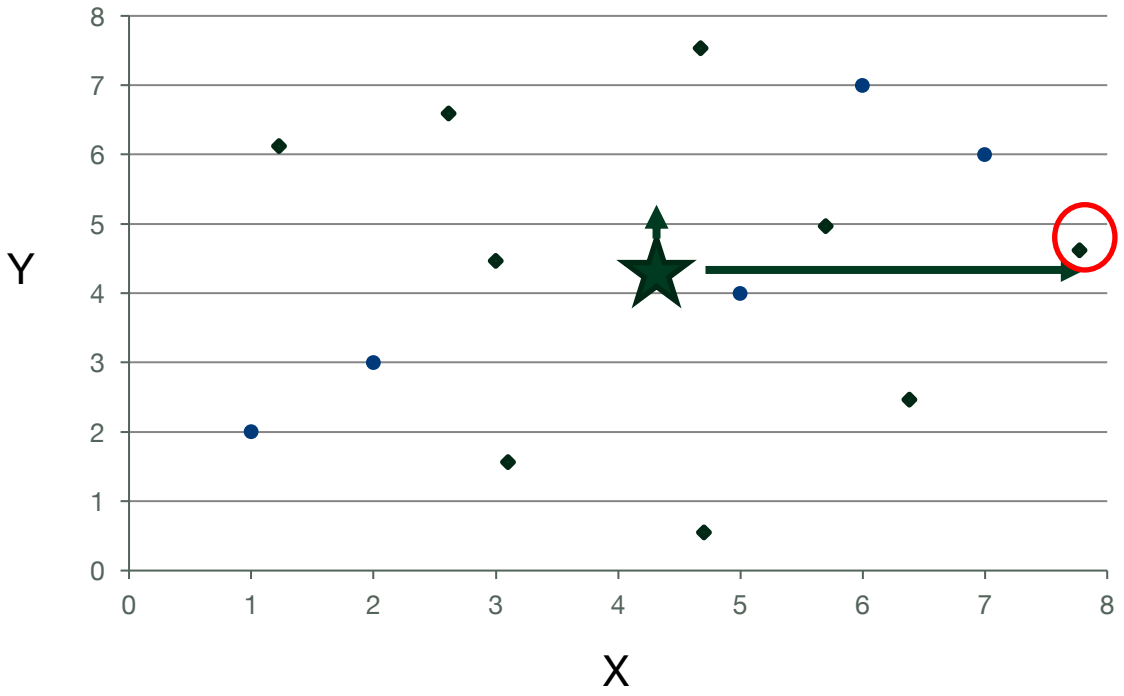
Calculando r

- Os produtos também refletem a força da correlação



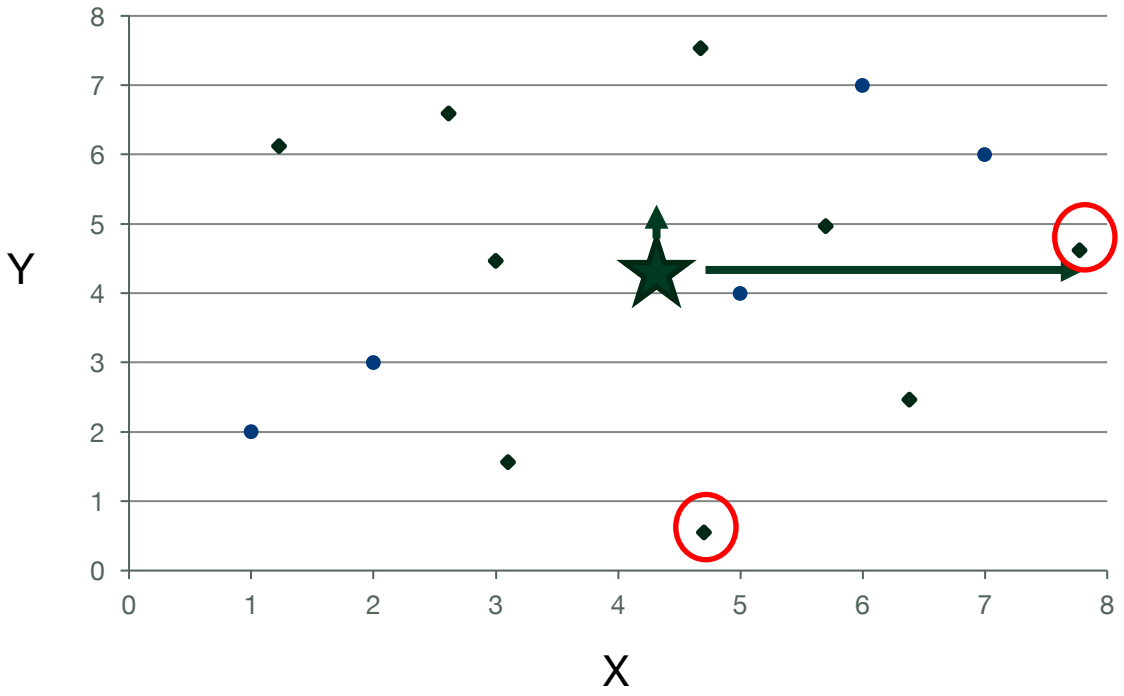
Calculando r

- Os produtos também refletem a força da correlação



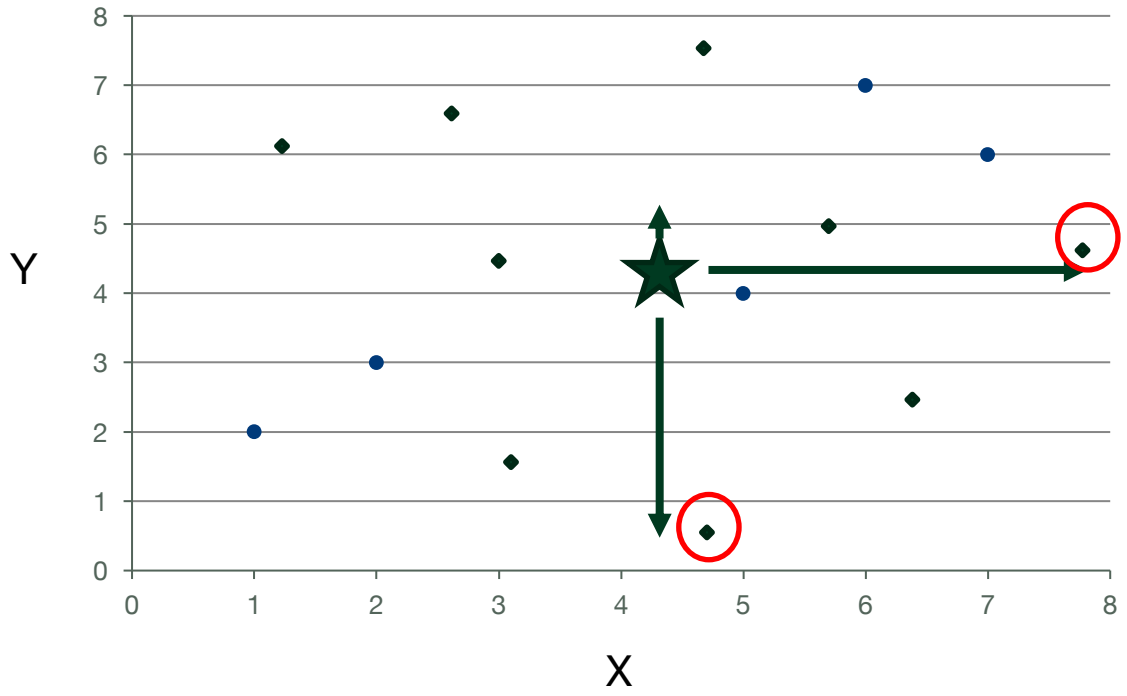
Calculando r

- Os produtos também refletem a força da correlação



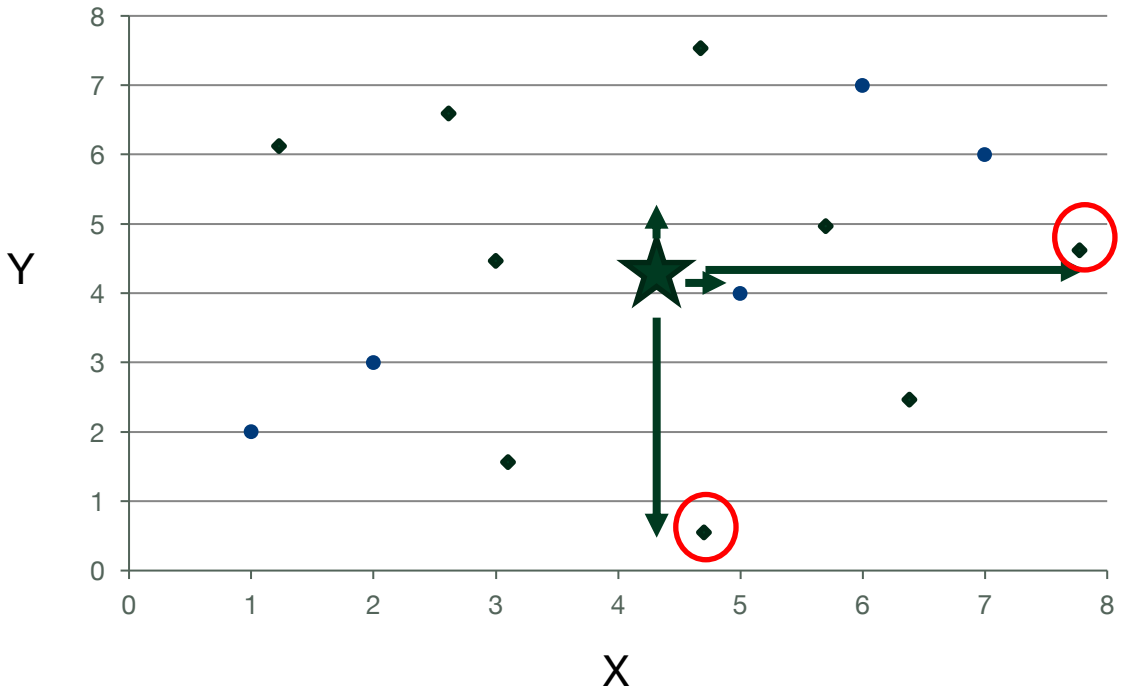
Calculando r

- Os produtos também refletem a força da correlação



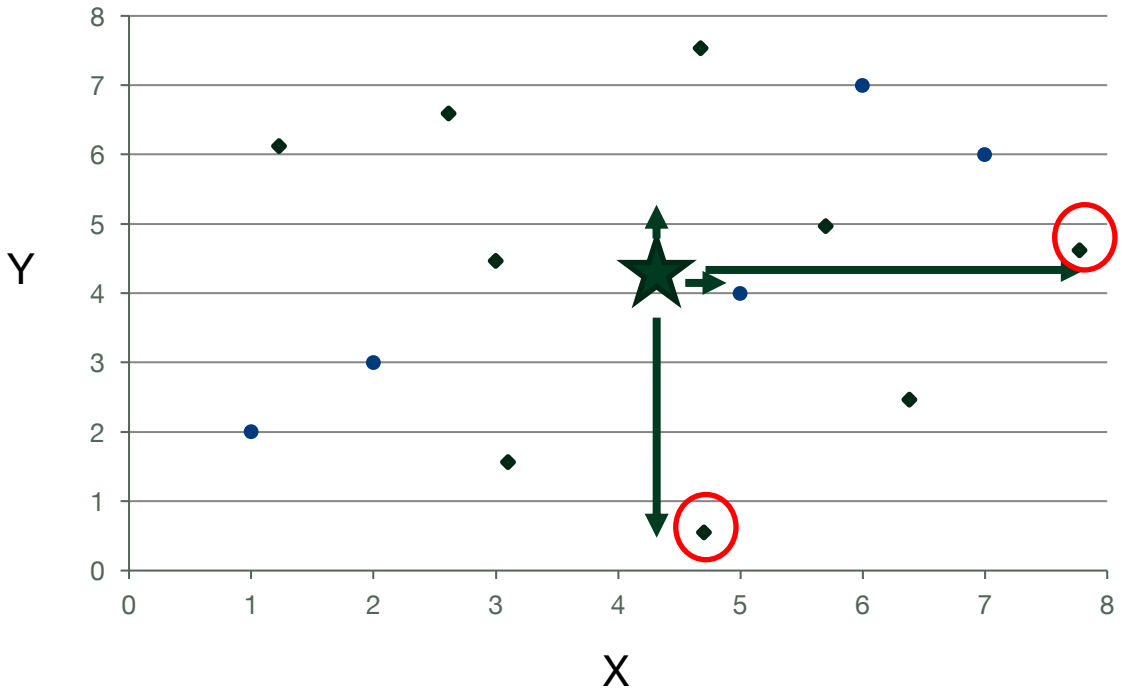
Calculando r

- Os produtos também refletem a força da correlação



Calculando r

- Os produtos também refletem a força da correlação



Para correlações fracas:

Desvios tendem a cancelar uns aos outros

Calculando r

- Agora precisamos comparar isso com a variância total
  - Começamos com SQ para cada variável
  - Então nós tomamos a raiz quadrada do produto
  - Esta medida da variância total é o nosso denominador:

$$\sqrt{(SQ_x * SQ_y)}$$

Calculando r

- Portanto, o coeficiente de correlação é apenas a forma padronizada de SP
  - Padronizado de modo que varia de -1 a 1

$$r = \text{Soma dos Produtos dos Desvios} / \sqrt{(SQ_X * SQ_Y)}$$

$$r = \Sigma[(X - M_x)(Y - M_y)] / \sqrt{(SQ_x * SQ_Y)}$$

$$r = \frac{\text{Quantidade da variância comum}}{\text{Quantidade da variância total}}$$

Espera e satisfação: soma dos produtos

O numerador de r é SP, a soma dos produtos dos desvios.

X (min)	Y (0–10)	$X - M_x$	$Y - M_y$	Produto
5	9	–22,5	2,4	–54,0
10	8	–17,5	1,4	–24,5
15	10	–12,5	3,4	–42,5
20	6	–7,5	–0,6	4,5
25	7	–2,5	0,4	–1,0
30	8	2,5	1,4	3,5
35	4	7,5	–2,6	–19,5
40	6	12,5	–0,6	–7,5
45	3	17,5	–3,6	–63,0
50	5	22,5	–1,6	–36,0

Dados simulados para fins didáticos

M_x = 27,5 min
M_y = 6,6 pontos

SP = –240

Somamos os produtos dos desvios das 10 pessoas.

Espera e satisfação: somas dos quadrados

Elevamos cada desvio ao quadrado e somamos separadamente para X e Y.

X	Y	$X - M_x$	$Y - M_y$	$(X - M_x)^2$	$(Y - M_y)^2$
5	9	–22,5	2,4	506,25	5,76
10	8	–17,5	1,4	306,25	1,96
15	10	–12,5	3,4	156,25	11,56
20	6	–7,5	–0,6	56,25	0,36
25	7	–2,5	0,4	6,25	0,16
30	8	2,5	1,4	6,25	1,96
35	4	7,5	–2,6	56,25	6,76
40	6	12,5	–0,6	156,25	0,36
45	3	17,5	–3,6	306,25	12,96
50	5	22,5	–1,6	506,25	2,56

$M_x = 27,5$
$M_y = 6,6$

$SQ_x = 2.062,5$

$SQ_y = 44,4$

$\sqrt{(SQ_x \times SQ_y)} \approx 302,61$

Dados simulados para fins didáticos

Espera e satisfação: cálculo de r

Dividimos SP pela raiz quadrada do produto das duas somas de quadrados.

Soma dos produtos	SQ_x	SQ_y
–240	**2.062,5**	**44,4**

$$r = SP / \sqrt{(SQ_x * SQ_y)}$$

$$r = -240 / \sqrt{(2.062,5 * 44,4)} \approx -0,793$$

Passos do teste de hipóteses

5. Tome uma decisão.

- Compare seu r calculado com o r crítico a partir do passo 4
- **Rejeitar ou não rejeitar a hipótese nula**

Espera e satisfação: conclusão

r = –0,793

r crítico = ±0,632

|r| = 0,793 > 0,632

Espera e satisfação: conclusão

r = –0,793

r crítico = ±0,632

|r| = 0,793 > 0,632

r(8) = –0,793
p = 0,006 (bilateral)

Rejeitamos H_0

Nesta amostra, maior tempo de espera está associado a menor satisfação com o atendimento.

A associação não demonstra que a espera, sozinha, causou a insatisfação.

Tamanho do efeito e variabilidade compartilhada

$r = -0{,}793$

O sinal indica a direção negativa. A magnitude mostra a força da associação linear neste conjunto.

$r^2 \approx 0{,}629$

Cerca de 62,9% da variabilidade da satisfação é contabilizada pelo ajuste linear que usa o tempo de espera.

r^2 descreve o ajuste nesta amostra. Não demonstra causalidade.

Dados simulados para fins didáticos

Correlação parcial

- As pessoas mais altas têm vozes mais grossas?
- E se você encontrou r = .60?
- Existe uma TERCEIRA VARIÁVEL que realmente está conduzindo este efeito?
- Sexo?
  - Homens mais altos em média
  - Homens vozes mais grossas em média
  - Pode ser gênero, e não a altura que gera o efeito

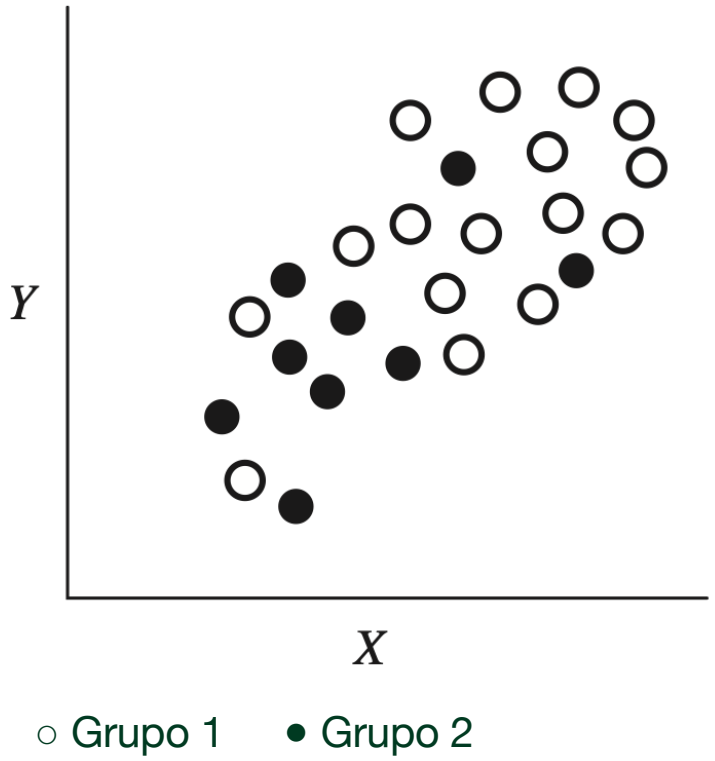
Correlação parcial

- Quando criamos uma correlação parcial nós:
  - Controlamos para remover parcialmente a...
  - ...variância de uma outra variável que potencialmente confunde ou altera a correlação entre duas outras variáveis

- Uma vez que controlamos pelo sexo da correlação entre altura e tom de voz, resta alguma correlação?

- As correlações parciais permitem “descontaminar” as correlações
  - Muitas vezes útil quando não temos controle experimental…

Correlação dentro e entre grupos

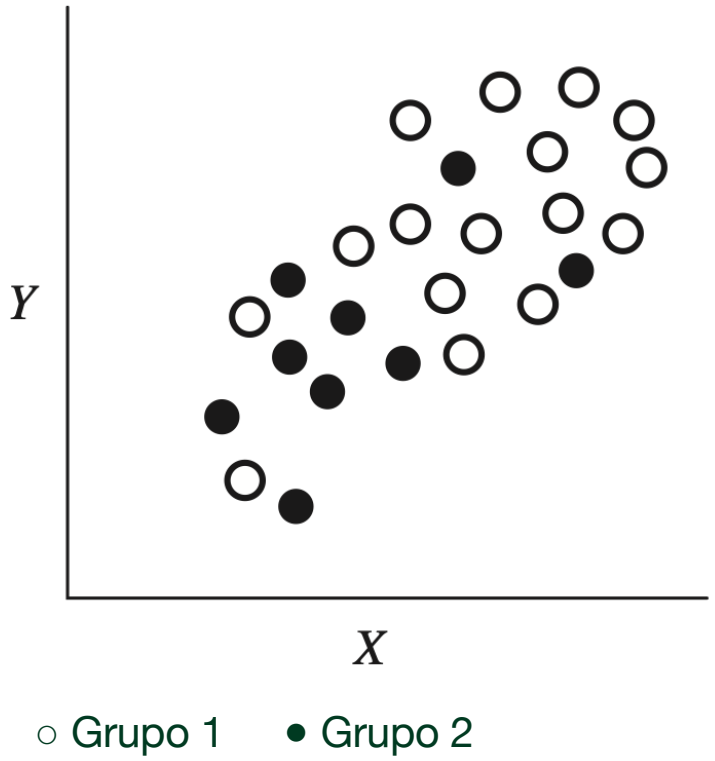


Juntando todos os pontos, X e Y parecem crescer juntos.

A tendência continua quando olhamos cada grupo separadamente?

A pergunta é se a associação depende apenas da junção dos dois grupos.

A associação permanece nos grupos



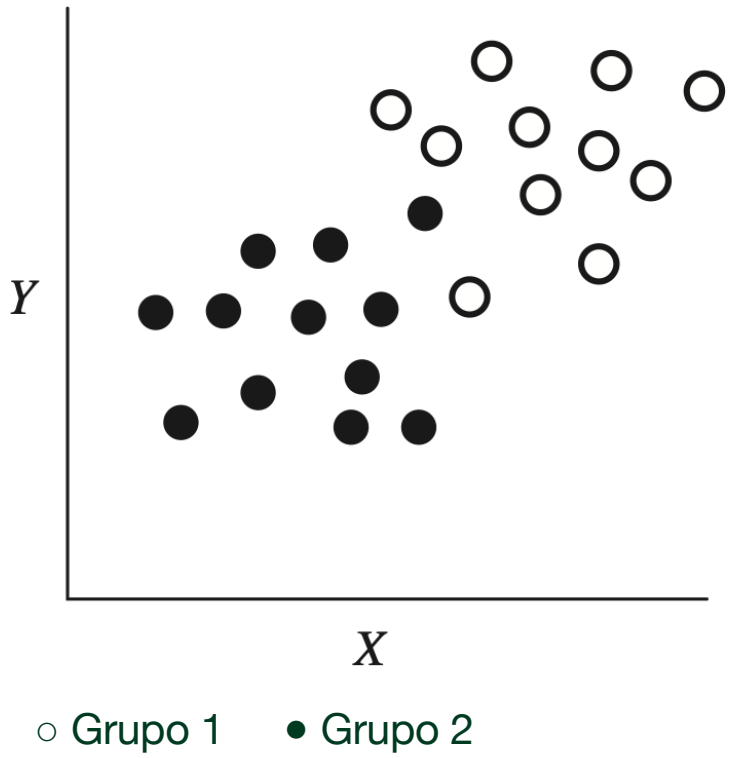
Em ambos os grupos, valores maiores de X tendem a acompanhar valores maiores de Y.

A associação não surge apenas da diferença entre as médias dos grupos.

Exemplo hipotético: horas de estudo e nota podem se associar nos dois turnos.

A associação persistir após o controle de turno não demonstra causalidade.

Uma associação no conjunto



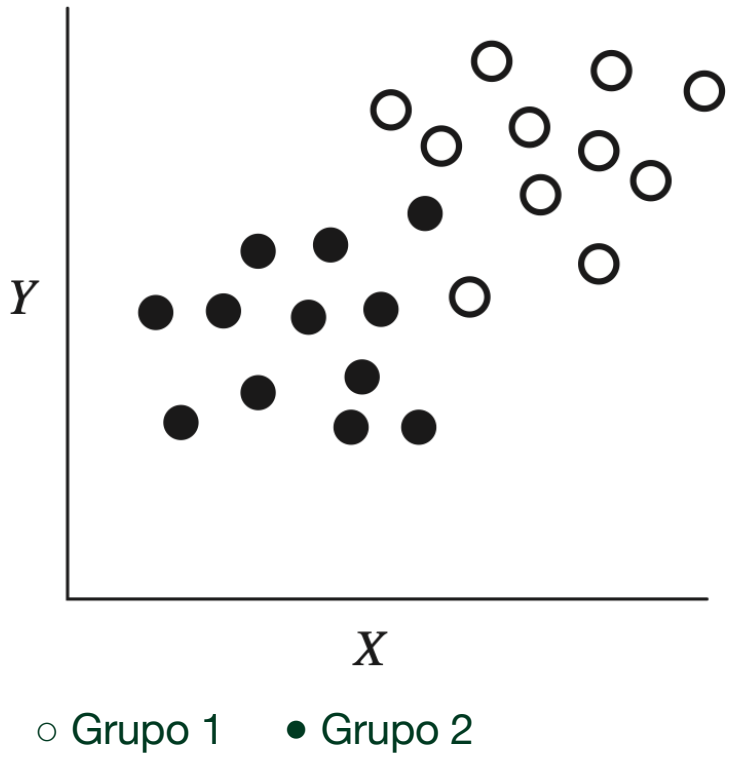
Um grupo concentra valores menores de X e de Y; o outro, valores maiores.

Juntando os grupos, aparece uma tendência crescente.

Dentro de cada grupo, essa tendência também está presente?

O padrão agregado pode refletir diferenças entre as médias dos grupos.

A associação reflete os grupos



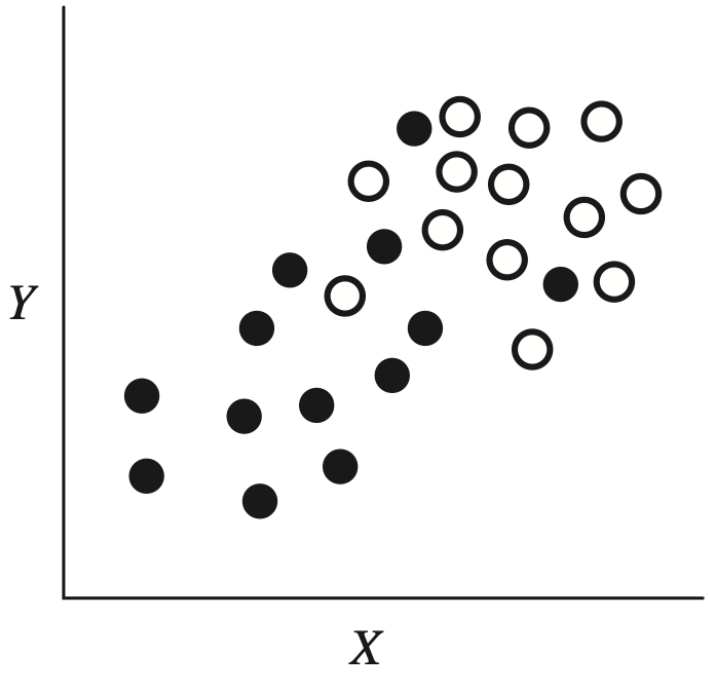
Dentro de cada grupo, não há uma tendência linear clara entre X e Y.

A correlação conjunta reflete principalmente a diferença entre as médias.

Exemplo hipotético: faixa etária pode explicar uma associação entre tamanho do pé e hábito de leitura.

Compare observações do mesmo grupo antes de interpretar a associação conjunta.

Relações diferentes entre grupos



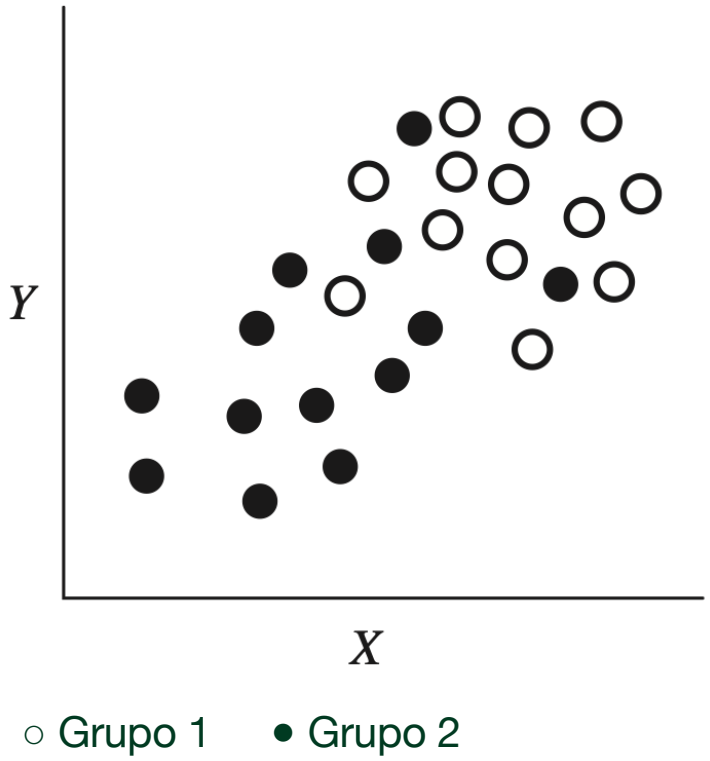
Em um grupo, X e Y apresentam uma tendência crescente.

No outro, a tendência linear é pouco evidente.

Podemos resumir os dois grupos com uma única associação?

A relação entre X e Y pode depender do grupo observado.

A associação depende do grupo



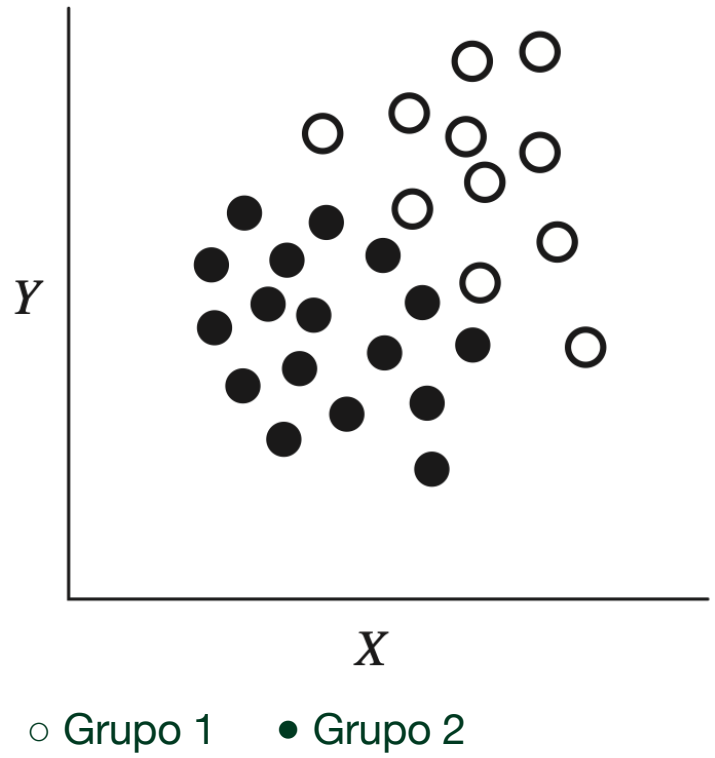
Esse padrão sugere heterogeneidade da associação.

Um único coeficiente de correlação parcial pode esconder essa diferença.

Na regressão, avaliamos essa hipótese com uma interação entre X e grupo.

O gráfico sugere uma hipótese. O teste da interação exige os dados.

A direção muda dentro dos grupos



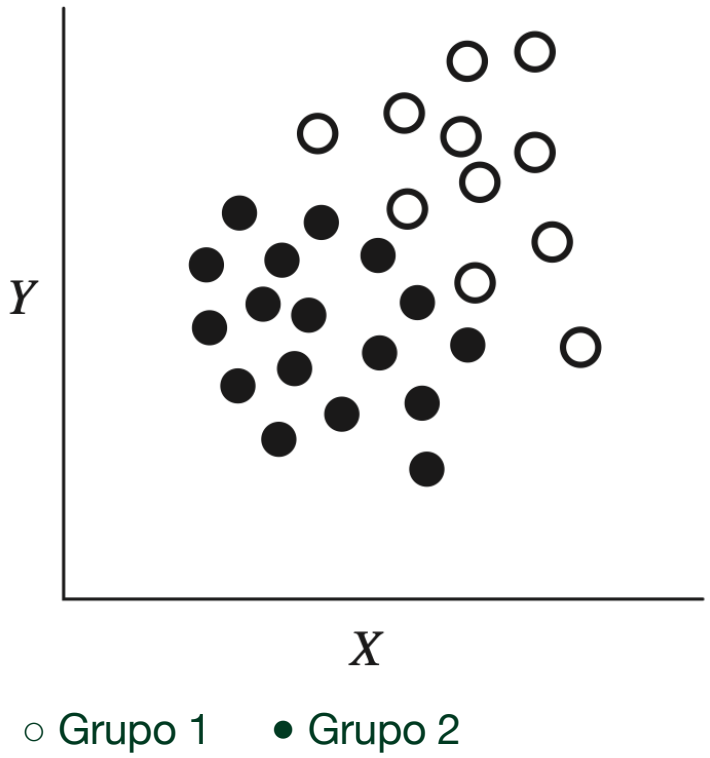
Juntando todos os pontos, a associação parece positiva.

Dentro de cada grupo, valores maiores de X tendem a acompanhar valores menores de Y.

Como o conjunto pode crescer se cada grupo apresenta uma tendência decrescente?

As comparações dentro e entre grupos respondem a perguntas diferentes.

“Paradoxo de Simpson"



A associação no conjunto pode ter direção oposta à associação em cada grupo.

A composição dos grupos altera o padrão observado quando agregamos os dados.

Precisamos distinguir a comparação entre grupos da comparação dentro deles.

A escolha do controle depende da pergunta e do papel de uma terceira variável.

Paradoxo de Simpson: um exemplo

Exemplo fictício: aprovação em duas disciplinas

Disciplina	Grupo A	Grupo B
Avançada	20 / 100 = 20%	5 / 50 = 10%
Introdutória	45 / 50 = 90%	80 / 100 = 80%
Total	**65 / 150 = 43,3%**	**85 / 150 = 56,7%**

A tem maior taxa em cada disciplina. B tem maior taxa no total.

A composição muda o resultado

O grupo A tem mais avaliações na disciplina de menor aprovação.

Distribuição das avaliações	Grupo A	Grupo B
Avançada	100 de 150 (66,7%)	50 de 150 (33,3%)
Introdutória	**50 de 150 (33,3%)**	**100 de 150 (66,7%)**

Taxa de A = (100 × 20% + 50 × 90%) / 150 = 43,3%

Taxa de B = (50 × 10% + 100 × 80%) / 150 = 56,7%

Idade, experiência e salário

Associação inicial

Trabalhadores mais velhos podem receber salários maiores e também ter mais experiência.

Pergunta após considerar a experiência

Entre pessoas com experiência semelhante, idade e salário ainda apresentam associação?

Na correlação parcial de Pearson, ajustamos idade e salário pela experiência e correlacionamos os resíduos dos dois ajustes.

Uma associação após o ajuste não demonstra causalidade.

Correlação e causalidade

