UNIDADE 4

Regressão linear Parte 1

Modelos, coeficientes e valores previstos

Robert Vidigal

MQAPP / UnB · 2026.2

Ceia de Natal: pratos e reclamações

Um familiar suspeita que, quanto mais pratos prepara para a ceia de Natal, menos seu irmão reclama da comida.

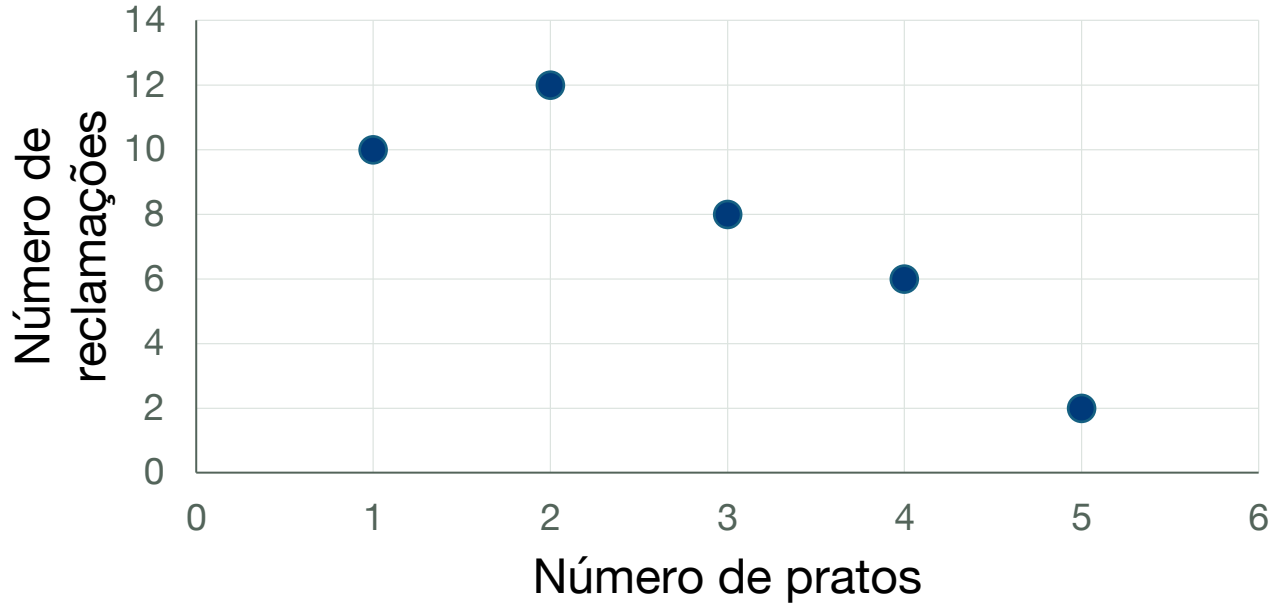
Em cinco ceias, ele registrou o número de pratos e a quantidade de reclamações.

Há evidência dessa associação negativa, com α = 0,05?

Ceia	Pratos X	Reclamações Y
1	2	12
2	4	6
3	5	2
4	3	8
5	1	10

Ceia de Natal: gráfico de dispersão

Cada ponto representa uma ceia de Natal.



O gráfico sugere uma associação negativa.

Ceias com mais pratos tendem a apresentar menos reclamações neste conjunto.

Dados do exercício didático

Ceia de Natal: hipóteses

A pergunta é direcional: esperamos uma correlação populacional negativa.

Hipótese nula

$$H_0: \rho \geq 0$$

A correlação populacional não é negativa.

Hipótese alternativa

$$H_1: \rho < 0$$

A correlação populacional é negativa.

Teste unilateral à esquerda, com $\alpha = 0{,}05$.

Ceia de Natal: graus de liberdade

Temos cinco pares de medidas, um para cada ceia.

$$g.l. = n - 2$$

$$g.l. = 5 - 2 = 3$$

Usaremos grau de liberdade = 3 para consultar o valor crítico da correlação.

Dados do exercício didático

Ceia de Natal: valor crítico

Na tabela de r, usamos gl = 3 e α = 0,05 unilateral.

g.l.	α unilateral	|r crítico|
3	0,05	0,805

A hipótese prevê sinal negativo.

r crítico = –0,805

Rejeitamos H_0 se r < –0,805.

Ceia de Natal: soma dos produtos

Multiplicamos os desvios de X e Y e somamos os produtos.

X	Y	$X - M_x$	$Y - M_Y$	Produto
2	12	–1	4,4	–4,4
4	6	1	–1,6	–1,6
5	2	2	–5,6	–11,2
3	8	0	0,4	0,0
1	10	–2	2,4	–4,8

$SP = \Sigma[(X - M_x) * (Y - M_Y)]$

$M_x = 3$

$M_Y = 7,6$

$SP = -22$

Ceia de Natal: somas dos quadrados

Elevamos os desvios ao quadrado e somamos cada coluna.

X	Y	$X - M_x$	$Y - M_y$	$(X - M_x)^2$	$(Y - M_y)^2$
2	12	–1	4,4	1	19,36
4	6	1	–1,6	1	2,56
5	2	2	–5,6	4	31,36
3	8	0	0,4	0	0,16
1	10	–2	2,4	4	5,76

$SQ_x = 10$

$SQ_y = 59{,}2$

$$\sqrt{(SQ_x \times SQ_y)} = \sqrt{592} \approx 24{,}33$$

Ceia de Natal: cálculo de r

$$r = SP / \sqrt{(SQ_x \times SQ_y)}$$

$$r = -22 / \sqrt{(10 \times 59{,}2)}$$

$$r \approx -0{,}904$$

$$-0{,}904 < -0{,}805$$

$r(3) = -0{,}904$
$p = 0{,}018$ (unilateral)

Ceia de Natal: decisão e conclusão

$-0{,}904 < -0{,}805$

$r(3) = -0{,}904$
$p = 0{,}018$ (unilateral)

Rejeitamos H_0

Neste exercício, há evidência de associação negativa: ceias com mais pratos tendem a ter menos reclamações do irmão.

A associação não demonstra que mais pratos ***causou*** a redução das reclamações.

O que vamos aprender

Usar uma reta para estimar valores de uma variável a partir de outra.

Interpretar o intercepto e os coeficientes nas unidades do problema.

Fazer previsões com um ou vários preditores e reconhecer os limites do modelo.

Correlação e regressão

Correlação

r resume a direção e a força da associação linear entre duas variáveis.

É uma medida padronizada.

Regressão

A equação estima Y em suas próprias unidades.

A regressão múltipla incorpora vários preditores.

Equação de regressão simples

$$\hat{Y} = \beta_0 + \beta_1 * X$$

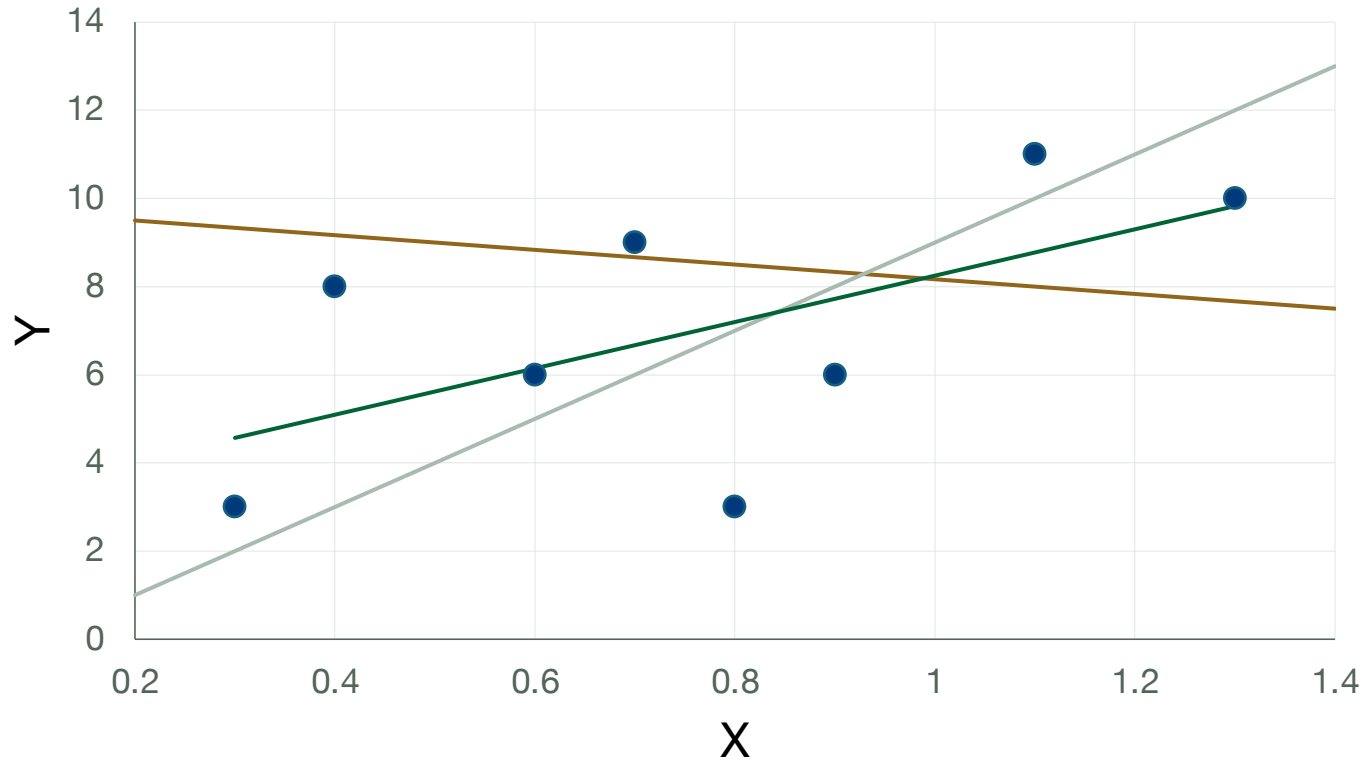
X: valor do preditor
Ŷ: valor previsto do desfecho

β_0 : intercepto, o valor previsto quando X = 0

β_1: variação prevista em Y por unidade adicional de X

Y é o valor observado. Ŷ é a estimativa produzida pelo modelo.

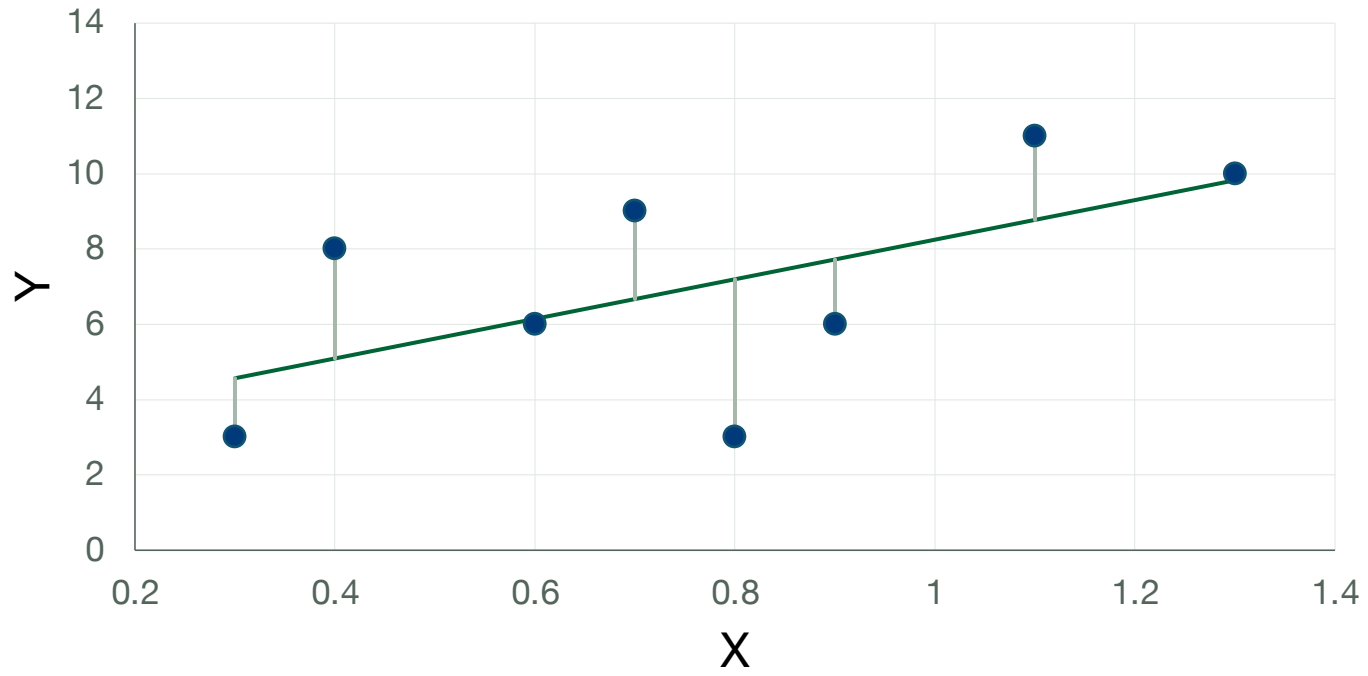
Qual reta representa melhor os dados?



As retas fazem previsões diferentes para os valores de X.

Precisamos de um critério para comparar os erros.

Resíduo: observado menos previsto

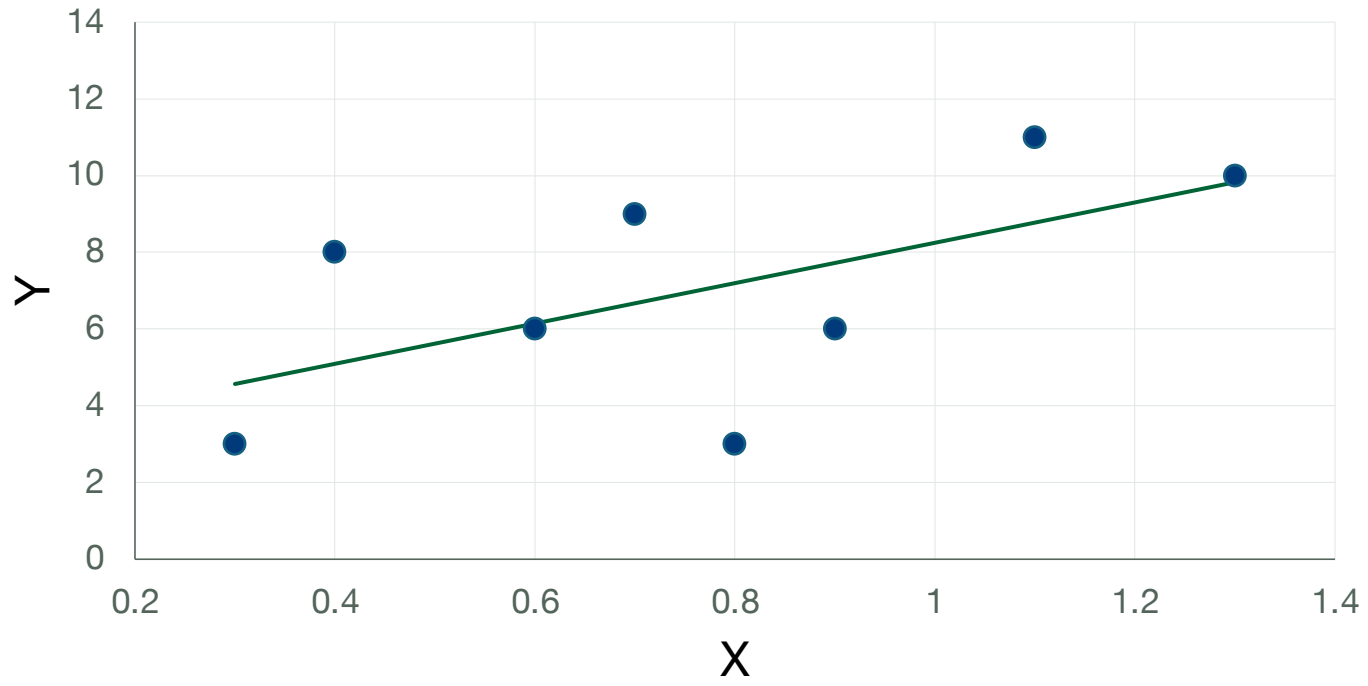


$$e_i = Y_i - \hat{Y}_i$$

É a diferença vertical entre o ponto observado e a reta ajustada.

Resíduos positivos ficam acima da reta. Resíduos negativos ficam abaixo.

Mínimos quadrados ordinários (MQO)



Soma dos quadrados dos resíduos neste ajuste: 41,92

Minimizamos Σe_i^2

Ao elevar ao quadrado, impedimos que resíduos positivos e negativos se anulem.

Como calcular a reta

Inclinação

$$\beta_x = SP / SQ_x$$

Usa a covariância entre X e Y (SP) e a variabilidade de X (SQ_x).

Intercepto

$$\beta_0 = M_y - \beta * M_x$$

A reta passa pelo ponto das médias: (M_x, M_y).

Valores observados e previstos

$$\hat{Y} = \beta_0 + \beta_1 * X$$

Substituímos X pelo valor de interesse e calculamos o valor previsto.

Em geral, Ŷ não coincide com cada Y observado. A diferença é o resíduo.

Evite extrapolar além do intervalo de X observado.

Exemplo: altura e avaliação da voz

Quatro pessoas, duas medidas por pessoa.

X: altura em centímetros
Y: tom da voz, de 1 a 7

Altura (cm)	Tom da voz
121,92	1
152,40	2
182,88	5
198,12	7

M_x = 163,83 cm
M_Y = 3,75 pontos

Exemplo: resultados da regressão simples

Variável	beta	t-score	p-valor
Intercepto (β_0)	–9,1864	–3,876	0,061
Altura (cm)	0,07896	5,544	0,031

Cada centímetro adicional está associado a aproximadamente 0,079 ponto a mais na avaliação prevista da voz.

O intercepto corresponde a X = 0, fora do intervalo observado.
O p > 0,05 não justifica removê-lo automaticamente.

Exemplo: previsões e extrapolação

$$\hat{Y} = -9{,}18 + 0{,}078 \times \text{altura (cm)}$$

Altura (cm)	$\hat{Y}$	Interpretação
167,64	4,051	Dentro do intervalo observado
182,88	5,254	Y observado = 5; resíduo ≈ –0,254
213,36	7,661	Extrapolação; fora da escala de 1 a 7

A precisão dos coeficientes importa. Arredonde apenas o resultado final.

Regressão múltipla: vários preditores

A regressão múltipla estima Y usando mais de uma variável preditora/independente.

Exemplo: prever salário a partir de idade e anos de experiência.

Cada coeficiente descreve uma associação ajustada pelos demais preditores do modelo.

Coeficientes em escalas diferentes exigem cuidado na comparação de magnitudes.

Equação da regressão múltipla

$$\hat{Y} = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \ldots + \beta_k X_k$$

Cada coeficiente β: variação prevista em Y por unidade do respectivo preditor, mantendo as demais variáveis constantes (“ceteris paribus”).

β_0: valor previsto quando todos os preditores são iguais a zero.

Exemplo com quatro preditores

$$\hat{Y} = 100 + 5X_1 + 10X_2 - 5X_3 + 2X_4$$

$X_1 = 5 \quad X_2 = 2 \quad X_3 = 7 \quad X_4 = 10$

$$\hat{Y} = 100 + 25 + 20 - 35 + 20$$

$$\hat{Y} = 130$$

Leitura de um resultado de regressão

Coeficiente: direção e tamanho da associação ajustada.

Erro padrão: incerteza da estimativa do coeficiente.

t-score e p-valor: evidência contra a hipótese de coeficiente populacional igual a zero, sob as condições do teste.

O computador calcula os coeficientes. A interpretação continua sendo nossa tarefa.

Voz: interpretação da regressão múltipla

Variável	beta	t-score	p-valor
Intercepto	8,211	2,261	0,152
Altura (cm)	–0,0484	–1,905	0,197
Sexo (1 = homem)	7,000	5,085	0,037

Mesma altura: a diferença prevista entre gêneros é de 7 pontos na escala de voz.

Altura: associação estimada de –0,0484 ponto por cm, mantendo sexo constante. p-valor = 0,197.

Um p > 0,05 não prova ausência de associação.
O modelo também não estabelece causalidade.

Voz: valores previstos com dois preditores

$$\hat{Y} = 8{,}211 - 0{,}0484 * \text{altura} + 7 * \text{sexo}$$

Altura (cm)	Sexo codificado	$\hat{Y}$
152,40	1 (homem)	7,831
152,40	0 (mulher)	0,831
182,88	0 (mulher)	–0,645

Previsões fora da escala de 1 a 7 mostram uma limitação do modelo linear neste exemplo.

Exemplo: crença no aquecimento global

Acreditar no aquecimento global (0 = não; 1 = sim).

A tabela estima associações ajustadas entre cada preditor e o desfecho.

n = 1.497
R^2 = 0,291

Variável	b	Erro-padrão
Exposição a furacões	0,043	0,035
Escolaridade	0,103**	0,035
Pessoa branca	–0,010	0,026
Religiosidade	–0,054	0,030
Idade (anos)	–0,073	0,046
Mulher	0,107***	0,021
Republicano	–0,129***	0,033
Ideologia	–0,674***	0,042
Intercepto	0,959***	0,039

***p<0,01; **p<0,05; *p<0,10